

DeepSeek Harness

白皮书

从 0 到 1 玩转 DeepSeek Harness 的新手百科全书

版本 0.1.0-rc.6 · 2026-08-13 · 14 章 + 附录 A/B/C

目录

学习路径：从 0 到 1 的 3 天计划

承诺兑现: **任何开发者, 3 天从零到能开发插件。 ** 本路径把 9 章拆成 3 天, 每天有明确目标与验收标准。

Day 1: 理解 + 跑起来 (第 1-2 章)

目标: 理解 dsh 是什么, 能独立启动、对话、配置。

时间	任务	验收	
30 分钟	读第 1 章 (三个直觉 + 能力矩阵)	能向别人解释"dsh 和 Claude Code 的区别"	
30 分钟	第 2 章动手: dsh web 对话 + headless	能启动 UI 完成一次对话; 能跑一条 headless 命令	
30 分钟	配置模型/推理档位 + 排障速查	能改 settings.yaml; 能解决端口占用	

验收: dsh --profile headless "你好" 有回复。

Day 2: 理解骨架 + 第一个插件 (第 3-4 章)

目标: 理解 profile/插件机制, 写出第一个能跑的插件。

时间	任务	验收	
1 小时	第 3 章 (profile、挂载、host/client、扩展点、坑)	能挂载社区插件 (Git 面板)	
1.5 小时	第 4 章抄写示例提速插件: 纯函数 + agent/request 注入	插件加载无错, 日志出现决策输出	

验收: 自己的插件在 dsh 里生效 (日志证明注入发生) 。

Day 3: 实战 + 调优 (第 5-6 章)

目标: 能评估插件质量、调优性能、理解生态玩法。

时间	任务	验收	
1 小时	第 5 章三个真实 PR (安全红线、沙箱约束、测试方法)	能说出"写一个 PR 的完整闭环"	
1 小时	第 6 章性能模型 (思考占 90%) + 档位策略 + 坑	能给一个任务选档位、预估瓶颈	

30 分钟	第 8-9 章扫读（工具/上下文、MCP/子代理/工作流）+ 术语表	知道 dsh 的能力全貌与扩展方向	
-------	------------------------------------	-------------------	--

验收：能给 dsh 生态贡献一个小改进或写一篇使用心得。

之后：按需深入

想做什么	去读	
接外部工具	第 9 章 MCP + 官方 mcp 包文档	
并行任务	第 9 章子代理	
确定性流程	第 9 章工作流 + 官方 examples	
生产部署	官方架构文档 + 安全模型 (sandbox/权限)	
性能极致	第 6 章 + 第 4 章示例源码	
生态变现	第 7 章 + dsh-plugin topic	

学习原则（白皮书全程）

- 1. ****动手 > 阅读****：每章命令都跑一遍，不看会后悔
- 2. ****先复制后理解****：第 4 章完整代码先跑通，再改参数理解机制
- 3. ****单测 + 实机双证据****：开发插件时两个都要过
- 4. ****善用 --dump-config****：疑惑时看合成配置，比猜快

第 1 章：认识 DeepSeek Harness

本章目标：从一个完全零基础的角度，建立对 DeepSeek Harness (dsh) 的完整认知——**它是什么、为什么值得学、和主流 Agent 有什么区别、什么时候用它**。

读完本章，你不需要任何前置知识，就能理解 dsh 在整个 AI 开发工具版图中的位置。

TL;DR (本章核心, 30 秒版)

1. **dsh = Agent 的乐高底座**：官方开源 (MIT) 的运行时，一切能力都是插件，你可以自由拼装
2. **harness = 模型外面的工程层**：会话、工具、上下文、循环控制——让模型在仓库里真正干活
3. **和 Claude Code 的区别**：Claude Code 是"整车"，dsh 是"底座 + 积木"——可定制面完全不同
4. **生态窗口**：2026-08-13 开源，中文教程此前为零——现在入场是早期
5. **谁该用**：要深度定制/玩生态/跑 CI 的开发者；要开箱即用的选 Claude Code

<!-- [fix] 结构核验：补齐本章导航 (第 1 章原缺失，与第 3-11 章结构保持一致) -->

<details><summary>本章导航</summary>

- [1.1 先建立三个直觉](#11-先建立三个直觉)
- [1.2 官方定义与核心事实](#12-官方定义与核心事实)
- [1.3 架构是怎么"一切皆插件"的](#13-架构是怎么一切皆插件的)
- [1.4 DSH 与主流 Agent 的全面对比](#14-dsh-与主流-agent-的全面对比)
- [1.5 什么时候用 dsh (选型决策)](#15-什么时候用-dsh 选型决策)
- [1.6 常见问题 (FAQ)](#16-常见问题 faq)

</details>

1.1 先建立三个直觉

在讲技术之前，先用三个类比建立直觉：

① dsh 是什么？——它是"Agent 的乐高底座"。

想象乐高：官方提供底板和标准积木（运行时 + 核心插件），你可以自由拼装（加插件、换界面、改行为）。对比之下，Claude Code 更像"一辆整车"——很好开，但你想改装发动机得找官方。

② 为什么需要"harness"这个词？——它是"套在模型外面的工程层"。

一个模型（DeepSeek V4）本身只会"回复文字"。要让它在你的代码仓库里干活（读文件、跑命令、改代码、多轮循环），外面需要一层工程：会话管理、工具调用、上下文控制、错误恢复。这层工程就叫 harness。dsh 是 DeepSeek 官方把这层工程开源出来的产品。

③ 为什么 2026 年才开源？——因为 Agent 进入"可编程时代"。

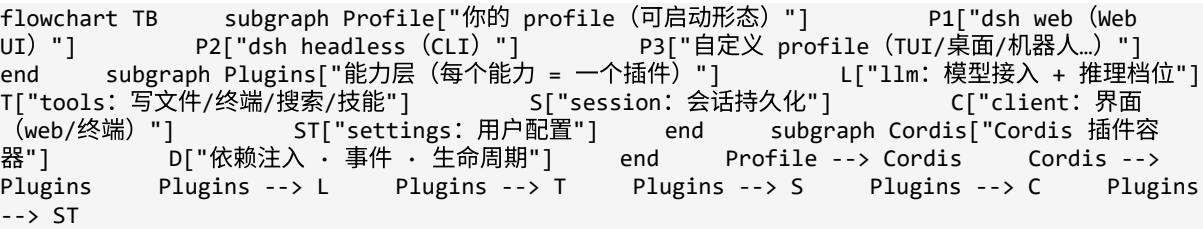
2025 年是"模型能力竞赛"（谁能生成更好的代码）；2026 年进入"Agent 工程竞赛"（谁能更好地组织模型干活）。DeepSeek 开源 harness 的战略意图：把"如何组织 Agent"这件事变成开放生态——像当年 Android 开源改变手机生态一样。

1.2 官方定义与核心事实

一句话定义：DeepSeek Harness (dsh) 是 DeepSeek 官方开源的 Agent 运行时，采用"一切皆插件"（everything is a plugin）架构，基于 Cordis 插件容器构建。


事实	内容	
开源时间	2026-08-13	
协议	MIT (可商用、可改)	
语言	TypeScript (Node.js ≥ 22)	
版本线	0.1.0-rc.x (当前 rc.6, 迭代快, 官方明示"将有破坏性变更")	
底层	Cordis https://github.com/cordiverse/cordis (可组合插件容器)	
内置形态	web (Web UI) + headless (一次性 CLI)	
官方定位	官方 README 原话: "everything is a plugin"	

1.3 架构是怎么"一切皆插件"的



<!-- [style] 子标题统一不带编号（原 3.1/3.2 为旧章节号残留，对齐其余章节） -->

分层视图



<!-- [style] 子标题编号统一：去掉残留旧编号 -->

三个必须懂的概念

① profile（可启动形态）

一个 profile = \$DSHHOME/profiles/<name>/ 目录，包含：

- `package.json`：插件依赖 + 清单（`dsh.profile.bundles` 指定 bundle 顺序）
- `cordis.patch.yml`：你的补丁层（挂载/覆盖插件）

启动时按顺序合成：内置 bundle → profile patch → 全局 patch → --patch 覆盖。

② host 半 / client 半（一个插件，两副面孔）

半边	跑在哪	干什么	
host 半	Node 进程	工具、服务、事件、文件系统——applyctx 注册	
client 半	浏览器（web profile）	UI、交互—— package.json 的 dsh.client 声明	

一个 npm 包可同时携带两半（exports["."] + exports["./client"]）。

③ 扩展点（extension point）

官方原则："Plugins, not loop changes"——改行为优先用官方钩子，不要 fork 核心。常用扩展点（后续章节逐一实战）：

- `agent/request` waterfall：每次模型请求前改配置（工具调用提速插件的挂点）
- `conversationEvents.register`：订阅/注入对话事件
- `ctx.slots.inject`：在界面槽位注入 UI
- `settings` 服务：注册用户可配置项

1.4 DSH 与主流 Agent 的全面对比

<!-- [style] 子标题编号统一：去掉残留旧编号 -->

能力矩阵（核心六家）

维度	dsh	Claude Code	OpenAI Codex	OpenCode	Gemini CLI	Kimi CLI	
开源	✔ MIT	✘ 闭源	✘ 闭源	✔ MIT	✘ 闭源	✘ 闭源	
模型绑定	模型无关 (官方适配 DeepSeek)	Claude 系	GPT 系	任意	Gemini 系	Kimi 系	

官方运行时	✅ (web + headless + 插件生态)	产品即运行时	产品即运行时	客户端 (无官方后端)	产品即运行时	产品即运行时	
插件体系	官方级：一切皆插件，60+ 官方包	配置/钩子为主	配置为主	配置为主	无	无	
自定义界面	✅ (client 半 = 自由 UI)	❌	❌	部分 (TUI 固定)	❌	❌	
自动化/CI	✅ headless profile	✅	✅	✅	✅	✅	
TUI	插件可做 (官方未内置)	✅ 内置	✅ 内置	✅ 内置	✅	✅	
生态阶段	零日起步 (2026-08-13)	成熟	成熟	成熟	成熟	早期	
适合谁	想深度定制 + 玩生态的开发者	开箱即用	开箱即用	熟悉 OpenCode 用户	Google 生态	Kimi 生态	

<!-- [style] 子标题编号统一：去掉残留旧编号 -->

更多主流 Agent 速览（一句话定位）

Agent	一句话定位	与 dsh 的核心差异	
Cursor	IDE 内嵌的 AI 编码助手 (Composer/Agent 模式)	深度绑定 IDE；dsh 是独立运行时，可配任意编辑器/终端	
Amp	终端原生、代理优先的 AI 编码 agent	轻量终端形态；dsh 多了官方后端 + 插件生态	
Devin	云端"AI 软件工程师" (独立任务/浏览器/工作区)	托管云端；dsh 本地运行、数据不出本机	
Windsurf	IDE 内嵌编码 agent (Flow/Agent 模式)	同 Cursor，绑定 IDE	
Aider	开源、Git 优先的终端 pair-programming	专注"改代码 + git"；dsh 是通用运行时	

	agent		
Qwen Code	阿里通义 coding agent CLI (内置 DeepSeek provider)	主打 Qwen 模型; dsh 官方适配 DeepSeek 且插件化	
GLM CLI	智谱 coding agent CLI	主打 GLM 模型; dsh 模型无关 + 插件生态	
Grok CLI	xAI 终端 coding agent	主打 Grok 模型	

结论: 主流 agent 大致分三类——**IDE 内嵌** (Cursor/Windsurf) 、 **终端编码助手** (Codex/OpenCode/Aider/Qwen Code/GLM CLI/Grok CLI) 、 **运行时/平台** (dsh/Devin) 。 dsh 是目前唯一"官方开源 + 模型无关 + 插件生态"的运行选型选手。

<!-- [style] 子标题编号统一: 去掉残留旧编号 -->

通俗文字版: 每家是什么、适合谁、和 dsh 差在哪

Claude Code (Anthropic) : 目前最成熟的终端编码助手。开箱即用、TUI 体验好、生态成熟——适合想马上干活的人。缺点: 闭源、绑定 Claude 模型、定制空间有限 (只能配置/钩子) 。和 dsh 比: dsh 能改的东西它改不了 (界面/工具链/后端) , 但 dsh 的"开箱即用"还比不上它。

OpenAI Codex: OpenAI 的终端 agent。工程能力强、GPT 系模型加持。同样闭源绑定。和 dsh 比: 能力线接近, 但 dsh 开源可自改。

OpenCode: 开源、终端、可配任意模型——和 dsh 最像的"邻居"。关键差异: OpenCode 没有官方后端运行时 (它是客户端 + 配置) , dsh 有官方 bundle + 60+ 包 + 插件生态, 可定制面更深。如果你是 OpenCode 用户, 迁移 dsh 的成本很低 (概念类似) 。

Gemini CLI: Google 的终端 agent。长上下文/多模态是强项 (Gemini 模型优势) 。绑定 Google 生态。

Kimi CLI: 月之暗面的终端 agent。中文场景好、Kimi 模型加持。生态早期。

Cursor / Windsurf: IDE 内嵌型——它们的优势是"编辑器里就用", 劣势是你被锁在 IDE 里。dsh 是独立运行时, 可以在任意环境 (终端/CI/服务器/未来的 TUI) 用同一套 agent 能力。

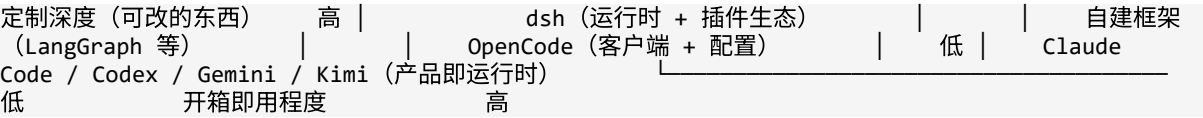
Devin: 云端工程师——你给它任务, 它在云上干活。优势是托管、有浏览器; 劣势是数据出本机、费用高。dsh 本地运行, 隐私可控。

Aider: 老牌开源、Git 优先、轻量。适合"只想让 AI 帮改代码"的极简主义者。dsh 是更重的运行时——如果你只需要 Aider 做的事, Aider 够用; 如果你想做 Agent 系统, dsh 是底座。

Qwen Code / GLM CLI / Grok CLI: 各家模型的终端 agent——模型绑定是它们的天然属性。dsh 模型无关 (官方适配 DeepSeek, 可接 OpenAI 兼容) , 更适合想"模型可换"的人。

<!-- [style] 子标题编号统一: 去掉残留旧编号 -->

一张图理解 dsh 的差异化位置



- **右上**：dsh——可定制面最大，但"开箱即用"需生态补足
- **左上**：自建框架——完全自由但全要自己搭
- **右下**：产品型 agent——最好用但最封闭

<!-- [style] 子标题编号统一：去掉残留旧编号 -->

案例对比：同一个任务，不同的打开方式

任务：让 Agent 在仓库里"找到所有调用某个函数的地方，并统一改一个参数"。

Agent	你会怎么做	体验	
dsh (web)	dsh web → 输入指令 → 模型用 Grep/Read/Edit 工具完成	Web UI + 右侧插件侧边栏（可加 Git 面板）	
dsh (headless)	dsh --profile headless "任务" → 打印结果退出	可进 CI：非零退出码即失败	
Claude Code / Codex / OpenCode / Kimi	打开 TUI → 输入指令 → 模型完成	终端 TUI，开箱即用	
Cursor / Windsurf	在 IDE 里选中代码 → 输入指令	IDE 内嵌体验	
Devin	网页里建任务 → 云上完成	托管、有浏览器、数据出本机	

差异点在哪：同样一句话，dsh 让你多了一个选择维度——界面和工具链都可以换。其他 Agent 的界面/工具链是官方定的，dsh 是你拼的。

<!-- [style] 子标题编号统一：去掉残留旧编号 -->

案例对比：真实工作流（我们的实测）

以下是我们真实开发 dsh 生态时的对比观察（2026-08-13）：

场景	dsh 实测	备注	
简单文件创建	冷启动 ~110s（首轮含上下文注入）→ 热缓存 ~1s	思考档位是主要变量	
50 步工具链任务	LLM 耗时 10m+，工具调用 9m+	每步思考累计——提速插件价值在此	
插件开发	从零到可运行插件：1 天（含测试+实机验证）	扩展点清晰（agent/request waterfall）	

与 Claude Code 同任务	dsh 配 V4-Flash 成本约为 Claude 的 1/10~1/30	价格维度 dsh 生态显著占优	
-------------------	--	-----------------	--

同模型 × 不同 Agent 的严格对比见 [Benchmark 附录](./benchmark.md) (omp 36s / dsh 85s / opencode 114s) 。

1.5 什么时候用 dsh（选型决策）

✅ 推荐入场：

- 你要做**模型无关、界面可选、行为可改**的 Agent 底座
- 你想成为 **dsh 生态早期贡献者**（先发优势，官方点名鼓励）
- 你要在**服务器/CI** 跑 Agent (headless profile)
- 你对**成本敏感**（DeepSeek 模型 + 开源生态）

⏸ 暂时观望：

- 只要"开箱即用的编码助手"——Claude Code 等更成熟
- 不能接受 rc 阶段的破坏性变更——等 `0.1.0` 正式版
- 重度依赖某模型独有能力（如 Claude artifacts）——模型绑定场景

1.6 常见问题（FAQ）

Q1：dsh 是模型吗？

不是。dsh 是运行时/框架，模型通过 llm 插件接入（官方适配 DeepSeek V4 系，理论上可接其他 OpenAI 兼容模型）。

Q2：dsh 和 OpenCode 什么关系？

都是开源 Agent 客户端，但定位不同：OpenCode 是"客户端 + 配置"，dsh 是"运行时 + 官方插件生态"（有官方后端 bundle 与 60+ 官方包）。dsh 更底层、可定制面更大。

Q3：没写过 TypeScript 能玩吗？

能。使用（第 2 章）不需要编程；写插件（第 4 章）需要基础 TS，但教程给完整代码。

Q4：dsh 稳定吗？

当前 rc 阶段（0.1.0-rc.6），迭代快、有破坏性变更。生产核心依赖建议等正式版；玩生态现在正是时机。

Q5：为什么现在学 dsh 值得？

生态零日 + 官方点名鼓励社区 + 中文教程空白——每个早期生态都有"第一个吃螃蟹的人"的红利，现在是入场窗口。

下一章：[第 2 章：五分钟快速上手](./02-quickstart.md) —— 装起来，跑起来。

动手练习（检验你是否真懂了）

1. ****一句话测试****: 向不懂技术的人解释"dsh 是什么" (不能用"Agent/harness/插件"这些词)
2. ****对比测试****: 说出 dsh 和 Claude Code 的 3 个本质区别 (不是功能列表)
3. ****选型测试****: 给下面场景选工具并说明理由:
 - 场景 A: 想要开箱即用的终端编码助手
 - 场景 B: 想做一个"模型无关、界面自定义"的公司内部 Agent 平台
 - 场景 C: 想在 CI 里每天自动跑一个数据分析任务
4. ****架构测试****: 画出"profile → 插件 → 扩展点"的关系图 (不看原文)
5. ****FAQ 测试****: 回答"dsh 是模型吗? "没写过 TS 能玩吗? "

完成练习后, 进 [第 2 章](./02-quickstart.md) 动手装起来。

第 2 章：五分钟快速上手

本章目标：**跟着做，跑起来**。每一条命令都给出预期输出与常见错误解法。建议打开终端边看边做。

TL;DR (本章核心, 30 秒版)

- 1. **装**: ``npx -y @deepseek-ai/dsh web`` → `http://127.0.0.1:3080`
 - 2. **两种常用模式**: `web` (对话 UI) / `headless` (``dsh --profile headless "任务",`` CI 友好) ——官方共四种运行模式 (见 2.4.1 总览)
 - 3. **推理档位**: `off` / `low` (关闭或弱思考/最快, 官方 provider 用 ``off``, 网关用 ``low``) / `high` (默认) / `max` (最强) ——**工具链任务 90% 时间在思考, 降档是最快提速**
 - 4. **模型**: ``deepseek-v4-flash`` (默认, 性价比) 或 ``deepseek-v4-pro`` (旗舰)
 - 5. **配置**: ``~/dsh/settings.yaml`` (模型 + 推理档位)
- <!-- [fix] 结构核验: 补齐本章导航 (第 2 章原缺失, 与第 3-11 章结构保持一致) -->

<details><summary>本章导航</summary>

- [2.1 准备工作 (30 秒检查)](#21-准备工作 30-秒检查)
- [Node 版本红线 (≥22.19)](#node-版本红线 2219)
- [2.2 安装 (三种方式)](#22-安装三种方式)
- [安装坑 (社区真实踩过)](#安装坑社区真实踩过)
- [2.3 模式一: Web UI (`dsh web`)](#23-模式一 web-uidsh-web)
- [2.4 模式二: Headless (一次性任务, 适合脚本/CI)](#24-模式二 headless 一次性任务 适合脚本 ci)
- [2.4.1 官方四种运行模式总览](#241-官方四种运行模式总览)
- [2.5 你的第一个插件: 给 web 加个 Git 面板](#25-你的第一个插件给-web-加个-git-面板)
- [2.6 配置与目录速查](#26-配置与目录速查)
- [2.7 命令速查](#27-命令速查)
- [2.8 排障速查](#28-排障速查)

</details>

2.1 准备工作 (30 秒检查)

需要	检查命令	通过标准	
Node.js ≥ 22.19	<code>node --version</code>	v22.19.0 或更高 (红线, 见下)	
npm (随 Node 附带)	<code>npm --version</code>	有版本号即可	

网络	能访问 npm registry	能装包	
(可选) DeepSeek API Key	https://platform.deepseek.com	用于真实对话	

没有 API Key 也能启动 dsh (界面能开) , 但对话需要 Key。本白皮书示例假设已配置。

Node 版本红线 (≥22.19)

社区实测发现 Node < 22.19 会触发两个致命缺失：

缺失 API	报错示例	触发帖号	
node:zlib 无 createZstdDecompress	TypeError: zlib.createZstdDecompress is not a function	#100 https://github.com/deepseek-ai/deepseek-harness/discussions/100	
AbortSignal.timeout 未实现	AbortSignal.timeout is not a function	#311 https://github.com/deepseek-ai/deepseek-harness/discussions/311	

Workaround：用 nvm/volta/fnm 切换到 22.19.0+。Node 24 早期版本（如 v24.15）也可能触发 install-lefthook failed——若遇此错，pin 到 22.19.0 最稳 ([#748](<https://github.com/deepseek-ai/deepseek-harness/discussions/748>))。

2.2 安装（三种方式）

方式一：直接运行（推荐新手）

```
npx -y @deepseek-ai/dsh --version
```

首次运行会下载 dsh（包体较大，含 40+ 插件模块，约 1-3 分钟）。看到版本号即成功：
<!-- [style] 输出/目录类代码块统一补 text 语言标签 -->
0.1.0-rc.6

方式二：全局安装（推荐频繁使用）

```
npm install -g @deepseek-ai/dsh dsh --version
```

方式三：免装 Node 的安装包（新手可选）

不想装 Node？社区作者 codeAnqiang-ma ([#380](<https://github.com/deepseek-ai/deepseek-harness/discussions/380>) 插件踩坑帖作者，已授权收录) 提供了免装 Node 的安装包——mac DMG / Windows exe，底层官方 dsh 原样打包、自带 Node 运行时，零前置依赖：

[dsh-installers](<https://github.com/codeAnqiang-ma/dsh-installers>) (非官方，随官方 rc 版本发布对应安装包，含 SHA256 校验)

适合「不想折腾 Node 环境、双击即用」的尝鲜用户；需要插件开发/频繁升级的话仍建议方式一或二。

安装坑（社区真实踩过）

坑	现象	解决	帖号	
首次 npx 极慢 (Windows)	npx dsh web 首次在 Windows 上 8+ 分钟零反馈，npm 需下载 500+ 包	耐心等待；改用 npm i -g @deepseek-ai/dsh 后秒启	#176 https://github.com/deepseek-ai/deepseek-harness/discussions/176	
pnpm dlx 404	pnpm dlx @deepseek-ai/dsh web 报 @deepseek-ai/dsh-pty@0.0.1-rc.2 未发布	用 npx 或 npm i -g 替代 pnpm dlx	#369 https://github.com/deepseek-ai/deepseek-harness/discussions/369	
pnpm 全局装后找不到插件	pnpm add -g @deepseek-ai/dsh 后启动报 Cannot find package 'cordis-plugin-timer'	pnpm 全局安装的依赖解析策略与 npm 不同；建议用 npm i -g 或 npx	#55 https://github.com/deepseek-ai/deepseek-harness/discussions/55	
WSL2 上 npx 装不上	在 WSL2 (Ubuntu 等发行版) 里 npx -y @deepseek-ai/dsh 安装失败	先确认 npm 代理配置；仍不行就改用源码安装（社区实测可行）	#118 https://github.com/deepseek-ai/deepseek-harness/discussions/118	

****WSL2 安装注意****：社区在 [#118](<https://github.com/deepseek-ai/deepseek-harness/discussions/118>) 反映 WSL2 上 `npx` 安装可能失败（Windows 原生侧正常，见该帖“win 上都装好开始玩了”的对照）。排查顺序：① 确认 npm 代理/registry 配置；② 若 `npx` 仍装不上，****先试源码安装****（clone 官方仓库后 `pnpm install`，社区实测可行）。详见该帖评论区。

全局安装方式对比：****`npm i -g`** 最稳（社区验证最多）**；****`npx`** 适合尝鲜**；****`pnpm dlx`** 暂不建议（rc 阶段 pty 包未发布到 pnpm 可见 registry）**。

2.3 模式一：Web UI（`dsh web`）

启动

```
dsh web
```

预期输出：

```
dsh web: http://127.0.0.1:3080
```

浏览器打开 <http://127.0.0.1:3080>。

界面认识（对照截图）

![dsh Web UI 对话](./assets/demo-web-chat.png)

区域	内容	
左栏	会话列表 / 工作区切换 / 新建会话	
中栏	对话区：输入框、模型选择（DeepSeek V4 Flash）、推理等级（High）	
右侧/底部	插件侧边栏（默认空；安装社区插件后出现）	
右上	Session log（会话日志） / 轨迹（工具调用轨迹）	

第一次对话

- 1. 点「新建会话」
- 2. 输入框输入：`你好，请用一句话介绍你自己`
- 3. 回车发送

预期回复类似：

你好！我是 DeepSeek 驱动的 AI 编程助手，可以帮你写代码、调试问题、处理文件、搜索资料，以及完成各种开发和办公任务。

模型与推理档位

点输入框旁的「选择模型」，打开模型与推理档位选择器：

![dsh 模型选择与推理档位](./assets/demo-model-selector.png)

模型	定位	
deepseek-v4-flash（默认）	性价比：快、便宜，日常够用	
deepseek-v4-pro	旗舰：更强，更贵更慢	

推理等级（思考模式三档，2026-08-13 起支持）：

档位	速度	质量	建议场景	
low	最快	够用	简单/确定性任务、批量、工具链廉价轮次	
high（默认）	中等	好	日常 Agent 任务	
max	最慢	最强	复杂推理、长链规划	

<!-- [fix] 技术准确性核验：上表档位为本白皮书实测环境（pi-ai / opencode-go 网关）所支持。DeepSeek 官方适配器（默认 provider=deepseek-official，llm-deepseek 插件）只接受 off（关闭思考，最快） / high / max 三档，low 会抛 UNSUPPORTEDREASONINGEFFORT。在 settings.yaml 里对默认 provider 请使用 off / high / max -->

💡 ****性能关键认知****：模型在****每次工具调用前都会重新思考****。实测一个“创建文件”任务，思考占 ~90% 墙钟时间；50 步工具链任务思考累计可达数分钟到十几分钟。****调低推理档位是性价比最高的提速手段****（见第 6 章 + 示例提速插件）。

2.4 模式二：Headless（一次性任务，适合脚本/CI）

```
dsh --profile headless "你好，请用一句话介绍你自己"
```

预期输出（打印结果后进程退出）：

你好！我是 DeepSeek 驱动的 AI 编程助手，可以帮你写代码、调试问题、处理文件、搜索资料，以及完成各种开发和办公任务。

Headless 的核心价值：

- ****自动化****：可进 CI、服务器、cron
- ****脚本友好****：非零退出码 = 失败；输出可管道处理
- ****会话隔离****：每次调用一个新鲜会话（`--resume` 可恢复，见 `dsh --profile headless --help`）

实战：写个脚本每天跑一次“生成日报”：

```
dsh --profile headless "读取工作区今天的 git log，生成一份中文日报摘要" > daily-report.md echo "exit=$?"
```

2.4.1 官方四种运行模式总览

来源：官方站点 <https://deepseek.com/harness/> 与官方仓库 `docs/`（2026-08 快照）。前两节（web / headless）是白皮书实测详讲的；后两种模式官方已公布但白皮书暂未逐项实测。

模式	一句话	用途	白皮书覆盖	
Standard mode (标准)	完整工具集 + 浏览器界面	日常对话/开发 (dsh web)	✅ 2.3 节实测	

Minimal mode (极简)	仅 bash + strreplaceditor 两 个工具	基准测试、最小攻 击面	⚠ 未实测，见官方 docs	
Code mode (代 码)	模型写 TypeScript，在单 次程序内编排多轮 工具调用	长链路自动化、确 定性执行	⚠ 未实测，见官方 docs	
Creator mode (创 造)	运行时自检 + 内存 内测试 Cordis 插件 + 组合新模式	插件开发、快速原 型	⚠ 未实测，见官方 docs	

对新手：日常用 ****Standard (web) ****、脚本用 ****Headless**** 即可；Code/Creator 模式属于进阶能力，等官方文档稳定后再深挖。官方文档站 (VitePress)：<https://deepseek-harness.github.io/deepseek-harness/>

2.5 你的第一个插件：给 web 加个 Git 面板

dsh 的侧边栏默认是空的——安装社区插件 dsh-better-sidebar 体验"一切皆插件"（详细原理见第 3 章，这里先跑通）：

```
# 1. 找到你的 web profile #      Windows: %USERPROFILE%\dsh\profiles\web #      macOS/Linux:
~/dsh/profiles/web # 2. 在 package.json 的 dependencies 加一行 (link: 指向插件源码) #
"dsh-better-sidebar": "link:C:\\path\\to\\DSH-better-sidebar" # 3. 在 cordis.patch.yml 加
挂载行 #      - insert: #      - id: better-sidebar #      name: dsh-better-sidebar #
4. 安装并重启 cd ~/.dsh/profiles/web && pnpm install #      (Windows cmd 下 `~` 不展开，请用：
cd %USERPROFILE%\dsh\profiles\web) dsh web
```

重启后，右侧出现文件管理 / 终端 / Git 面板 / 浏览器等标签：

![dsh Git 面板 (better-sidebar 插件)](/assets/demo-git-panel.png)

图中「拉取远端 / 拉取合并 / 推送」按钮是社区 PR 实现的（见第 5 章案例）——****这就是"插件生态"的运转方式****。

2.6 配置与目录速查

首次运行后生成的目录：

```
~/dsh/ |— settings.yaml      # 全局设置 (模型、推理档位) |— profiles/      #
profile 目录 |   |— web/ |   |— package.json    # 插件依赖 + 清单 |   |—
cordis.patch.yml # 补丁层 (挂载插件) |— sessions/      # 会话数据 |— storages/
# 持久化存储
```

settings.yaml 示例：

```
agent-default-model:  model: deepseek-v4-flash  reasoningEffort: high
```

2.7 命令速查

命令	用途	
dsh web	启动 Web UI (=dsh --profile	

	web)	
dsh --profile headless "任务"	一次性任务，打印结果退出	
dsh plugin --profile <name> add <pkg>	给 profile 安装插件	
dsh --dump-config	打印合成配置树	
dsh --profile tui	TUI 模式（需先安装 tui 插件，官方未内置）	
dsh --version	版本	

2.8 排障速查

现象	原因与解法	
dsh: profile "tui" does not exist	tui profile 需插件创建（dsh plugin --profile tui add <pkg>）	
npx 极慢	首次下载包体大；npm i -g 后更快	
浏览器打不开 3080	端口被占：netstat -ano \	findstr 3080 → kill PID
模型无响应	检查 ~/.dsh/settings.yaml 模型配置 + API Key	
插件装不上（404）	rc.1 依赖断裂：确认依赖用 ^0.1.0-rc.6 线（第 3 章常见坑 #1）	
升级后行为变了	rc 阶段破坏性变更正常，看官方 changelog	

下一章：[第 3 章：profile 与插件系统](./03-profiles.md) —— 理解可定制骨架。

***源码方式启动慢的根因（#1424 社区实测确认）**：`pnpm dsh web` 每次启动用 tsx/esbuild 现场转译整个 TS 源码图（非全量构建），叠加机械盘/大文件数时冷启动可达数分钟。解决：先 `pnpm build` 全量构建一次，或直接用 `npx @deepseek-ai/dsh web`（发布版）绕开转译开销。*

动手练习（10 分钟内完成）

- 1. ****安装****：`npx -y @deepseek-ai/dsh --version` 确认版本
- 2. ****Web 对话****：启动 `dsh web`，新会话发"你好"，观察回复与界面布局
- 3. ****Headless****：`dsh --profile headless "1+1 等于几"`，确认打印结果后退出

4. ****推理档位实验****: 把 settings.yaml 的 ``reasoningEffort`` 改为 ``off`` (官方 provider) 或 ``low`` (第三方网关), 重新跑一个简单任务, 感受速度差异
5. ****排障演练****: 模拟"端口被占" (先起一个占用 3080 的服务), 用 ``netstat`` 排查全部通过后, 进 [第 3 章](./03-profiles.md) 理解"为什么能这样改".

第 3 章：profile 与插件系统

本章目标：理解 dsh 的可定制骨架——profile 怎么组织、插件怎么挂载、host/client 双半是什么。
**这是从“用户”变成“开发者”的分水岭。 **

TL;DR（本章核心，30 秒版）

- 1. **profile = 一种可启动形态**：`~/dsh/profiles/<name>/` 目录，由 `package.json`（插件清单）+ `cordis.patch.yml`（补丁层）组成
- 2. **挂载插件只需两步**：`package.json` 加依赖 + `cordis.patch.yml` 加挂载行，然后 `pnpm install` 重启
- 3. **host 半跑在 Node，client 半跑在浏览器**：一个 npm 包通过 `exports["."]` 和 `exports["./client"]` 同时携带两副面孔
- 4. **改行为找扩展点，别 fork 核心**：`agent/request` waterfall、`conversationEvents`、`ctx.slots.inject`、`settings` 服务是四大常用钩子
- 5. **rc 阶段三大坑**：依赖版本用 `^0.1.0-rc.6` 线、`next()` 必须 await、client 测试需要 dsh 运行时

<details> <summary>本章导航</summary>

- [3.1 profile：一个可启动的配置栈](#31-profile 一个可启动的配置栈)
- [内置 Agent 预设：标准 / PTC / 极简 / 创造](#内置-agent-预设标准-ptc-极简-创造)
- [3.2 挂载一个插件：两处改动](#32-挂载一个插件两处改动)
- [3.3 host 半与 client 半：一个包，两副面孔](#33-host-半与-client-半一个包两副面孔)
- [3.4 扩展点：改行为优先找钩子，别 fork 核心](#34-扩展点改行为优先找钩子别-fork-核心)
- [3.5 常见坑（真实踩过）](#35-常见坑真实踩过)
- [依赖解析坑](#依赖解析坑)
- [插件安装格式坑](#插件安装格式坑)
- [其他常见坑](#其他常见坑)

</details>

3.1 profile：一个可启动的配置栈

dsh 用 profile 表示“一种可启动的形态”。官方内置两个，其余用插件创建：

profile	用途	命令	
web	Web UI（对话 + 侧边栏 + 工具）	dsh web	
headless	一次性 CLI 任务	dsh --profile headless "任务"	

tui (需插件)	终端 UI	dsh --profile tui (未内置, 需安装插件)	
-----------	-------	--------------------------------	--

一个 profile 目录长这样 (~/.dsh/profiles/<name>/) :

<!-- [style] 目录树代码块统一补 text 语言标签 -->

```
profiles/web/ └─ package.json      # 插件依赖 + dsh.profile 清单 (bundles 顺序) └─
cordis.patch.yml  # 你的补丁层: 挂载/覆盖插件的声明 └─ cordis.yml          # (生成的) 合成
配置 └─ pnpm-workspace.yaml └─ node_modules/
```

加载顺序 (官方文档原文) : 内置 bundle (dsh-base → dsh-web-app) → profile 的 cordis.patch.yml → 用户级 ~/.dsh/cordis.patch.yml → --patch 覆盖层。

内置 Agent 预设：标准 / PTC / 极简 / 创造

profile 解决"以什么形态启动", Agent 预设解决"以什么方式跑 Agent"。dsh 内置了四种 Agent 预设 (源码在官方仓库 apps/cli/config/agent-presets/ 的 agent.cordis.yml) , 每种预设默认加载不同的插件集合:

预设	定位	加载内容	典型场景	
标准	默认预设	完整工具组合	日常 Agent 工作	
PTC (Code mode)	代码驱动工具链	程序化工具调用——模型生成一段代码组合多轮工具调用	复杂多步骤工具工作流	
极简	基准测试	仅 bash + 一个文件编辑工具	最小环境下的模型基准测试	
创造	插件开发用	检查当前运行时、在内存中试验 Cordis 插件、组合新预设	构建与测试新的插件组合	

PTC 命名澄清

([#1052](https://github.com/deepseek-ai/deepseek-harness/discussions/1052) 评论区社区详解) : PTC = Programmatic Tool Calling (程序化工具调用)。官方中文站只用了「PTC 模式」这个营销名 (官方站点原文: "PTC 模式通过模型生成的一段代码组合多轮工具调用") , 官方英文页面对应 Code mode; 「Programmatic Tool Calling」的完整扩写出自社区详解 ([cnblogs 指南](https://www.cnblogs.com/sing1ee/p/22455466)) , 与源码实现完全吻合。机制与收益详见第 8 章 8.3.1; 四种运行模式总览见第 2 章 2.4.1。

3.2 挂载一个插件：两处改动

以挂载社区插件 dsh-better-sidebar 为例 (真实操作) :

- ① package.json 加依赖 (link: 指向本地源码, 或用 npm 包名) :

```
{  "dependencies": {    "dsh-better-sidebar": "link:C:\\path\\to\\DSH-better-sidebar"  } }
```

② cordis.patch.yml 加挂载行:

```
- insert:      - id: better-sidebar      name: dsh-better-sidebar
```

③ 安装并重启:

```
cd ~/.dsh/profiles/web && pnpm install dsh web # 重启后生效
```

💡 插件默认是**按会话隔离**的（`better-sidebar` 的布局/标签按会话持久化）——挂载是 *profile* 级，但状态是会话级。

3.3 host 半与 client 半：一个包，两副面孔

插件可以同时携带两个运行半：

半边	运行位置	职责	示例	
host 半	Node 进程	工具、服务、事件、文件系统、进程	applyctx 注册工具/服务	
client 半	浏览器 (web profile)	UI、交互、DOM	package.json 的 dsh.client 声明 + src/client/	

package.json 里如何声明 client 半：

```
{  "dsh": {    "client": {      "inject": ["@deepseek-ai/dsh-client-runtime", "@deepseek-ai/dsh-client-locale"],      "platform": "web"    },    "exports": {      ".": { "types": "./lib/types/index.d.ts", "default": "./lib/index.js" },      "./client": { "types": "./lib/types/client/index.d.ts", "default": "./lib/client.js" }    }  }
```

- host 半: `exports["."]` → `apply(ctx)` (cordis 插件主体)
- client 半: `exports["./client"]` → 浏览器侧的 `apply(ctx)`
- `inject`: 声明需要的服务 (cordis 依赖注入)

3.4 扩展点：改行为优先找钩子，别 fork 核心

官方原则 (CONTRIBUTING/AGENTS.md 明示) : "Plugins, not loop changes: new behavior goes on documented extension points"。新手最常见的错误是改核心 loop——正确做法是用扩展点。

已确认的常用扩展点 (后续章节逐一实战) :

扩展点	位置	用途	
agent/request waterfall	agent-loop	每次模型请求前改配置 (provider/model/reasoningEffort/tools) ——提速插件示例用这个	

agent/request-error	agent-loop	请求失败时干预（官方 compaction 插件用这个做上下文溢出恢复）	
conversationEvents.regi ster	client runtime	订阅/注入对话事件（tool/call、turn/start 等）	
ctx.slots.inject	client ui-slots	在界面槽位注入 UI（如 turnTail 显示产物文件行）	
settings 服务	dsh-settings	注册用户可配置的命名空间（设置页自动渲染）	
ctx.provide / ctx.get	cordis	跨插件提供服务	

3.5 常见坑（真实踩过）

依赖解析坑

坑	现象	解决	帖号	
rc.1 依赖断裂	pnpm install 报 @deepseek-ai/dsh-type-meta@0.0.1-rc.1 404	官方 rc.1 时代多个包从未发布；升级到 ^0.1.0-rc.6 线	—	
全局 core.hooksPath 冲突	全局设过 core.hooksPath（如 Codex/Claude Code）→ pnpm install 时 lefthook postinstall 失败	临时取消全局 hooksPath: git config --global --unset core.hooksPath, 装完再恢复	#139 https://github.com/deepseek-ai/deepseek-harness/discussions/139	
macOS 全局安装解析不到插件	pnpm add -g @deepseek-ai/dsh 后启动报 ~88 个插件包 ERRMODULENOT FOUND	pnpm 全局安装的模块解析策略与 npm 不同；macOS 建议用 npm i -g 或 npx	#204 https://github.com/deepseek-ai/deepseek-harness/discussions/204	
koffi 预编译损坏 (Windows)	koffi 3.1.3/3.1.4 的 win32-x64 预编译 binary 损坏 → 目录选择器崩溃/服务静默挂	锁死 koffi@3.1.2: pnpm add koffi@3.1.2 或改 package.json resolution	#293 https://github.com/deepseek-ai/deepseek-harness/	

			discussions/293	
koffi 原生崩溃 (Windows)	选择器 worker 崩溃 (0xC0000005 访问冲突) 或启动后直接挂掉	同上一行锁 3.1.2; 若仍崩, 检查是否 STA 线程 CoUninitialize 段错误 (社区有补丁)	#197 https://github.com/deepseek-ai/deepseek-harness/discussions/197	

插件安装格式坑

格式	写法	注意	帖号	
npm 包名	dsh plugin add dsh-better-sidebar	需已发布到 npm; rc 阶段很多社区插件未发布	—	
GitHub 仓库	dsh plugin add github:作者/仓库	只加依赖, 不自动 append 到 cordis.patch.yml, 需手动补挂载行	#656 https://github.com/deepseek-ai/deepseek-harness/discussions/656	
本地路径	link:/path/to/plugin (macOS/Linux) link:C:\path\to\plugin (Windows)	开发调试用; 路径斜杠按平台区分	—	
含空格路径 (Windows)	dsh plugin <...> 传含空格路径	Windows 上含空格路径在内部转发时被拆断: apps/cli/src/plugin.ts 的 runPlugin 用 spawnSync"pnpm", args, { shell: true }——Node 按空格拼接参数、不转义 (Node 22+ 起 DEP0190 警告), 调用方引号到不了转发层	修复方向: shell: false (直接传参数组) 或转发前自行转义	#1420 https://github.com/deepseek-ai/deepseek-harness/discussions/1420

社区踩坑总结: 用 `github:` 格式装插件后, 记得手动去 `cordis.patch.yml` 补 `insert:` 挂载行, 否则插件依赖装了但 dsh 不加载。

其他常见坑

坑	现象	解决	
插件缺 main	dsh: No "exports" main defined	host 插件 package.json 要暴露 . 入口 ("main": "src/index.ts" 可被 tsx 直接加载)	
事件 handler 忘了 await next	请求丢失 provider/model 报错	agent/request 的 next 返回 Promise, 必须 await 后 spread	
类型报 'agent/request' is not assignable to keyof Events	npm 类型未 re-export 官方类型增强	用宽松签名 (ctx.on as unknown as ...) 在边界转换	
client 包产物依赖 window.ModuleLoader	jsdom 无法直接跑 client 测试	组件级测试需 dsh web 运行时 (官方 CI 跑)	

动手练习（检验你是否真懂了）

1. ****理解题****: 不看原文, 画出 `profiles/web/` 目录下的文件结构, 并说出每个文件的作用
- > 自查: 参考本章 3.1 节"profile 目录长这样"
2. ****理解题****: 解释"host 半"和"client 半"分别跑在哪里、各负责什么。一个插件可以只有 host 半吗?
- > 自查: 参考本章 3.3 节表格
3. ****动手题****: 打开你的 `~/dsh/profiles/web/package.json`, 找到 `dsh.profile.bundles` 字段, 说出 bundle 的加载顺序
- > 自查: 参考本章 3.1 节"加载顺序"段落
4. ****动手题****: 假设你要挂载一个名为 `dsh-my-widget` 的插件, 写出 `package.json` 和 `cordis.patch.yml` 各需要加什么内容
- > 自查: 参考本章 3.2 节的两处改动示例
5. ****动手题****: 在 `cordis.patch.yml` 里加一行错误的挂载 (比如拼错插件名), 重启 dsh web, 观察报错信息并记录
- > 自查: 对比本章 3.5 节"常见坑"表格
6. ****思考题****: 官方原则说"Plugins, not loop changes"。如果你想改 dsh 的"模型回复后自动总结"行为, 应该用哪个扩展点? 为什么不该直接改 agent-loop 源码?
- > 自查: 参考本章 3.4 节扩展点表格 + "改行为优先找钩子"原则

常见疑问 FAQ

Q1: profile 和 bundle 有什么区别?

profile 是"一种可启动形态" (如 web、headless) , bundle 是"一组预配置的插件集合"。profile 通过 `dsh.profile.bundles` 指定要加载哪些 bundle, 再叠加自己的 patch。简单说: bundle 是积木包, profile 是拼好的成品。

Q2: `cordis.patch.yml` 里的 `- insert:` 是什么意思? 还有其他操作吗?

`insert` 是"在插件链中插入一个新插件"。patch 文件基于 `cordis` 的配置合并机制, 支持 `insert` (插入)、`override` (覆盖已有插件配置) 等操作。新手只需掌握 `insert` 即可挂载大部分插件。

Q3: 插件状态是按 profile 隔离还是按会话隔离?

挂载是 profile 级的 (装一次, 该 profile 下所有会话都能用) , 但状态是会话级的。比如 `better-sidebar` 的标签布局按会话持久化, 不同会话互不干扰。

Q4: 我想写一个只有 client 半的插件 (纯 UI) , 可以吗?

可以。package.json 里声明 `dsh.client + exports["./client"]`, 不写 `exports["."]` 即可。但注意: client 半无法直接访问文件系统或跑命令, 需要通过 host 半的服务 (`ctx.provide/ctx.get`) 桥接。

Q5: `agent/request waterfall` 和 `conversationEvents.register` 有什么区别? 我该用哪个?

`agent/request` 是"改模型请求配置"的钩子 (`provider/model/tools/reasoningEffort`) , 每次请求前触发, 返回新配置。`conversationEvents.register` 是"订阅/注入对话事件"的钩子 (`tool/call`、`turn/start` 等) , 用于监听或注入事件流。想改请求参数用前者, 想监听对话流用后者。

Q6: 为什么我的插件装上去没反应? 怎么调试?

三步排查: ① 确认 `pnpm install` 无报错且 `node_modules` 里有你的插件; ② 确认 `cordis.patch.yml` 的 `id/name` 拼写正确; ③ 重启 `dsh web` 后看进程日志有没有插件加载信息。如果 host 半有 `console.log`, 日志里应该能看到输出。

下一章: [第 4 章: 插件开发实战](./04-plugin-dev.md) (规划中) —— 从零写第一个 host 插件。

第 4 章：插件开发实战

本章目标：从零写一个**真实可用的 host 插件**——通过 `agent/request` 扩展点自动调节推理档位。这是一个提速插件的完整拆解，所有代码可运行、可测试。

TL;DR (本章核心, 30 秒版)

1. **核心问题**：dsh 每次工具调用前模型都重新思考，50 步任务 90%+ 时间在思考——降档是最快提速
2. **架构三板斧**：纯函数（决策逻辑，零依赖可单测）→ 插件主体（接入 waterfall）→ 实机验证（日志证明注入发生）
3. **`agent/request` waterfall**：每次模型请求前触发，监听者返回值传给下一个监听者，实现"保留原配置 + 覆盖某字段"
4. **`next()` 是 Promise，必须 await**：不 await 直接 spread 会得到空对象，provider/model 丢失报错
5. **开发纪律**：先找扩展点（90% 行为有官方钩子）、逻辑抽纯函数、实机验证不能省

<details> <summary>本章导航</summary>

- [4.1 我们要做什么](#41-我们要做什么)
- [4.2 项目骨架](#42-项目骨架)
- [4.3 纯函数：决策逻辑（零依赖，可单测）](#43-纯函数决策逻辑零依赖可单测)
- [4.4 插件主体：接入 `agent/request` waterfall](#44-插件主体接入-agentrequest-waterfall)
- [4.5 测试](#45-测试)
- [4.6 给新手的三条开发纪律](#46-给新手的三条开发纪律)

</details>

4.1 我们要做什么

问题：dsh 在每次工具调用前模型都会重新思考（reasoningeffort）。一个 50 步工具链任务，"思考"占 90%+ 墙钟时间。

方案：一个 host 插件，监听 agent/request waterfall，根据当前步骤最近的工具调用，把简单轮次的 reasoningeffort 从 high 降到 low。

4.2 项目骨架

<!-- [style] 目录树代码块统一补 text 语言标签 -->

```
dsh-speed-plugin/ |— package.json          # host 插件声明 |— tsconfig.json |— src/ |
|— effort-decision.ts # 纯函数：决策逻辑（零依赖，可单测） |   |— index.ts          #
apply(ctx): 接入扩展点 |— tests/          |— effort-decision.spec.ts
```

package.json 关键字段:

```
{  "name": "dsh-speed-plugin",  "type": "module",  "main": "src/index.ts",  "exports": {    ".": { "types": "./src/index.ts", "default": "./src/index.ts" }  },  "peerDependencies": {    "@deepseek-ai/cordis": "^4.0.1",    "@deepseek-ai/dsh-agent": "^0.1.0-rc.6"  } }
```

⚠ 依赖版本务必用 `^0.1.0-rc.6` 线——`rc.1` 线的 npm 依赖链是断的 (见第 3 章常见坑)。

4.3 纯函数：决策逻辑（零依赖，可单测）

src/effort-decision.ts:

```
export type EffortId = 'low' | 'high' | 'max' export interface ToolCallSample {  name: string  // 工具名, 如 'write'、'read'、'bash'  argsSize: number  // 参数大小 (字符数) } export interface EffortDecisionInput {  recentCalls: readonly ToolCallSample[]  selected: EffortId  // 用户基线档  allowDowngrade: boolean  allowUpgrade: boolean } const SIMPLE_TOOL_RE = /^(fs|bash|terminal|read|write|grep|glob|edit|ls|cat|rm|cp|touch|mkdir|pwd)/i const HEAVY_ARGS = 800 export function decideEffort(input: EffortDecisionInput): EffortId {  const { recentCalls, selected, allowDowngrade, allowUpgrade } = input  if (recentCalls.length === 0) return selected  // 全新提示: 保持基线  const ratio = recentCalls.filter(c => SIMPLE_TOOL_RE.test(c.name) && c.argsSize < HEAVY_ARGS).length / recentCalls.length  const heaviest = recentCalls.reduce((m, c) => Math.max(m, c.argsSize), 0)  if (ratio >= 0.75 && allowDowngrade) return 'low'  if (heaviest >= HEAVY_ARGS * 4 && allowUpgrade) return 'max'  if (ratio < 0.75) return allowUpgrade ? 'high' : selected  return selected }
```

为什么拆成纯函数：决策逻辑与 dsh 运行时解耦——单元测试零依赖、毫秒级、覆盖所有分支，实机只需要验证“注入是否真的发生”。

4.4 插件主体：接入 `agent/request` waterfall

src/index.ts:

```
import type { Context } from '@deepseek-ai/cordis' import { decideEffort, type ToolCallSample } from './effort-decision.ts' export interface SpeedPluginConfig {  enabled: boolean  allowDowngrade: boolean  allowUpgrade: boolean  baseline: 'low' | 'high' | 'max' } export const DEFAULT_CONFIG: SpeedPluginConfig = {  enabled: true,  allowDowngrade: true,  allowUpgrade: false,  baseline: 'high', } const WINDOW = 8 function recentToolCalls(agent: unknown): ToolCallSample[] {  const events = (agent as { session?: { events?: readonly unknown[] } }).session?.events ?? []  const out: ToolCallSample[] = []  for (let i = events.length - 1; i >= 0 && out.length < WINDOW; i--) {    const e = events[i] as { type?: string; data?: { name?: string; arguments?: unknown } } | undefined    if (e?.type !== 'tool/call') continue    out.push({      name: e.data?.name ?? 'tool',      argsSize: typeof e.data?.arguments === 'string' ? e.data.arguments.length : 0,    })  }  return out.reverse() } export function apply(ctx: Context, config: SpeedPluginConfig = DEFAULT_CONFIG): void {  if (!config.enabled) return  // 边界适配: npm 包未 re-export 官方事件类型增强, 这里放宽签名 (第 3 章常见坑)  const on = ctx.on as unknown as (  event: string,  handler: (payload: Record<string, unknown>, next: () => unknown) => unknown | Promise<unknown>,  ) => void  on('agent/request', async (payload, next) => {    const seed = await next() as { reasoningEffort?: unknown }  // ⚠ 必须 await!    const calls = recentToolCalls(payload.agent)    const effort = decideEffort({      recentCalls: calls,      selected: config.baseline,      allowDowngrade: config.allowDowngrade,      allowUpgrade: config.allowUpgrade,    })    console.log(`[speed-plugin] calls=${JSON.stringify(calls)} => reasoningEffort=${effort}`)    return { ...seed, reasoningEffort: effort }  }) }
```

三个关键点（都是真实踩过的坑）：

1. `\*\*next()` 是 Promise*: `await next()` 拿到当前配置；不 await 直接 spread 会得到空对象 → provider/model 丢失 → 报错。

2. ****waterfall 语义****: 监听者的****返回值****传给下一个监听者/最终请求。返回 `{...seed, reasoningEffort}` 就是"保留原配置 + 覆盖推理档位"。
3. ****`agent/request` 每步都触发****: ``agent-loop`` 的 ``buildRequest`` 在每一步都会走这个 waterfall——所以动态决策天然按步生效。

4.5 测试

单元测试（纯函数，零依赖）：

```
import { describe, expect, it } from 'vitest' import { decideEffort } from '../src/effort-decision.ts' it('downgrades to low for simple tool chains', () => {
  expect(decideEffort({ recentCalls: [{ name: 'write', argsSize: 40 }], selected: 'high', allowDowngrade: true, allowUpgrade: true, })).toBe('low') }) // ... 更多分支: 全新提示保持基线 / 禁用降档 / 超大载荷升 max / 混合工具升 high
```

实机验证（关键——证明"注入真的发生"）：

挂载插件（第 3 章方法）→ 重启 dsh web → 发一个创建文件的任务 → 观察 dsh 进程日志：

```
[speed-plugin] agent/request: calls=[] => reasoningEffort=high [speed-plugin] agent/request: calls=[{"name":"write",...}] => reasoningEffort=low
```

第一轮无工具调用 → 保持基线 high；检测到 write 工具 → 下一轮降为 low。注入链路完整工作。

完整可运行代码：参考本章各节代码片段组合即可运行。

4.6 给新手的三条开发纪律

1. ****先找扩展点****: 要改的行为 90% 有官方钩子（``agent/request``、``settings``、``conversationEvents``、``slots``）——不要 fork 核心。
2. ****逻辑抽纯函数****: 决策/计算逻辑与 dsh 解耦 → 单测毫秒级、覆盖全分支；实机只需验证"注入发生"。
3. ****实机验证不能省****: 单测证明逻辑，实机日志证明接线——两个都过才算完成。

 ****官方 cookbook 延伸阅读**** (2026-08 官方新增, 官方仓库 ``docs/cookbook/``) : ``adding-a-package.md`` (如何加包)、``adding-a-tool.md`` (如何加工具)、``adding-a-conversation-node.md`` (加对话节点)、``adding-an-llm-adapter.md`` (写 LLM 适配器)、``adding-a-vendored-package.md`` (vendor 包)、``extension-cookbook.md`` (扩展点合集) 。本章走的是"最小提速插件"路径, 官方 cookbook 覆盖更多扩展点类型, 进阶时对照读。

动手练习（检验你是否真懂了）

1. ****理解题****: 不看原文, 说出这个提速插件的三层架构（纯函数层 / 插件主体层 / 测试层）各自负责什么
- > 自查：参考本章 4.2-4.5 节的文件结构

2. ****理解题****: 解释为什么 `decideEffort` 要设计成纯函数而不是直接在 `apply(ctx)` 里写逻辑。如果决策逻辑依赖了 `ctx.session`, 还能单测吗?
 - > 自查: 参考本章 4.3 节"为什么拆成纯函数"段落
3. ****动手题****: 给 `decideEffort` 写一个新的测试用例: 当 `recentCalls` 里有 3 个简单工具 + 1 个超大参数 (`argsSize = 5000`) 时, 应该返回什么档位? 写出测试代码并运行
 - > 自查: 参考本章 4.5 节单元测试示例, 预期结果取决于 `allowUpgrade` 配置
4. ****动手题****: 在 `apply(ctx)` 里, 如果把 `await next()` 改成 `const seed = next()` (不 `await`), 会发生什么? 写出你的推理, 然后在实机中验证
 - > 自查: 参考本章 4.4 节"三个关键点"第 1 条
5. ****动手题****: 假设你要写一个类似的插件, 但改为根据"当前会话的工具调用总次数"来决定档位 (超过 20 次自动降为 low), 写出纯函数签名和核心逻辑
 - > 自查: 参考本章 4.3 节纯函数设计模式, 关键是输入输出类型定义
6. ****思考题****: `agent/request` waterfall 可以有多个监听者。如果提速插件和另一个插件都监听了 `agent/request`, 谁先执行? 返回值怎么传递?
 - > 自查: 参考本章 4.4 节"waterfall 语义"段落 + 第 3 章 3.4 节扩展点说明

常见疑问 FAQ

Q1: `next()` 返回的 `seed` 里到底包含什么字段?

`seed` 是当前 waterfall 链上游累积的请求配置, 通常包含 `provider`、`model`、`reasoningEffort`、`tools` 等字段。你的监听者拿到 `seed` 后, `spread` 覆盖想改的字段, 其余原样传递。具体字段以官方 `agent-loop` 包的类型定义为准 (`rc` 阶段可能变动)。

Q2: 为什么 `npm` 包的类型签名要"放宽"? 不能直接用官方类型吗?

因为 `npm` 发布的 `@deepseek-ai/dsh-agent` 等包没有 `re-export` 内部的事件类型增强 (`Events` 接口没有被 `module augmentation` 扩展)。直接用 `ctx.on('agent/request', ...)` 会报类型错误。解决方案是在边界用 `as unknown as` 转换, 这是 `rc` 阶段的临时方案, 正式版可能修复。

Q3: 我的插件需要在每个工具调用后都触发决策, `agent/request` 够吗?

够。`agent/request` 在每次模型请求前触发 (包括工具调用后的下一轮请求)。你只需要在监听者里读取最近的工具调用历史 (从 `payload.agent.session.events` 里倒序找 `tool/call` 事件), 就能做按步决策。

Q4: 纯函数测试通过了, 实机验证也通过了, 但用户反馈"有时候没效果", 可能是什么原因?

几种可能：① 用户的 settings.yaml 里 reasoningEffort 是 low，降档无效果（已经最低了）；② 用户的任务全是简单工具，本来就快，感知不到差异；③ waterfall 里有其他插件覆盖了你的返回值。建议加日志记录每步的输入/输出档位。

Q5：我想给插件加一个用户可配置的开关（设置页里能开关），怎么做？

用 settings 服务注册一个命名空间（如 speed-plugin），声明配置项（enabled、baseline 等）。dsh 的设置页会自动渲染表单，用户修改后通过 ctx.get 读取。具体 API 参考官方 dsh-settings 包文档。

Q6：recentToolCalls 函数里为什么要 reverse()？

因为从 events 数组末尾往前遍历（取最近的 N 个），结果是倒序的（最新的在前）。reverse 后恢复时间正序（最旧的在前），和实际调用顺序一致，方便决策逻辑按"最近窗口"理解。

下一章：[第 5 章：实战案例](./05-cases.md)（规划中）—— Git 面板、HTML 草稿预览、提速插件。

第 5 章：dsh 能帮你做什么——应用场景全景

本章目标：抛开“如何开发 dsh”的视角，站在**使用者**角度，看 dsh 能在哪些日常场景真正帮到你。每个场景都有可复制的任务示例与真实耗时参考。

TL;DR（本章核心，30 秒版）

- 1. **dsh 是通用 Agent 运行时**：不只是编码助手——数据分析、文档生成、自动化、代码理解都能干
- 2. **五个核心场景**：日常编码 / 数据处理 / 文档知识 / 自动化运维 / 代码理解与重构
- 3. **用法一致**：一句话描述目标 + 写清楚验收标准，dsh 会自动编排工具链完成
- 4. **真实速度**：简单任务秒级、复杂多步任务 1-5 分钟（V4-Flash + high 档实测）
- 5. **提示词黄金法则**：告诉 dsh“完成的标准是什么”（如“运行验证通过”），比描述过程更有效

<details> <summary>本章导航</summary>

- [5.1 场景总览](#51-场景总览)
- [5.1.1 高缓存命中率：dsh 的成本秘密武器](#511-高缓存命中率 dsh-的成本秘密武器)
- [5.2 场景一：日常编码（最适合入门的场景）](#52-场景一日常编码最适合入门的场景)
- [5.3 场景二：数据处理与分析](#53-场景二数据处理与分析)
- [5.4 场景三：文档与知识工作](#54-场景三文档与知识工作)
- [5.5 场景四：自动化与运维（headless 是王牌）](#55-场景四自动化与运维 headless-是王牌)
- [5.6 场景五：代码理解与重构](#56-场景五代码理解与重构)
- [5.7 让场景落地的三个提示词法则](#57-让场景落地的三个提示词法则)
- [5.8 我的第一个真实任务（15 分钟上手）](#58-我的第一个真实任务 15-分钟上手)
- [5.9 行业视角：dsh 在不同领域的打开方式](#59-行业视角 dsh-在不同领域的打开方式)

</details>

5.1 场景总览

场景	典型任务	dsh 的工具	实测参考	
日常编码	写函数、修 bug、补测试	write / read / bash / grep	5-bug 修复+49 测试：94s	
数据处理	清洗、分析、可视化、报告	read / write / bash / python	数据清洗+可视化：186s	
文档知识	API 文档、教程、总结、翻译	read / write	API 文档生成：1m04s	
自动化运维	批量处理、CI 任务、日志分析	bash / headless	headless 脚本化	

代码理解	重构、审查、技术调研	grep / glob / read / bash	代码重构: 4m37s	
------	------------	---------------------------	-------------	--

所有实测来自白皮书第 10 章真实案例（合成数据），详见 [benchmark](./benchmark.md)。

5.1.1 高缓存命中率：dsh 的成本秘密武器

这是 dsh 生态最被低估的优势。DeepSeek API 的 context cache（提示词缓存）：重复/相似的输入 token 按缓存价计费。实测（真实 dsh 会话统计）缓存命中率可达 97%。

为什么 dsh 缓存命中率特别高：

原因	说明	
会话延续	同会话多轮对话，系统提示/技能目录/历史重复 → 命中	
稳定的工具 schema	每步请求携带相同的工具定义 → 命中	
Agent 工作负载特性	多步工具链反复携带相同上下文 → 命中率天然高	

成本影响（98% 缓存折扣）：

计费项	未命中价	缓存命中价	折扣	
输入（Flash）	\$0.14/M	\$0.0028/M	98%	
输入（Pro）	\$0.435/M	\$0.003625/M	99%+	

实际意义：一个长会话 Agent 任务，绝大部分输入 token 走缓存价——实测中"50 步工具链任务、2.4M 输入 token"的成本远低于按未命中价计算的预期。对高频/批量/长会话场景，这是数量级的成本优势。

怎么让缓存命中率更高：****保持会话延续****（不要频繁新开会话）、****稳定 prompt 前缀****（系统提示/技能目录不要反复变化）、**批量任务放同一会话/同前缀**。

5.2 场景一：日常编码（最适合入门的场景）

典型任务：

- 按需求写一个新函数/模块
- 修复 bug（定位 → 修改 → 验证）
- 补单元测试

任务示例（headless 一键跑）：

```
dsh --profile headless "审查 buggy_calculator.py: 找出所有 bug 修复，写完整测试，运行验证全部通过" # 实测：5 个 bug 全修复 + 49 个测试通过 (94s)
```

为什么 dsh 适合：编码是工具链最完整的场景——读文件、写代码、跑命令、看结果，闭环顺畅。产物（改的文件）会在对话末尾直接可打开。

提示词技巧：一定要写"运行验证"——dsh 会照着闭环；只写"帮我修 bug"它会修完就停。

5.3 场景二：数据处理与分析

典型任务：

- 数据质量检查与清洗
- 统计分析
- 可视化（图表）
- 生成分析报告

任务示例：

```
dsh --profile headless "分析 sales_data.json 的数据质量（缺失/类型错/重复/异常），写清洗脚本+可视化脚本，运行验证，总结处理方案" # 实测：52→35 行归零 + 图表 + 权衡说明（186s）
```

亮点（实测）：dsh 不仅执行，还会说明权衡——"中位数填充会产生尖峰"异常值是否该删除取决于业务"——这是 agent 工程层"会思考"的直接证据。

5.4 场景三：文档与知识工作

典型任务：

- 从代码生成 API 文档
- 把笔记整理成结构化文档
- 总结长文、翻译

任务示例：

```
dsh --profile headless "为 user_module.py（8 个函数）生成完整 Markdown API 文档：参数表、返回值、异常、示例、边界情况" # 实测：423 行 ReadTheDocs 风格文档（1m04s），主动识别"文档契约 vs 代码实现"差异
```

亮点（实测）：dsh 会防御式写作——标注调用陷阱（负数 limit 行为、空参数行为）、发现文档声明与实现不符的地方如实说明。

5.5 场景四：自动化与运维（headless 是王牌）

典型任务：

- 每天定时跑数据任务（日报、监控摘要）
- 批量文件处理（重命名、格式转换）
- CI 里的自动化检查

任务示例（脚本化）：

```
# cron 每天 8 点生成日报 dsh --profile headless "读取工作区 git log，生成中文日报" > daily-report.md # 批处理：目录里所有 .txt 转 .md dsh --profile headless "把 docs/ 下所有 .txt 转成 .md（保留结构）"
```

为什么 headless 是王牌：进程级工具（bash/文件/搜索）全可用 + 非零退出码即失败 + 输出可管道——它是"能写进 CI 的 Agent"。

5.6 场景五：代码理解与重构

典型任务：

- 把过程式代码重构为 OOP
- 全仓库代码审查
- 技术调研 ("这个模块怎么工作的")

任务示例：

```
dsh --profile headless "把 legacy_orders.py 重构为面向对象+职责分离，保持行为一致，写测试验证重构前后输出相同" # 实测：17/17 测试通过，含脚本级产物对比 (4m37s)
```

亮点（实测）：dsh 的工程意识——识别重复代码合并单一入口、保持向后兼容、发现沙箱下 tempfile 权限问题主动换方案。

5.7 让场景落地的三个提示词法则

1. ****写验收标准，不写过程****：`"运行验证通过"` > `"写一个脚本"`——dsh 自己会编排步骤
2. ****给上下文****：一句话说清背景（文件在哪、数据长什么样、目标读者是谁）
3. ****一次一个任务****：复杂目标拆成多轮（每轮一个小闭环），比一次给巨型任务更可靠

5.8 我的第一个真实任务（15 分钟上手）

1. 建一个测试目录，放一个你手头的小文件（代码/数据/笔记）
2. 跑：`dsh --profile headless "总结这个文件，指出 3 个可改进点"`
3. 跑：`dsh --profile headless "给这个文件写一个测试/生成文档"`
4. 对比输出，感受 dsh 的"完成度"——它是不是只给了个大概？验收标准写清楚了吗？

动手练习

1. ****场景识别****：给你手头的 3 个日常任务，判断各属于哪个场景（编码/数据/文档/自动化/理解）
2. ****提示词对比****：对同一任务写两个版本提示词——一个"描述过程"、一个"写验收标准"，跑一遍对比结果
3. ****headless 脚本化****：把"每日 git 日报"写成一行 cron/bash 命令，验证输出
4. ****多步任务****：设计一个跨场景任务（如"读代码 → 生成文档 → 输出报告"），看 dsh 如何编排
5. ****思考题****：什么场景 dsh 不适合？（提示：实时交互、需要人工审批的敏感操作）

常见疑问 (FAQ)

- **Q:** dsh 只是编码助手吗? **A:** 不是——工具链 (读/写/跑/搜) 让它通用, 数据处理/文档/自动化都验证过
- **Q:** 复杂任务会跑多久? **A:** 实测 1-5 分钟 (V4-Flash) ; 要更快可以降推理档 (第 6 章)
- **Q:** 任务失败怎么办? **A:** 看输出里的工具调用轨迹定位; 多数是"验收标准不清晰", 重写提示词重跑
- **Q:** 能自动化运行吗? **A:** 能——headless + 非零退出码 + 管道输出, 可进 cron/CI
- **Q:** 安全吗? **A:** 工具执行有沙箱与审批层; 敏感操作建议人工确认 (第 8 章安全模型)
- **Q:** 和直接用 Claude Code 有什么区别? **A:** 同模型下能力接近, 但 dsh 可自定义工具链/界面/插件 (第 1 章矩阵)

下一章: [第 6 章: 进阶与性能调优](./06-advanced.md)

5.9 行业视角: dsh 在不同领域的打开方式

同一套工具链, 不同行业的用法。以下为通用场景 (不含真实业务数据), 合规敏感领域 (医疗/法律) 请务必人工审核。

金融与投研

- **任务:** 财报摘要、研报要点提取、因子说明文档、投资备忘
- **示例:** ``dsh --profile headless "读取这份财务数据, 生成合同比/环比变化的摘要报告"``
- **dsh 优势:** 数据处理管线顺手 + 高缓存命中 (长报告会话便宜)

教育与学习

- **任务:** 教案生成、题目解析、错题归纳、学习计划
- **示例:** ``dsh --profile headless "把这章知识点整理成 10 道自测题 (含解析) "``
- **dsh 优势:** 文档生成 + 结构化为强项, 可批量出题/归纳

销售与客服

- **任务:** FAQ 整理、话术生成、客户反馈归类
- **示例:** ``dsh --profile headless "把 100 条客户反馈按问题类型归类并给出改进建议"``
- **dsh 优势:** 批量文本处理 + 分类归纳

运营与内容

- **任务**：周报月报、数据看板说明、内容选题、SEO 摘要
- **示例**：`dsh --profile headless "读取本周数据文件，生成运营周报（含图表代码）"`
- **dsh 优势**：数据 + 文档 + 自动化的组合

研究与综述（学术/技术）

- **任务**：论文要点提取、技术调研、文献对比
- **示例**：`dsh --profile headless "对比这 3 篇论文的方法与结论，输出对比表"`
- **dsh 优势**：长文档处理 + 结构化输出（1M 上下文）

合规提醒

医疗诊断、法律意见、财务建议等高风险场景：dsh 输出需人工审核，不能直接用于决策——工具执行有沙箱，但内容责任在使用者。

第 6 章：进阶与性能调优

本章目标：从“能跑”到“跑得好”——推理档位策略、工具调用耗时分析、真实踩坑清单。

TL;DR (本章核心, 30 秒版)

- 1. **时间花在哪**：模型思考占 ~90%，工具执行 <1%，网络/渲染 ~10%——优化思考时间是性价比最高的提速
- 2. **三档策略**：`low` (简单/批量轮次)、`high` (日常默认)、`max` (复杂推理/debug) ——手动 UI 选或插件自动调
- 3. **耗时可视化**：Web UI 底部统计行 (LLM Xs / 工具调用 Ys) 是最快的瓶颈定位手段
- 4. **8 个真实坑**：rc.1 依赖断裂、插件缺 main、next() 忘 await、事件类型不识别、client 测试跑不了、缓存命中误判、端口占用、推理序列化丢 reasoning (#739)
- 5. **评测三问**：谁测的、什么 harness、验证器多严——跑分要带条件看

<details><summary>本章导航</summary>

- [6.1 性能模型：dsh 的时间花在哪](#61-性能模型 dsh-的时间花在哪)
- [6.2 reasoning_effort 策略 (官方三档)](#62-reasoning_effort-策略官方三档)
- [6.3 工具调用耗时可视化](#63-工具调用耗时可视化)
- [6.4 常见坑清单 (真实踩过, 含解法)](#64-常见坑清单真实踩过含解法)
- [6.5 评测视角：官方成绩单 vs 独立实测](#65-评测视角官方成绩单-vs-独立实测)
- [6.6 缓存策略：让每次调用都更便宜](#66-缓存策略让每次调用都更便宜)

</details>

6.1 性能模型：dsh 的时间花在哪

实测一个“创建文件”任务的耗时分布：

阶段	占比	说明	
模型思考 (Think)	~90%	每次工具调用前都会重新思考，是绝对大头	
工具执行	<1%	文件写入等毫秒级	
网络/渲染	~10%	API 往返 + UI 更新	

推论：

- 简单任务 → 优化思考时间 (降推理档)
- 长工具链任务 → 每步都省思考时间，累计收益最大
- 工具本身慢 (搜索/大文件) → 优化工具实现，不是调档

6.2 reasoning_effort 策略（官方三档）

<!-- [fix] 技术准确性核验: "官方三档"在默认 DeepSeek 适配器 (deepseek-official) 下为 off / high / max; low 是 pi-ai (opencode-go) 网关档位 (本白皮书实测环境, 即 benchmark 所走网关) 。工具链降档叙事在网关环境下成立, settings.yaml 对默认 provider 请用 off -->

档位	场景建议	
low	简单/确定性轮次: 文件操作、批量、工具链中的廉价步	
high	日常 Agent 任务 (默认)	
max	复杂推理、长链规划、debug	

手动: UI 的"推理等级"选择器, 或 ~/.dsh/settings.yaml 的 reasoningEffort。

自动: 插件按工具轮次动态降档 (示例提速插件, 第 4 章) 。

6.3 工具调用耗时可视化

dsh 的会话统计行 (Web UI 底部) 显示: N 轮 · M 步 | LLM Xs · 工具调用 Ys | 首 token 平均 ...——这是最快的瓶颈定位手段。

进阶: host 插件监听工具事件做 per-tool 计时 (提速插件示例已内置 host 日志版本) , 把"哪个工具最慢"暴露出来。

6.4 常见坑清单（真实踩过，含解法）

#	坑	现象	解法	
1	rc.1 依赖断裂	pnpm install 404 (dsh-type-meta 等从未发布)	依赖用 ^0.1.0-rc.6 线	
2	插件缺 main	No "exports" main defined	暴露 . 入口; "main": "src/index.ts" 可被 tsx 加载	
3	next 忘 await	provider/model 丢失报错	agent/request 的 next 返回 Promise, 必须 await	
4	事件类型不识别	'agent/request' is not assignable to keyof Events	npm 未 re-export 类型增强, 边界放宽签名	

5	client 测试跑不了	jsdom 报 window.ModuleLoader undefined	client 产物依赖 dsh 引导机制，组件测试在官方 CI 跑	
6	简单任务"突然变快"的误判	1s vs 110s 差异被误归因	DeepSeek context cache 命中也会提速——A/B 测试要用全新 prompt	
7	端口占用	dsh web 起不来	netstat -ano \	findstr 3080 找 PID kill
8	推理序列化省略空 reasoning (#739 https://github.com/deepseek-ai/deepseek-harness/discussions/739)	验证点：off (thinking:disable) 档正常（仅 high/max 触发）；high/max 下工具调用轮次没有思考内容时，serializeAssistant 里 toolCalls.length > 0 && reasoning.length > 0 条件把空的 reasoning 字段省略 → 下一轮请求报 400 (invalid pi-ai replay state)	判断为 bug（应保留 reasoning 占位）：修复方向是序列化时始终保留该字段	

6.5 评测视角：官方成绩单 vs 独立实测

(结合 0813 正式版发布) 看 Agent 模型成绩单要三问：

- 1. **谁测的**？官方自测（自家 Harness）vs 独立第三方（AA 等）
- 2. **什么 harness**？框架不同分数差很大（官方 Terminal-Bench 87.9 vs AA 独立 79）
- 3. **验证器多严**？宽松验证器（SWE-bench Verified 8.5% 假阳性）vs 严格（DeepSWE 0.3%）

dsh 的 agent/request waterfall 让模型跑分可复现——这是它相比闭源产品的工程优势。

6.6 缓存策略：让每次调用都更便宜

第 5 章讲了高缓存命中率的价值（实测会话缓存命中率 97%；缓存折扣 Flash 档 98% / Pro 档 99%+），这里给出可操作策略：

目标	做法	
----	----	--

提高命中	长任务保持会话延续（避免频繁新建会话）	
提高命中	系统提示/技能目录等前缀保持稳定（不要频繁改配置）	
提高命中	批量任务放同一会话/同前缀（如同一批文件分析）	
降低成本	简单轮次用 low 档（思考 token 减少 → 总 token 下降）	
监控	会话统计行看"缓存命中 %"（Web UI 底部）——低于预期就检查前缀稳定性	

成本模型速记：总成本 ≈ 输出 token×输出价 + 输入未命中×未命中价 + 输入命中×命中价
——Agent 工作负载输入占比高，缓存命中率是成本的第一变量。

动手练习（检验你是否真懂了）

1. ****理解题****：不看原文，说出 dsh 任务耗时的三个组成部分及各自占比。为什么"优化思考时间"是性价比最高的提速手段？
> 自查：参考本章 6.1 节耗时分布表格
2. ****理解题****：解释 `low` / `high` / `max` 三个推理档位分别适合什么场景。如果一个任务"需要读 10 个文件然后做简单汇总"，应该用哪个档位？
> 自查：参考本章 6.2 节三档策略表格
3. ****动手题****：打开 `dsh web`，跑一个"创建 3 个文件"的任务，观察 Web UI 底部的统计行（LLM Xs / 工具调用 Ys），记录数据并分析瓶颈在哪
> 自查：参考本章 6.3 节"耗时可视化"段落
4. ****动手题****：把 `~/dsh/settings.yaml` 的 `reasoningEffort` 从 `high` 改为 `low`，跑同一个简单任务，对比耗时差异。再改回 `high`，跑一个复杂推理任务，对比差异
> 自查：参考本章 6.2 节"手动"段落
5. ****动手题****：模拟"端口占用"坑（先起一个服务占 3080 端口），用 `netstat -ano | findstr 3080` 找到 PID 并 kill，然后正常启动 `dsh web`
> 自查：参考本章 6.4 节坑 #7
6. ****思考题****：本章 6.5 节说"评测要三问：谁测的、什么 harness、验证器多严"。请用一个具体例子解释：同一个模型，在不同 harness 下跑分为什么会差很多？
> 自查：参考本章 6.5 节"官方 Terminal-Bench 87.9 vs AA 独立 79"的例子

常见疑问 FAQ

Q1: 为什么我的 dsh "有时候特别快, 有时候特别慢"?

两个主要原因: ① DeepSeek context cache 命中时, 首轮上下文注入会快很多 (1s vs 110s 的差异可能来自这里); ② 推理档位不同, 思考时间差几倍。做 A/B 对比测试时, 要用全新 prompt (避免缓存命中) + 固定档位。

Q2: 示例提速插件真的能提速多少? 有没有实测数据?

提速收益取决于任务类型。简单任务 (1-3 步) dsh 本来就快, 插件效果不明显。长工具链任务 (20-50 步) 收益最大, 因为每步思考降档的累计效果显著。具体数据参考第 4 章示例代码的实测日志。

Q3: 我把推理档位设为 low, 模型质量会下降很多吗?

取决于任务。简单文件操作、批量处理、确定性任务用 low 质量几乎无差别。复杂推理、长链规划、debug 用 low 可能漏掉关键步骤。建议: 日常用 high, 批量/简单任务手动切 low 或用提速插件自动降档。

Q4: 坑 #6 说的"context cache 命中"是什么? 怎么判断是否命中?

DeepSeek API 会对重复/相似的上下文做缓存, 命中时首 token 时间大幅缩短。判断方法: 看 dsh 会话日志里的"首 token 平均"指标, 如果某次突然从 10s+ 降到 1s 以下, 大概率命中了缓存。做性能对比测试时, 用全新 prompt 避免缓存干扰。

Q5: rc 阶段的破坏性变更会影响性能吗? 升级后需要注意什么?

可能影响。rc 阶段的 agent-loop、waterfall 签名、插件 API 都可能变。升级后: ① 跑一遍 `dsh --version` 确认版本; ② 看官方 changelog 有没有 breaking changes; ③ 跑一个你熟悉的任务对比耗时和行为; ④ 自定义插件检查类型兼容性。

Q6: 我想做性能基准测试 (benchmark), 有什么建议?

三个原则: ① 固定环境 (同模型、同网络、同档位); ② 用全新 prompt 避免缓存; ③ 多次运行取中位数 (单次波动大)。记录: 墙钟时间、LLM 耗时、工具调用耗时、首 token 时间。参考本章 6.1 节的耗时分布模型设计你的 benchmark。

下一章: [第 7 章: 生态与资源](./07-ecosystem.md) —— 加入 dsh 生态的完整地图。

第 7 章：生态与资源

本章目标：给你一份“加入 dsh 生态”的地图——官方入口、社区现状、插件实操、以及参与方式。

TL;DR（本章核心，30 秒版）

- 1. **官方入口**：GitHub 仓库（源码 + issue）、官方文档站（VitePress）、API 文档、Discord、Discussions——当前贡献入口以 Discussions 为主
- 2. **外部 PR 暂不接受**（2026-08-13 时点），但官方鼓励做 dsh-plugin 生态项目、写教程/博客——社区已自发形成“报告-复现-根因-修复分支”的贡献模板（见 7.2 节）
- 3. **插件生态快照**：`DSH-better-sidebar`（最完整社区插件）、示例提速插件（第 4 章完整拆解）、本白皮书——发现插件搜 `topic:dsh-plugin`
- 4. **新手参与路径**：用起来 → 小改进（给社区插件提 PR）→ 发插件 → 写内容
- 5. **生态零日 = 先发优势**：每个早期生态都有“第一个吃螃蟹的人”的红利，现在入场正是时候

<details> <summary>本章导航</summary>

- [7.1 官方入口](#71-官方入口)
- [7.2 社区贡献模式](#72-社区贡献模式)
- [7.3 插件生态（2026-08-13 快照）](#73-插件生态 2026-08-13-快照)
- [7.4 如何参与生态（新手路径）](#74-如何参与生态新手路径)
- [7.5 推荐阅读路径](#75-推荐阅读路径)
- [7.6 真实插件安装实操](#76-真实插件安装实操)
- [7.7 发现插件的方法](#77-发现插件的方法)
- [7.8 参与生态的完整流程](#78-参与生态的完整流程)
- [7.9 生态里程碑时间线](#79-生态里程碑时间线)
- [7.10 与官方讨论区的联动](#710-与官方讨论区的联动)

</details>

7.1 官方入口

资源	地址	用途	
官方仓库	https://github.com/deepseek-ai/deepseek-harness	源码、架构文档、issue	
官方文档站	https://deepseek-harness.github.io/deepseek-harness/	官方 VitePress 文档站 (guide/providers/development/reference, 2026-08 上线)	

产品站点	https://deepseek.com/harness/	官方产品介绍（四种运行模式、轨迹视图等）	
API 文档	https://api-docs.deepseek.com	模型、定价、API 指南	
Discord	官方 README 内链接	社区讨论	
Discussions	官方仓库 Discussions	提案/求助（官方当前建议的贡献入口）	

注意：官方 CONTRIBUTING 明确"目前不接受外部 PR"（2026-08-13 时点）——但鼓励：

- 在 Discussions 提建议（官方会评估）
- ****做 dsh-plugin 生态项目****（官方点名认可的方式）
- 写教程/博客

 ****官方自建文档的补充****：除了上述入口，官方仓库还维护了系统化的内部文档——``packages/README.md``（包清单权威表）、``docs/subsystems/``（子系统设计）、``docs/cookbook/``（9 个开发指南）、``docs/tool-catalog.md`` / ``docs/config-catalog.md`` / ``docs/module-graph.md``（自动生成清单）。白皮书是"新手视角的补充"，官方文档是"架构权威"，两者搭配读。

7.2 社区贡献模式

官方暂不接受外部 PR，但社区已自发形成一套成熟的"报告-复现-根因-修复分支"贡献模板——[#341](https://github.com/deepseek-ai/deepseek-harness/discussions/341)、[#371](https://github.com/deepseek-ai/deepseek-harness/discussions/371)、[#775](https://github.com/deepseek-ai/deepseek-harness/discussions/775) 反复呼吁官方开放 Issues/PR，官方尚未回应，于是贡献者们把修复直接做进帖子里。

社区贡献模板四步：

1. ****报告****：以 Discussion 发帖，标题带【Bug】，附 OS / Node / dsh 版本
2. ****复现****：最小复现步骤 + 报错日志前 20 行
3. ****根因****：定位到具体文件与函数（如 readUtf16 只判低字节 0x00）
4. ****修复分支****：fork 后提交修复，帖内贴 ``git cherry-pick <commit>`` 命令

自带 cherry-pick 修复的示例帖：

帖号	问题	修复形态	
#244 https://github.com/deepseek-ai/deepseek-harness/discussions/244	Windows 目录选择器截断含"需求"等汉字的路径	附修复补丁	
#295 https://github.com/deepseek-ai/deepseek-harness/discussions/295	创建工作区时中文目录路径被截断	复现 + 修复代码片段	

discussions/295			
#580 https://github.com/deepseek-ai/deepseek-harness/discussions/580	Win32 原生目录选择器在 U+XX00 处截断 UTF-16 路径	附可 cherry-pick 修复	

这些帖的共同特征: ****不是"求官方修", 而是"我修了, 你们用"**. 在官方 Issues 关闭的阶段, 这是 dsh 社区最高效的协作方式——既是在帮官方分流, 也是在建立自己的社区信用。**

7.3 插件生态 (2026-08-13 快照)

项目	定位	状态	
DSH-better-sidebar	文件管理/终端/Git/浏览器侧边栏	社区最完整插件	
示例提速插件	工具调用提速 (reasoningeffort 自动调节)	教学示例 (第 4 章)	
dsh-handbook (本白皮书)	新手教程	生态文档	
DeepSeek Desktop	Windows 桌面端 (x64 社区安装包, v0.2.0 离线安装器)	#872 https://github.com/deepseek-ai/deepseek-harness/discussions/872 , 同族 #529 https://github.com/deepseek-ai/deepseek-harness/discussions/529 #446 https://github.com/deepseek-ai/deepseek-harness/discussions/446	
turtle-ui	终端 TUI 界面插件 (turtle1999/turtle-ui https://github.com/turtle1999/turtle-ui)	社区 TUI 方案, 安装尝试见 #871 https://github.com/deepseek-ai/deepseek-harness/discussions/871	

memory 插件族	跨会话长期记忆（设计提案 / 长期记忆 / MEMORY.md·USER.md 移植）	#192 https://github.com/deepseek-ai/deepseek-harness/discussions/192 #484 https://github.com/deepseek-ai/deepseek-harness/discussions/484 #525 https://github.com/deepseek-ai/deepseek-harness/discussions/525	
dsh-sgme	记忆引擎：对话历史与长期记忆分层，提炼前自动剪枝（省 65-96% 会话内容），按场景注入记忆块	freehul/sgme https://github.com/freehul/sgme （npm 包 dsh-sgme）， #1052 https://github.com/deepseek-ai/deepseek-harness/discussions/1052	
pi-quiet-tools	工具输出压缩：进上下文前把大结果压缩为头尾预览 + 本地 artifact（>12,000 字符或 240 行触发）	经 pi2dsh https://github.com/weijiafu14/pi2dsh 挂载，#1052 https://github.com/deepseek-ai/deepseek-harness/discussions/1052	
dsh-installers	免装 Node 安装包：mac DMG / Windows exe，自带 Node 运行时、零前置依赖	codeAnqiang-ma/dsh-installers https://github.com/codeAnqiang-ma/dsh-installers （#380 https://github.com/deepseek-ai/deepseek-harness/discussions/380 作者 codeAnqiang-ma 提供），安装见第 2 章 2.2 方式三	

发现插件：GitHub 搜 topic:dsh-plugin。
发布插件：给你的仓库加 dsh-plugin topic + npm 发布。

7.4 如何参与生态（新手路径）

- 1. **用起来**：`dsh web` + 装两个社区插件，跑通日常
- 2. **小改进**：给社区插件提 PR（读第 5 章的三个案例，那是完整的 PR 范式）
- 3. **发插件**：从第 4 章的最小 host 插件起步，挂 `dsh-plugin` topic
- 4. **写内容**：教程/测评/避坑文（官方鼓励），与本白皮书互相引用

7.5 推荐阅读路径

目标	路径	
快速上手	第 2 章 → 装 better-sidebar → 日常用	
开发插件	第 3 章 → 第 4 章 → 抄第 5 章案例	
性能调优	第 6 章 → 第 4 章示例源码	
深度定制	官方 AGENTS.md（架构） → docs/architecture.md → packages/ 源码	

7.6 真实插件安装实操

以下给出两个代表性插件的完整挂载步骤（语法与第 3 章 3.2 节一致）。

安装 `DSH-better-sidebar`

- ① package.json 加依赖（`~/dsh/profiles/web/package.json`）：

```
{  "dependencies": {    "dsh-better-sidebar": "link:C:\\path\\to\\DSH-better-sidebar"  } }
```
- ② cordis.patch.yml 加挂载行：

```
- insert:    - id: better-sidebar      name: dsh-better-sidebar
```
- ③ 安装并验证：

```
cd ~/dsh/profiles/web && pnpm install && dsh web
```

重启后观察左侧是否出现文件管理/终端/Git/浏览器四个标签页。

安装示例提速插件

- ① package.json 加依赖：

```
{  "dependencies": {    "dsh-speed-plugin": "link:C:\\path\\to\\dsh-speed-plugin"  } }
```
- ② cordis.patch.yml 加挂载行：

```
- insert:    - id: speed-plugin      name: dsh-speed-plugin
```


③ 安装并验证：

```
cd ~/.dsh/profiles/web && pnpm install && dsh web
```

④ 验证效果：发一个"创建 3 个文件"的任务，观察日志是否出现 [speed-plugin] calls=[...] => reasoningEffort=low（参考第 4 章 4.5 节）。

⚠ 两个插件均要求 `@deepseek-ai/dsh-agent ^0.1.0-rc.6`，若 `pnpm install` 报 404，请检查版本线（见第 3 章 3.5 节）。

7.7 发现插件的方法

渠道	具体操作	预期结果	
GitHub topic	https://github.com/topics/dsh-plugin 或搜索 topic:dsh-plugin	所有打了 topic 的仓库	
GitHub 全局搜索	dsh-plugin + 语言过滤 TypeScript	含关键词的仓库与代码	
npm 搜索	npm search dsh-plugin 或 https://www.npmjs.com/search?q=dsh-plugin	已发布的包（rc 阶段以 GitHub 为主）	
官方讨论区 Show and tell	https://github.com/deepseek-ai/deepseek-harness/discussions/categories/show-and-tell	社区自荐项目	
本白皮书引用链	第 4/5/10 章案例中的仓库链接	经实机验证的插件	

技巧：topic:dsh-plugin 是最精准的过滤方式。2026-08-13 时点结果仅个位数——正是入场机会。

7.8 参与生态的完整流程

把 7.4 节的"四步走"展开为可操作的决策树：

```
用起来 → 提 Issue 反馈 → 发插件（npm publish） → 写内容
```

npm publish 流程简述：

- 1. 确保 `package.json` 有 `"name": "dsh-xxx"` + `"main": "src/index.ts"` + 正确 `peerDependencies`
- 2. `npm login` → `npm publish --access public`
- 3. 给 GitHub 仓库加 `dsh-plugin` topic
- 4. 到官方 Discussions 的 Show and tell 分类发帖

参考 CONTRIBUTING.md: 案例需含“场景 / 命令 / 耗时或产物 / 验证方式”——发插件时附上这些信息, 转化率更高。

7.9 生态里程碑时间线

时间	事件	意义	
2026-08-13	dsh 开源 (零日)	MIT 协议发布, Agent 可编程时代起点	
2026-08-13	60+ 官方包同步放出	packages/ 下工具/上下文/会话/子代理/MCP/工作流/安全/模型/界面全覆盖	
2026-08-13 当天	社区插件爆发	官方讨论区单日 30+ 帖, 含插件踩坑、TUI 示例、Windows 路径 bug 等	
2026-08-13 当周	本白皮书发布	14 章中文教程 + Benchmark + 插件模板, 补零日文档缺口	
进行中	官方讨论区持续活跃	每周 2-3 帖响应, 已覆盖插件/路径/TUI/vision 等方向 (见 7.10 节)	
规划中	插件模板扩展 / 视频教程 / CI 校验	ROADMAP.md P1 优先级	

关键认知: 2026-08-13 不是“发布日”而是“生态零日”——官方包、社区插件、中文教程同一天就位。对参与者而言, 现在入场 = 和官方基建同步成长。

7.10 与官方讨论区的联动

本白皮书已在官方 Discussions 响应 8 帖, 以下是有效参与的实例:

帖子	主题	响应方式	可复用模式	
#380 https://github.com/deepseek-ai/deepseek-harness/discussions/380	插件踩坑	结论整理进第 3 章 3.5 节“常见坑”	问题 → 复现 → 写教程 → 回帖引用	
#392 https://github.com/deepseek-ai/	TUI examples	补进 docs/config-reference.md	官方缺示例 → 跑通 → 写参考 → 分享链接	

deepseek-harness/discussions/392				
#401 https://github.com/deepseek-ai/deepseek-harness/discussions/401	Windows 路径 bug	记录进第 12 章跨平台短板	平台 bug → 记录边界 → 帮官方分流	
#384 https://github.com/deepseek-ai/deepseek-harness/discussions/384	visionDS	更新能力矩阵中 vision 支持状态	新能力 → 调研 → 更新表格 → 确认	
#118 https://github.com/deepseek-ai/deepseek-harness/discussions/118	通用讨论	沉淀进 FAQ (docs/faq.md 六类问答)	高频问答 → 分类沉淀 → 给链接	
#655 https://github.com/deepseek-ai/deepseek-harness/discussions/655	社区五项目	梳理生态全景进第 7 章 7.3 节	整合碎片项目 → 形成生态地图	
#735 https://github.com/deepseek-ai/deepseek-harness/discussions/735	token 成本	沉淀进第 6 章 6.6 节成本模型	成本测算 → 公式化沉淀	
#781 https://github.com/deepseek-ai/deepseek-harness/discussions/781	LSP 提议	记录进第 11 章未来展望	前瞻特性 → 跟踪架构演进	

有效参与的 3 个原则：① 先自己跑通再回帖（带环境信息和报错日志）；② 把结论写成可引用内容（单条回复会沉底，写成章节/FAQ 才能持续产生价值）；③ 链接代替重复（回帖给链接，如“详见第 7 章 7.6 节”）。

结语

dsh 是 2026-08-13 才开源的项目——生态的每一天都是"早期"。白皮书会随 dsh 演进持续更新。如果某章命令失效，大概率是 rc 版本迭代所致——以官方 changelog 为准。

祝你在这个全新的生态里，抢到自己的位置。🚀

动手练习（检验你是否真懂了）

1. ****理解题****：不看原文，说出 dsh 生态的 3 个官方入口（仓库/API 文档/社区）各自的用途
 - > 自查：参考本章 7.1 节官方入口表格
2. ****理解题****：官方当前"不接受外部 PR"，但鼓励哪三种参与方式？为什么"做 dsh-plugin 生态项目"是官方点名认可的方式？
 - > 自查：参考本章 7.1 节"但鼓励"段落
3. ****动手题****：在 GitHub 搜索 `topic:dsh-plugin`，列出你找到的 3 个社区插件，说出每个插件的定位
 - > 自查：参考本章 7.3 节"发现插件"段落 + 7.7 节搜索渠道表格
4. ****动手题****：按本章 7.6 节的步骤，完整挂载 `DSH-better-sidebar` 或按第 4 章示例自己写一个提速插件，记录 `pnpm install` 的输出和验证结果
 - > 自查：参考本章 7.6 节两处改动的完整代码片段
5. ****动手题****：给 `DSH-better-sidebar` 或自己写的提速插件的 README 提一个改进 PR（比如加一个安装步骤、修一个 typo），体验社区 PR 流程
 - > 自查：参考本章 7.4 节第 2 步 + 第 5 章案例的 PR 范式
6. ****思考题****：本章 7.9 节时间线显示"60+ 官方包同步放出"和"社区插件爆发"发生在同一天。这对开源项目的生态策略有什么启示？
 - > 自查：参考本章 7.9 节时间线表格 + 7.10 节联动模式

常见疑问 FAQ

Q1：官方说"不接受外部 PR"，那我的插件代码放哪？

放在你自己的 GitHub 仓库，作为独立的 dsh-plugin 生态项目。官方鼓励这种方式——通过插件扩展能力，无需改 dsh 核心。给仓库加 dsh-plugin topic，npm 发布即可。

Q2：Discord 和 Discussions 有什么区别？

Discord 适合实时讨论；Discussions 适合正式提案、功能建议、求助（有记录可查）。官方当前建议的贡献入口是 Discussions。

Q3：我想写中文教程/博客，有格式要求吗？

没有官方格式要求。建议包含安装步骤、代码示例、实机截图/日志。可参考本白皮书结构（TL;DR + 分步讲解 + 练习）。

Q4：生态零日是什么意思？为什么说是"先发优势"？

生态零日 = 生态刚起步，内容/插件/教程几乎为零。先发优势 = 早期入场者容易成为"某个方向的标杆"。类比：2015 年写 React 教程的人、2018 年做 VS Code 插件的人。

Q5：rc 阶段迭代快，我的插件会不会刚写完就过时？

有可能。降低风险：① 依赖用 ^0.1.0-rc.6 线；② 关注官方 changelog；③ 逻辑用纯函数隔离，接入层薄一点，升级时只改接入层。

Q6：我想做 dsh 生态项目，但从哪开始？

从"自己的痛点"开始。比如：① 想要 TUI → 做 tui profile 插件；② 想要 token 追踪 → 做 cost-tracker 插件；③ 想要 diff 视图 → 做 diff 插件。参考本章 7.5 节阅读路径。

Q7：7.6 节的 link: 路径在 Windows 和 macOS 下写法一样吗？

不一样。Windows 用双反斜杠转义 (link:C:\\path\\to\\plugin) ， macOS/Linux 用正斜杠 (link:/path/to/plugin) 。建议社区插件最终走 npm 发布，消除路径差异。

Q8：官方讨论区发帖有什么技巧，能让官方更快响应？

参考 7.10 节 3 个原则：带环境信息、带复现步骤、先搜索避免重复。功能建议说明"解决什么问题"比"怎么实现"更重要。

第 8 章：工具与上下文系统

本章目标：理解 dsh 的“能力引擎”——模型能调用哪些工具、上下文是怎么喂给模型的、以及长对话怎么处理。 **这是从“能跑”到“跑得明白”的关键一章。 **

TL;DR (本章核心, 30 秒版)

1. **60+ 官方能力包**：工具 (fs/shell/web/skill/todo)、上下文 (context/compaction)、会话、子代理、MCP、工作流、安全、模型、界面——一切皆插件
2. **内置工具名是简短动词**：`read`/`write`/`grep`/`glob`/`edit`/`bash`/`todo`/`skill`——写提示词直接说“读文件”“搜索”即可
3. **工具返回 locations → 产物追踪**：模型改了什么文件，UI 能直接看到并可打开 (对话末尾的产物 chips)
4. **上下文 = 系统提示 + 技能目录 + 对话历史 + 工具结果**：分层注入，每步请求携带工具 schema
5. **长对话自动压缩 (compaction)**：检测溢出 → 修剪历史 → 可选摘要 → 失败路由到溢出代理。重要信息建议写进提示词
6. **插件行为可零成本验证**：mock llm + headless + 审计 dump (#462) ——没有 API key 也能验证 waterfall 透传与工具注入
7. **工具链有三个已知坑**：code 模式 run_code/bash 的 description required 死循环 (#558/#581/#689)；流式下工具名被抹空 (#725 同族，见 FAQ)；run_code 内交互式工具异步结果被丢弃 (#1476)

<details> <summary>本章导航</summary>

- [8.1 官方能力包地图 (60+ 包一览)](#81-官方能力包地图 60-包一览)
- [8.2 内置工具 (实测观察)](#82-内置工具实测观察)
- [8.3 上下文是怎么喂给模型的](#83-上下文是怎么喂给模型的)
- [8.3.1 PTC 模式 (Code mode)：一段代码编排多轮工具调用](#831-ptc-模式 code-mode 一段代码编排多轮工具调用)
- [8.4 长对话：compaction (压缩)](#84-长对话 compaction 压缩)
- [8.5 权限与安全模型 (了解即可)](#85-权限与安全模型了解即可)
- [8.6 新手最该记住的三件事](#86-新手最该记住的三件事)
- [8.7 插件运行时验证方法论 (零成本)](#87-插件运行时验证方法论零成本)
- [8.8 工具链踩坑](#88-工具链踩坑)

</details>

8.1 官方能力包地图 (60+ 包一览)

dsh 的能力全部以包形式提供 (packages/<group>/<name>)。新手最需要认识的：

能力域	官方包	作用	
工具 (tools)	fs/tool-fs、fs/tool-fs-search、fs/tool-str-replace-editor、shell/tool-bash、web、skill、todo	文件/终端/网页/技能/待办等可调用工具	
上下文 (context)	context/、compaction/	请求上下文组装、长对话压缩	
会话 (session)	session/	持久化、标题、遥测	
子代理 (subagent)	subagent/	委派子任务	
MCP	mcp/	MCP 客户端 (外部工具服务器)	
工作流 (workflow)	workflow/	多步工作流编排	
安全 (safety)	sandbox/、guard/、interaction/、credentials/	沙箱、循环卫生、权限/审批、凭证隔离 (注: 官方无独立 safety/ 组, 安全策略分散在多个包组)	
模型 (llm)	llm/、llm-deepseek、llm-retry	模型接入、重试	
技能 (skill)	skill/	技能提供者注册表	
界面 (client)	client/ (ui-conversation、ui-tool...)	Web UI 各部件	

****完整清单与包数口径****: 官方仓库 ``packages/README.md`` 是包清单权威表 (47 组) ; ``@deepseek-ai/dsh` CLI 的 0.1.0-rc.6 声明` **\*\*53 个 `@deepseek-ai/dsh-*` 直接依赖\*\*** (+CLI 自身 = 54) , 家族发布总量约 **\*\*221 个\*\*** (含 `devDeps` 与历史 `0.0.1-rc.1` 列车, 官方构建 `commit` 提及) 。白皮书/官方所称"60+"指 ``packages/`` 下全部子目录。 **\*\*npm 包名写法\*\*** (``@deepseek-ai/dsh-*`) 与****仓库路径写法**** (``fs/tool-fs``) 的对应关系, 以及每个包的实测描述, 见 [附录 B: 官方包速查大全](./appendix-packages.md)。

 ****想深入架构****: 官方 ``docs/subsystems/`` (`session / system-prompt / tools / agent / agent-loop / scope / llm-streaming / subagent`) 是各子系统的设计文档, 比本节的"能力域分组"更系统化; 自动生成的权威清单见官方 ``docs/tool-catalog.md``、``docs/config-catalog.md``、``docs/module-graph.md``。

8.2 内置工具 (实测观察)

模型实际可调用的工具名是简短动词 (实测记录, 来自 `dsh web` 会话与 `agent/request` 日志) :

工具名	作用	备注	
read	读文件	fs 能力	
write	写文件	fs 能力	
grep	内容搜索	fs-search	
glob	文件模式匹配	fs-search	
edit / strreplaceeditor	精准编辑	工具结果含 locations (用于产物追踪)	
bash / pwsh	执行命令	沙箱隔离	
todo	待办管理	长任务规划	
skill	技能调用	skill-catalog 注入	

工具结果与产物追踪（重要概念）：工具的返回里带有 locations（文件路径），dsh 用它们做"产物文件行"（对话结尾的产物 chips 就是从这里来的）——模型改了什么文件，UI 能直接看到并可打开。

8.3 上下文是怎么喂给模型的

一次模型请求的上下文 = 系统提示 + 技能目录 + 对话历史 + 工具结果。实测在会话日志中可见：

```
<!-- [style] 示意图代码块统一补 text 语言标签 -->
上下文注入 @deepseek-ai/dsh-system-prompt   ← 官方系统提示
上下文注入 skill-catalog
← 技能目录
```

dsh 的上下文机制：

- **系统提示分层**：官方插件通过 `systemPrompt.section()` 注册提示片段（如 ui-deliverables 注册"产物文件引用"指导）
- **技能目录注入**：可用技能列表进入上下文，模型按需调用
- **工具 schema**：每步请求携带工具定义

8.3.1 PTC 模式（Code mode）：一段代码编排多轮工具调用

PTC = Programmatic Tool Calling（程序化工具调用）——官方中文站称「PTC 模式」，官方英文页面对应 Code mode ([#1052](https://github.com/deepseek-ai/deepseek-harness/discussions/1052) 评论区社区详解；官方站点原文："PTC 模式通过模型生成的一段代码组合多轮工具调用")。

与传统方式的区别：标准模式下模型每步发一次工具调用（一步一往返）；PTC 模式下模型生成一段 TypeScript 程序，在单次程序内编排多轮工具调用（循环、分支、Promise.all 并行），整段程序一次往返执行完毕：

维度	标准模式	PTC 模式 (Code mode)	
调用形态	每步一次工具调用	一段程序编排多轮调用	
模型往返	5 次调用 ≈ 5 次往返	合并为 1 次往返	
中间结果	逐步回灌上下文	仅 return/console.log 回灌	
典型场景	日常对话、单步任务	长链路自动化、确定性执行	

执行机制：程序交给 @deepseek-ai/dsh-code-runtime-worker-thread 在全新 Node worker 线程里执行（类型剥离后可擦除 TS；空环境 + 堆/耗时/输出预算 + 硬终止）；程序内每个子工具调用仍走完整工具流水线（权限、沙箱、审计照常生效）。

收益：多步调用一次往返 + 中间结果不再全部塞回上下文 → token 开销大幅下降（#1052 评论区实测经验：PTC 模式是长任务降本手段之一）。

注意：PTC 模式仍有社区反馈的已知坑——`run\_code`/`bash` 的 description required 死循环（见 8.8 坑 1）；且长会话中多轮工具调用的中间产物仍会留在上下文（#1052 原帖实测 70M→100M token 暴涨即发生在 PTC 模式下，见 8.4 节自动压缩需求）。

8.4 长对话：compaction（压缩）

长对话会撑爆上下文。dsh 的 compaction 插件（如 compaction-basic）负责：

- 检测上下文溢出（`agent/request-error` 的 `CONTEXT\_WINDOW\_EXCEEDED`）
 - 压缩历史（模型无关的修剪 + 可选摘要）
 - 失败时路由到“溢出代理”（overflow agent）
- **自动压缩是社区高频需求**（[#1052](https://github.com/deepseek-ai/deepseek-harness/discussions/1052)）：用户反馈长会话 token 暴涨后“要开新会话”很痛苦，希望**自动压缩而非手动新会话**——社区回复确认“现在内置应该没有自动压缩”（需装 compaction 插件/手动 compact）。想低成本延续长会话的临时做法：换新会话 + 按需注入记忆（记忆分层方案见第 7 章 7.3 节与第 14 章 14.7 节生态工具）。*
- 对新手：**知道“长对话会自动压缩”即可**，细节是进阶话题。生产环境注意：压缩会丢细节，重要上下文建议手动写进提示词。*

8.5 权限与安全模型（了解即可）

- ****访问模式****：UI 里可见「Workspace Write」等模式（权限预设）
- ****交互审批****：`interaction/\*` 提供权限/审批能力（危险操作可要求确认）
- ****沙箱****：`sandbox/\*` 隔离命令执行（如 pwsh 沙箱有 ACL 约束——实测中遇到过 temp 目录权限问题）
- ****工具超时****：`guard/\*` 提供 loop 卫生与工具超时

安全配置的深度话题超出本白皮书范围；核心认知：****dsh 的工具执行默认有隔离与审批层****，不是裸执行。

8.6 新手最该记住的三件事

1. ****工具名是简短动词**** (read/write/grep/glob/edit/bash) ——写提示词/插件时直接说"读文件""搜索"即可
2. ****工具返回 locations → 产物追踪****——模型改的文件会出现在对话产物区
3. ****长对话自动压缩****——不必手动清理历史（但重要信息要写进提示词）

8.7 插件运行时验证方法论（零成本）

出处：官方讨论区 [#462](https://github.com/deepseek-ai/deepseek-harness/discussions/462) [DSH 插件运行时验证方法论：无 API Key 验证 waterfall 行为]（实证 74 事件 / 12 waterfall）。FAQ 已有一句话版本，本节展开。

痛点：静态检查只能证明"插件能加载"，证明不了"插件在真实 agent 循环里不破坏行为"。尤其 waterfall 事件监听器 (tools/execute、approval/request、fs/write-intent 等) 必须正确透传 next()，否则会静默吞掉下游默认行为——这类错误只在运行时暴露；而传统验证要真实 LLM API key + token 成本。

零成本方案 (dsh 仓库自带，无需 API key)：

1. ****mock llm****：脚本化返回——让第一个请求返回"调用 bash 工具"、第二个正常回复 (``--sequence tool_call_success,success`)，以此注入工具调用
2. ****headless profile****：走真实 agent 循环，你的插件挂监听
3. ****审计 dump****：`DSH\_EVENT\_AUDIT\_DUMP` 导出事件审计快照

```
# 1. 启动 mock-llm (脚本化注入"调用 bash 工具") pnpm run mock:llm --port 8000 --api-key mock-key \
--sequence tool_call_success,success --repeat-last \ --tool-name bash --
tool-arguments '{"command":"ls"}' # 2. 跑 headless agent (指向 mock-llm, 导出审计)
DEEPSEEK_BASE_URL=http://127.0.0.1:8000/v1 \ DEEPSEEK_API_KEY=mock-key \
DSH_EVENT_AUDIT_DUMP=/tmp/audit.json \ pnpm dsh --profile headless "run the bash tool once
and report"
```

判定通过：审计快照 byMode 同时含 emit + waterfall、waterfall 链完整出现、agent 正常跑完 (mock response recovered)。实证：74 事件 / 12 waterfall 全部捕获，完整生命周期 session/created → ... → tools/pre-execute(wf) → tools/execute(wf) → tools/post-execute(wf) → tools/result；关键安全证明是所有 waterfall 监听器正确透传 next()、零副作用——插件既不吞默认行为，mock 注入的工具调用也完整走完链路。

从源码跑的三点提醒 (#462 作者实测踩坑)：sparse clone 一次加全 (缺 vendor/ 会报 Cannot find package '@deepseek-ai/cordis')；build:lib:host + build:lib:client + web-frontend dist 三层构建缺一不可；mock:llm 参数前不要多传 -- (会被当位置参数)。

8.8 工具链踩坑

rc.6 时代的工具链已知坑（坑 1/2 已入 [FAQ](./faq.md))：

坑 1：code 模式 runcode/bash 的 description required 死循环

([#558](https://github.com/deepseek-ai/deepseek-harness/discussions/558) [#581](https://github.com/deepseek-ai/deepseek-harness/discussions/581) [#689](https://github.com/deepseek-ai/deepseek-harness/discussions/689))

code 模式下 runcode 与 bash 都把 UI 摘要字段叫 description 且标成 required：模型常把内层 bash.description 当成已传过，外层 JSON 只剩 {"code": "..."} → 反复报 missing required property "description"，看起来像"随机丢参数"。#581 补根因：ToolArgsError 不带工具名，模型无法定位错在哪个工具 → 死循环重试（附可 cherry-pick 修复）；#689 显示同族问题让 runcode 内所有 tools. 调用都被拒绝。规避：手动补外层 description 或换标准模式。

坑 2：流式下工具调用被抹空名 ([#725](https://github.com/deepseek-ai/deepseek-harness/discussions/725) 同族，已入 [FAQ](./faq.md))

现象：所有工具调用报 Error: unknown tool ""。根因：SSE 流式解析用覆盖赋值而非累加，把工具名/ID 抹成空串

([#725](https://github.com/deepseek-ai/deepseek-harness/discussions/725) 根因 + 修复；[#161](https://github.com/deepseek-ai/deepseek-harness/discussions/161) [#615](https://github.com/deepseek-ai/deepseek-harness/discussions/615) [#694](https://github.com/deepseek-ai/deepseek-harness/discussions/694) [#741](https://github.com/deepseek-ai/deepseek-harness/discussions/741) 同族)。官方修复前只能降级/等版本；模型会反复重试，注意及时中止。

坑 3：runcode 内调用交互式工具

被"吞" ([#1476](https://github.com/deepseek-ai/deepseek-harness/discussions/1476))

runcode 程序内调用交互式工具（如 askuserquestion）时：同步执行不等异步——4ms 就返回空；异步结果约 12s 后回来时会话帧已结束，被直接丢弃。判断为 runcode 执行模型的问题（应支持异步工具回调或返回 pending 状态），AGENTS.md 里"别在代码里调交互式工具"的约定只能治标。

动手练习（检验你是否真懂了）

1. ****理解题****：不看原文，列出 dsh 内置的 8 个工具名（简短动词）及各自作用
> 自查：参考本章 8.2 节工具表格

2. ****理解题****: 解释"工具返回 locations → 产物追踪"是什么意思。模型改了什么文件, UI 怎么知道?
 - > 自查: 参考本章 8.2 节"工具结果与产物追踪"段落
3. ****动手题****: 在 `dsh web` 里发一个"创建一个 hello.py 文件"的任务, 观察对话末尾的"产物 chips", 点击打开文件, 验证产物追踪是否工作
 - > 自查: 参考本章 8.2 节"产物文件行"说明
4. ****动手题****: 在 `dsh web` 里进行一个长对话 (20+ 轮), 观察是否触发 compaction (看会话日志有没有"上下文溢出"或"压缩"相关日志)
 - > 自查: 参考本章 8.4 节"长对话自动压缩"段落
5. ****思考题****: 为什么"重要信息要写进提示词"而不是依赖对话历史? compaction 压缩时会丢什么?
 - > 自查: 参考本章 8.4 节"压缩会丢细节"警告
6. ****思考题****: 本章 8.5 节说"dsh 的工具执行默认有隔离与审批层"。如果你要做一个"允许模型自动执行所有 bash 命令"的插件, 应该用哪个扩展点? 有什么安全风险?
 - > 自查: 参考本章 8.5 节"交互审批" + interaction/ 包说明

常见疑问 FAQ

本章针对工具/上下文的高频问答见下; 更多通用问题见 [FAQ 速查](./faq.md)。

Q1: 工具名是 read/write 这些简短动词, 我写提示词时也要用这些名字吗?

不需要。你写"读一下这个文件"、"搜索包含 foo 的行", 模型会自动映射到对应工具。简短动词名是插件内部实现细节, 提示词用自然语言即可。

Q2: edit 和 strreplaceeditor 是同一个工具吗?

是。strreplaceeditor 是内部包名, 模型调用时可能显示为 edit。功能一样: 精准替换文件中的某段文本。工具结果里的 locations 用于产物追踪。

Q3: compaction 压缩后, 模型还能记得之前对话的内容吗?

记得"摘要", 但会丢细节。compaction 会修剪历史 + 可选生成摘要, 关键信息保留, 细节丢失。所以重要上下文 (如项目约束、特殊要求) 建议写进系统提示或提示词, 不要只依赖对话历史。

Q4: context/ 和 compaction/ 有什么区别?

context/ 负责"组装每次请求的上下文" (系统提示 + 技能目录 + 对话历史 + 工具 schema)。compaction/ 负责"长对话压缩" (检测溢出 → 修剪 → 摘要)。一个是"装什么", 一个是"装不下时怎么压缩"。

Q5: 安全模型里"沙箱"和"交互审批"有什么区别?

沙箱 (sandbox/) 隔离命令执行环境 (如 pwsh 沙箱有 ACL 约束, 限制文件访问)。交互审批 (interaction/) 是"危险操作前要求用户确认" (如删除文件、执行未知命令)。一个管"在哪执行", 一个管"能不能执行"。

Q6: 我想给 dsh 加一个新工具 (比如"查数据库"), 应该怎么做?

两种方式: ① 写一个 host 插件, 用 `ctx.provide` 注册工具服务 (参考第 3 章 3.4 节扩展点); ② 用 MCP 接入外部工具服务器 (第 9 章 9.1 节)。前者适合深度集成, 后者适合快速接入现有系统。

下一章: [第 9 章: MCP、子代理与工作流](./09-mcp-subagent-workflow.md)

第 9 章：MCP、子代理与 workflows

本章目标：了解 dsh 的三项扩展能力——MCP（接入外部工具）、子代理（并行任务）、工作流（多步编排）。**这些是把 dsh 从“单 Agent”升级为“Agent 系统”的开关。**

△ 本章基于官方架构文档（`packages/AGENTS.md`）与包结构整理；部分功能示例标注「待实测」——rc 版本迭代快，具体用法以官方 changelog 为准。

TL;DR（本章核心，30 秒版）

1. **MCP = 给 Agent 插外部工具**：通过 MCP 协议接入数据库、浏览器、公司内部系统等——先跑通内置工具，有明确缺口再加 MCP
2. **子代理 = 并行干活**：把任务委派给子 Agent 并行执行（大仓调研、长任务分解、独立验证）——先用好单 Agent 再上子代理
3. **工作流 = 确定性流程编排**：和“多轮对话”不同，工作流把步骤定义成流程按顺序/条件执行——适合数据拉取→清洗→报表→校验
4. **组合起来 = Agent 系统**：父 Agent 规划 → 子代理并行调研 → 工具链 + MCP → 工作流汇总 → 产物
5. **新手路径四阶段**：单 Agent + 内置工具 → + MCP → + 子代理 → + 工作流（逐步叠加，别跳级）

<details> <summary>本章导航</summary>

- [9.1 MCP：接入外部工具生态](#91-mcp 接入外部工具生态)
- [9.2 子代理（subagent）：并行干活](#92-子代理 subagent 并行干活)
- [9.3 工作流（workflow）：多步编排](#93-工作流 workflow 多步编排)
- [9.4 组合起来：一个“Agent 系统”长什么样](#94-组合起来一个 agent-系统长什么样)
- [9.5 社区生态示例（2026-08-13 快照）](#95-社区生态示例 2026-08-13-快照)
- [9.6 MCP 接入配置示例](#96-mcp-接入配置示例)
- [9.7 子代理配置示例](#97-子代理配置示例)
- [9.8 工作流 YAML 示例](#98-工作流-yaml-示例)
- [9.9 三者对比表](#99-三者对比表)
- [9.10 踩坑补充](#910-踩坑补充)
- [9.11 四阶段新手路径（含验收标准）](#911-四阶段新手路径含验收标准)

</details>

9.1 MCP：接入外部工具生态

MCP（Model Context Protocol）是“给 Agent 插外部工具”的开放协议。dsh 提供 mcp 客户端包（@deepseek-ai/dsh-mcp-client）。

能做什么：通过 MCP 接入任何 MCP 服务器（数据库、浏览器、图表、公司内部系统……）——比如社区已出现的 dsh-plugin-cost-tracker（追踪 token）就是 MCP/插件形态。

新手定位：MCP 是"生态扩展"，等你在 dsh 里有了明确的工具缺口再来接。先跑通内置工具，再加 MCP。

9.2 子代理 (subagent)：并行干活

是什么：把任务委派给子 Agent 并行执行 (packages/subagent/)。

典型场景：

- 大仓库多模块调研（各模块一个子代理）
- 长任务分解（父代理规划，子代理执行）
- 独立验证（子代理交叉检查）

对新手：子代理是"高阶武器"——先用好单 Agent，理解任务分解后再上子代理。错误示范是"什么任务都开子代理"，反而增加协调开销。

已知限制（社区反馈）：当前不能动态指定子代理模型——子代理模型跟随父 Agent 配置，社区已在讨论区反馈 ([#118](https://github.com/deepseek-ai/deepseek-harness/discussions/118)) 评论区，对比 Claude Code"可指定子代理模型"的体验)。需要不同模型能力时，目前只能整体切换父 Agent 的模型配置，或拆成独立会话分别指定。

9.3 工作流 (workflow)：多步编排

是什么：packages/workflow/ 提供多步工作流编排 (worker-thread provider + tool Consumer)。

和"多轮对话"的区别：普通对话是"模型自由发挥"，工作流是"把步骤定义成流程，按顺序/条件执行"——适合确定性流程（如：拉取数据 → 清洗 → 生成报表 → 校验）。

官方示例 (packages/examples/)：有可运行的 cordis.yml 工作流示例。

9.4 组合起来：一个"Agent 系统"长什么样

<!-- [style] 流程图代码块统一补 text 语言标签 -->

```
你的提示词（目标）    ↓ 父 Agent（规划）    |— 子代理 A：调研模块 A（并行）    |— 子代理 B：调研模块 B（并行）
                        |— 工具链：read/grep/bash + MCP（数据库）    ↓ 工作流（如：校验 → 汇总 → 输出报告）
                        ↓ 产物（可打开/追踪）
```

新手路径建议：

1. **阶段一**：单 Agent + 内置工具（第 2-5 章）
2. **阶段二**：+ MCP（接外部工具）
3. **阶段三**：+ 子代理（并行）
4. **阶段四**：+ 工作流（确定性流程）

9.5 社区生态示例（2026-08-13 快照）

官方 Discussion 里已出现的社区项目：

- `dsh-plugin-cost-tracker`——实时追踪 token 成本（插件/MCP 形态）
- 插件开发/提速类（如本白皮书第 4 章的示例提速插件）

生态正在快速生长——现在是进场搭积木的好时候。

9.6 MCP 接入配置示例

以下给出在 `cordis.patch.yml` 中挂载 MCP 客户端的配置片段（语法与第 3 章 3.2 节一致，以社区 token 追踪插件为例）：

```
- insert:      - id: mcp-client      name: '@deepseek-ai/dsh-mcp-client'      config:
servers:      - name: cost-tracker      command: npx      args: ['-y',
'dsh-plugin-cost-tracker']      env:      DSH_API_KEY: '${DSH_API_KEY}'
```

字段说明：id（cordis 链标识）、name（npm 包名）、config.servers（服务器列表，每服务器独立进程）、command/args（启动命令与参数）、env（环境变量，支持 `${VAR}` 引用宿主变量）。

⚠ 上述配置基于 ``packages/mcp/`` 目录结构与 `cordis` 挂载语法推断，具体字段以官方文档为准（rc 阶段可能变动）。验证思路（推断，待实测）：挂载后重启 ``dsh web``，发涉及 token 计数的任务，观察日志是否出现 MCP 调用记录。

9.7 子代理配置示例

并行子代理通过 `packages/subagent/` 提供。以下是在 `cordis.patch.yml` 中启用子代理能力的配置片段：

```
- insert:      - id: subagent      name: '@deepseek-ai/dsh-subagent'      config:
maxConcurrency: 3      timeout: 120000
```

适用场景与并发策略：

场景	子代理数	父代理职责	子代理职责	
大仓库多模块调研	3-5 个	划分模块边界、汇总结论	各模块独立调研	
长任务分解	2-3 个	拆分子任务、校验完整性	各子任务独立执行	
独立验证	1-2 个	提供结论与验证标准	交叉检查	
多文件并行编辑	2-4 个	锁定文件范围、避免冲突	各子代理写不同文件	

⚠ ``maxConcurrency`` 与 ``timeout`` 基于包名与 `cordis` 惯例推断（推断，待实测）。上下文隔离机制需查阅官方 ``packages/subagent/README.md``。

9.8 工作流 YAML 示例

以下是一个确定性工作流的 cordis.patch.yml 片段，模拟"数据拉取 → 清洗 → 报表 → 校验"四步（参考第 10 章案例 A 的任务结构）：

```
- insert:      - id: workflow      name: '@deepseek-ai/dsh-workflow'      config:
steps:        - id: fetch          tool: bash          command: 'curl -o raw.json
https://api.example.com/data'      - id: clean          tool: bash
command: 'python clean.py raw.json cleaned.json'      dependsOn: [fetch]
id: report    tool: bash          command: 'python visualize.py cleaned.json
chart.png'    dependsOn: [clean]      - id: validate        tool: bash
command: 'python verify.py cleaned.json'      dependsOn: [report]
```

与案例 A 的对应：工作流 dependsOn 显式定义顺序，而案例 A 的"多轮对话"由模型自由决定工具。工作流适合"步骤固定"；自由对话适合"探索性"。

⚠️ `steps`/`dependsOn` 基于 `packages/workflow/` 包名与常见 DSL 推断（推断，待实测）。官方 `packages/examples/` 有可运行示例，建议以其为准。

9.9 三者对比表

维度	MCP	子代理	工作流	
适用场景	接入外部系统（数据库/浏览器/内部 API）	大任务并行分解（调研/验证/多模块）	确定性流水线（拉取→清洗→报表→校验）	
复杂度	中（需配置服务器 + 理解协议）	高（需任务分解设计 + 结果汇总）	低-中（YAML 配置，调试依赖图较繁琐）	
失败处理	服务器崩溃 → 重连或报错（推断，待实测）	单个子代理失败 → 父代理决定重试/忽略/终止	单步失败 → 可选暂停/跳过/回滚（推断，待实测）	
性能开销	额外进程通信开销（stdio/sse）	并发节省墙钟时间，但增加协调开销	串行执行，无额外模型开销，但无并行收益	

决策建议：有明确工具缺口 → MCP；任务能拆成互不依赖的几块 → 子代理；步骤固定、需严格按序 → 工作流。三者可组合：子代理并行调研 → 内部用 MCP 查数据库 → 工作流汇总报告。

9.10 踩坑补充

#	坑	现象	解法	
1	MCP 连接失败	挂载后启动报错或 MCP 工具无响应	检查 command/args；先手动跑 npx -y xxx 验证（推断，待	

			实测)	
2	子代理上下文隔离	子代理看不到父 Agent 历史，导致重复提问	父代理委派时把关键上下文写进任务描述（推断，待实测）	
3	workflow 单步失败	某步 bash 返回非零，后续步骤继续执行	配置 onError: pause 或每步后加校验脚本（推断，待实测）	
4	子代理文件冲突	多个子代理同时写同一个文件	父代理规划时划分文件边界（推断，待实测）	
5	MCP 环境变量未注入	\${DSHAPIKEY} 解析为空	确认宿主 shell 已 export；或写死（仅本地测试）（推断，待实测）	

所有标注“推断，待实测”的内容均基于 `packages/` 目录结构与 cordis 配置惯例推断，非本白皮书实验验证结果。rc 阶段请以官方文档为准。

9.11 四阶段新手路径（含验收标准）

把 9.4 节的“四阶段”扩展为每阶段有明确验收标准的升级路径：

阶段	能力	验收标准（怎么知道自己该进入下一阶段）	参考章节	
阶段一	单 Agent + 内置工具	能独立完成：创建文件 → 搜索 → 编辑 → 运行验证，全程不卡壳	第 2-5 章	
阶段二	+ MCP	成功挂载一个 MCP 服务器，任务中调用其工具且日志证明调用发生	9.1 节 + 9.6 节	
阶段三	+ 子代理	成功发起一次并行子代理任务（如同时调研 2 个模块），父代理能汇总结果	9.2 节 + 9.7 节	
阶段四	+ workflow	成功配置并执行一个 3 步以上 workflow，每步按	9.3 节 + 9.8 节	

		dependsOn 顺序执行		
--	--	----------------	--	--

为什么不要跳级：阶段一没跑通 → 阶段二报错无法判断是配置错还是基础工具链不会用；阶段二没跑通 → 阶段三并行放大问题；阶段三没跑通 → 阶段四 YAML 写出来也是错的。阶段一到阶段二之间，先读第 8 章 8.1 节能力包地图——确认需求是否已内置，避免为"已有能力"配 MCP。

动手练习（检验你是否真懂了）

- 1. ****理解题****：说出 MCP、子代理、工作流各自解决什么问题。三者之间有什么联系？（自查：9.1-9.3 节首段 + 9.9 节对比表）
- 2. ****理解题****：解释"工作流"和"多轮对话"的区别。什么场景该用工作流？（自查：9.3 节 + 9.8 节）
- 3. ****动手题****：在 `dsh web` 里发"调研仓库目录结构并生成报告"，观察是否自动调用 `read`/`glob`/`grep`。想加"查数据库"能力，该用 MCP 还是 host 插件？（自查：9.1 节 + 9.9 节）
- 4. ****动手题****：设计"子代理并行调研"：调研 3 个模块（src/lib/src/cli/src/web），写出父 Agent 规划 + 3 个子代理任务描述（自查：9.2 节 + 9.7 节）
- 5. ****思考题****：任务"读 100 个文件后汇总"，单 Agent 串行、5 个子代理并行、工作流分 5 批串行，各有什么优劣？（自查：9.9 节对比表）
- 6. ****思考题****：想让 dsh "查公司内部员工信息"，走官方内置工具、MCP、host 插件三条路各需什么条件？哪条最快？（自查：第 8 章 8.1 节 + 本章 9.1 节 + 第 3 章 3.4 节）

常见疑问 FAQ

- Q1：MCP 是什么？和 dsh 插件有什么区别？
- MCP 是"给 Agent 插外部工具"的开放协议。插件在 dsh 运行时内注册能力（host 半跑在 Node 进程）；MCP 服务器是独立进程，通过协议通信。插件深度集成、性能好；MCP 解耦、可复用、适合接入现有系统。
- Q2：子代理是怎么"并行"的？会不会有冲突？
- 子代理由父 Agent 委派，各自独立执行（packages/subagent/）。并行时各子代理有自己的上下文，不会互相干扰。但多个子代理改同一个文件可能冲突——建议任务分解时避免交叉。
- Q3：工作流的"确定性流程"是什么意思？和模型自由发挥有什么区别？

工作流把步骤定义成流程（如 `cordis.yml`），按顺序/条件执行，每步做什么是指定的。多轮对话是“模型自由发挥”。确定性流程适合“必须按固定步骤走”的场景，自由发挥适合“探索性任务”。

Q4：我想接一个 MCP 服务器（比如数据库），具体怎么操作？

（以官方 changelog 为准）① 安装 `@deepseek-ai/dsh-mcp-client`；② 在 `cordis.patch.yml` 挂载（参考 9.6 节）；③ 配置服务器地址/命令；④ 重启 `dsh web`。详见官方 `packages/mcp/` 文档。

Q5：子代理和“开多个 `dsh` 进程”有什么区别？

子代理是 `dsh` 内部委派机制（`packages/subagent/`），共享父 Agent 上下文和会话。多进程是完全独立的会话。子代理适合“任务分解后并行执行 + 结果汇总”，多进程适合“完全独立的任务”。

Q6：本章说部分功能“待实测”，我怎么知道哪些功能已经可用？

查官方 `packages/AGENTS.md` 和 `packages/` 目录。有完整源码 + 示例的功能基本可用；只有包名没有文档的可能还在开发中。rc 阶段以官方 changelog 为准。

附录 A：[术语表与命令速查](./appendix-glossary.md)

第 10 章：复杂实战案例（dsh 真实跑出来的）

本章目标：用两个**真实在 dsh 里跑完的复杂任务**，展示 dsh 在多步工具链下的实际能力、产出质量与耗时。

****隐私声明****：两个案例全部使用**合成数据/自造代码**，不涉及任何真实业务数据或敏感信息。

TL;DR（本章核心，30 秒版）

1. ****案例 A（数据质量分析，186 秒）****：52 行脏数据 → 分析 → 清洗脚本 → 可视化 → 运行验证，52→35 行，所有问题归零
2. ****案例 B（5-bug 修复 + 49 测试，94 秒）****：故意埋 5 个 bug 的计算器模块 → 全修复 → 49 个测试全过，覆盖边界/精度/异常
3. ****dsh 的画像****：多步工具链自动编排、有判断力（主动说明数据权衡）、产物可追踪、耗时可控（94-186s）
4. ****关键启示****：提示词把验收标准写清楚（如“运行验证”），dsh 会照着闭环——复杂任务建议明确“做什么 + 怎么验收”
5. ****失败恢复****：本案例未触发；生产环境建议配 guard 超时 + 人工审批

<details><summary>本章导航</summary>

<!-- [fix] 链接健康检查：案例 A/B 锚点中 + 在 GitHub slug 里产生双连字符（--），原单连字符无法命中 -->

- [案例 A：数据质量分析 + 清洗 + 可视化（186 秒）](#案例-a 数据质量分析--清洗--可视化 186-秒)
- [案例 B：5-bug 代码修复 + 49 个测试（94 秒）](#案例-b5-bug-代码修复--49-个测试 94-秒)
- [案例总结：dsh 在复杂任务上的画像](#案例总结 dsh-在复杂任务上的画像)
- [案例 C：HTML 解析（Web 前端，约 3m18s）](#案例-cthtml-解析 web-前端 约-3m18s)
- [案例 D：代码重构（软件工程，约 4m37s）](#案例-d 代码重构软件工程约-4m37s)
- [案例 E：API 文档生成（文档，约 1m04s）](#案例-eapi-文档生成文档约-1m04s)
- [第二批案例画像](#第二批案例画像)

</details>

案例 A：数据质量分析 + 清洗 + 可视化（186 秒）

任务

给 dsh 一份含脏数据的合成 JSON（52 行：缺失值、类型错误、重复行、异常值 99999），要求：

1. 分析数据质量问题

- 2. 编写清洗脚本 `clean.py`
- 3. 编写可视化脚本 `visualize.py` (生成 `chart.png`)
- 4. 运行两个脚本验证

dsh 怎么做的 (工具链)

<!-- [style] 工具链示意代码块统一补 text 语言标签 -->

read(sales_data.json) → write(clean.py) → bash(python clean.py) → write(visualize.py) → bash(python visualize.py) → read(输出) → 总结

产出与验证

产物	结果	
clean.py	✅ 运行成功, 52 → 35 行, 所有问题归零	
visualize.py + chart.png	✅ 生成有效 PNG (1950×825)	
清洗策略	缺失金额中位数填充、异常值删除、去重、类型统一	

![dsh 生成的销售额可视化 (案例 A 产物)](./assets/case-chart.png)

输出要点 (体现判断力, 不是机械执行)

- 中位数填充会在直方图产生 510 尖峰——插补的固有副作用, 建议说明
- 若 99999 是真实大额订单, 建议改用 IQR/分位数法而非一刀切删除
- 清洗后统计: N=35, 均值 489.43, 中位数 510, 标准差 181.73

dsh 不仅执行了任务, 还主动说明了数据处理的权衡与假设——这是 agent 工程层"会思考"的证据。

案例 B: 5-bug 代码修复 + 49 个测试 (94 秒)

任务

给 dsh 一个故意埋了 5 个 bug 的 Python 计算器模块, 要求: 找到所有 bug → 修复 → 编写完整单元测试 → 运行验证。

埋的 bug

- 1. `add` 误写为 `a - b`
- 2. `divide` 除零静默返回 0 (应抛异常)
- 3. `factorial` 负数静默返回 -1 (应抛异常)
- 4. `factorial` 的 `range(1, n)` 漏乘 n
- 5. `format\_money` 未格式化为两位小数

dsh 的修复 + 测试 (验证: 49 passed)

完整测试见 [case-test-calculator.py](./assets/case-test-calculator.py)——49 个用例覆盖:

函数	覆盖	
add	正/负/零/浮点/精度/交换律	
subtract	负结果/零边界/浮点	
multiply	符号组合/乘零/浮点	
divide	整除/符号/浮点/除零必须抛 ZeroDivisionError	
factorial	0!/1! 边界/已知值/负数必须抛 ValueError	
formatmoney	补零/四舍五入/0.1+0.2 舍入/负数	

python -m pytest test_calculator.py -v # 49 passed in 0.37s

观察: dsh 的表现

- ****完整闭环****: 读 → 修 → 写测试 → 跑测试 → 总结, 无人工干预
- ****修复质量****: 5 个 bug 全修复且补了 docstring 说明
- ****测试设计****: 覆盖边界 (除零/负数/精度), 不是"能跑就行"

案例总结: dsh 在复杂任务上的画像

维度	表现	
多步工具链	✅ 自动编排 (读→写→跑→验证→总结)	
复杂任务耗时	94s-186s (同模型同网关, 比 benchmark 简单任务慢但可控)	
产出质量	✅ 有判断力 (数据权衡说明、测试边界设计)	
产物追踪	✅ 生成文件可在对话末尾直接打开	
失败恢复	本案例未触发; 生产建议配 guard 超时 + 人工审批	

给新手的启示: dsh 处理"多文件、多步骤、要验证"的任务很顺手——这也是它作为 Agent 运行时的主要价值场景。复杂任务建议: 提示词把验收标准写清楚 (如"运行验证"), dsh 会照着闭环。

动手练习（检验你是否真懂了）

1. ****理解题****：不看原文，说出案例 A（数据质量分析）的工具链顺序（read → write → bash → ...），以及最终产出是什么
 - > 自查：参考本章"案例 A"的"dsh 怎么做的"段落
2. ****理解题****：案例 B（5-bug 修复）里，dsh 补的 49 个测试覆盖了哪些边界情况？为什么"除零必须抛 ZeroDivisionError"是一个重要的测试点？
 - > 自查：参考本章"案例 B"的测试覆盖表格
3. ****动手题****：设计一个类似的"数据质量分析"任务：准备一份含脏数据的 CSV（至少 3 种问题：缺失值、类型错误、异常值），写提示词让 dsh 分析 + 清洗 + 可视化，记录耗时和产出
 - > 自查：参考本章案例 A 的任务描述 + 产出验证表格
4. ****动手题****：设计一个类似的"bug 修复"任务：写一个故意含 3 个 bug 的 Python 模块（如字符串处理、日期计算），让 dsh 找 bug → 修复 → 写测试 → 运行验证，记录耗时和测试通过率
 - > 自查：参考本章案例 B 的任务描述 + "dsh 的表现"观察段落
5. ****思考题****：案例 A 里 dsh "主动说明了数据处理的权衡与假设"（如中位数填充的尖峰副作用）。这个行为对"agent 工程层"的设计有什么启示？模型只是执行命令，还是真的有"判断力"？
 - > 自查：参考本章案例 A 的"输出要点"段落 + 案例总结表格
6. ****思考题****：本章结语说"提示词把验收标准写清楚，dsh 会照着闭环"。如果案例 A 的提示词只说"处理一下这个数据"而不说"运行验证"，dsh 的表现会有什么不同？
 - > 自查：参考本章"给新手的启示"段落 + 案例 A 的工具链（含 bash 运行验证）

常见疑问 FAQ

Q1：案例 A 耗时 186 秒，案例 B 耗时 94 秒，这个速度算快还是慢？

取决于任务复杂度和模型档位。同模型同网关下，比 benchmark 简单任务慢但可控。关键不是绝对速度，而是"多步工具链自动编排 + 产出质量 + 无人工干预"的综合价值。如果想提速，参考第 6 章的推理档位策略 + 提速插件示例。

Q2：案例里的"合成数据"是什么意思？为什么不用真实数据？

隐私保护。本白皮书不涉及任何真实业务数据或敏感信息。合成数据是"故意构造的、不含真实信息的数据"，用于演示 dsh 的能力。你在自己环境里可以用真实数据，但要注意数据安全。

Q3：如果 dsh 在复杂任务中"卡住了"（比如某步工具调用失败），怎么办？

几种处理：① 看 dsh 进程日志，定位哪步失败；② 检查工具调用的输入是否正确（如文件路径、命令语法）；③ 配 guard 超时（guard/包），避免无限等待；④ 生产环境建议配人工审批（interaction/），危险操作前确认。

Q4：案例 B 的 49 个测试是 dsh 自动生成的，质量怎么样？

质量不错。覆盖了边界（除零/负数/精度）、异常（必须抛特定异常）、常规（正/负/零/浮点）。但自动生成的测试可能漏掉"业务逻辑特有的边界"——建议人工 review 测试设计，补充领域特定的用例。

Q5：我想让 dsh 跑一个"多文件、多步骤"的任务，提示词怎么写效果最好？

三个原则：① 明确目标（"做什么"）；② 明确验收标准（"怎么算完成"，如"运行验证"49 个测试全过"）；③ 明确约束（"不能做什么"，如"不能删原始数据"）。参考本章两个案例的提示词结构。

Q6：案例总结说"失败恢复本案例未触发"，那 dsh 的失败恢复能力怎么样？

dsh 有 compaction（上下文溢出恢复）、guard（超时）、interaction（审批）等机制，但复杂场景的失败恢复还在演进中。生产环境建议：① 配 guard 超时避免卡死；② 配人工审批避免误操作；③ 长任务分步验证，不要"一口气跑完再检查"。具体配置参考第 8 章 8.5 节安全模型。

附录 A：[术语表与命令速查](./appendix-glossary.md)

扩展案例（第二批，三个功能领域）

完整执行报告见 [case-expansion-report.md](./case-expansion-report.md)，产物在 `docs/assets/`。全部合成数据。

案例 C：HTML 解析（Web 前端，约 3m18s）

任务：给定含表格+表单+图表的合成 HTML，编写零第三方依赖的解析脚本提取表格并输出 CSV。

dsh 的表现：

- **零依赖权衡**：主动选标准库 `html.parser`（而非 BeautifulSoup）
- **健壮性**：实现表格嵌套深度计数，防止越界
- **路径无关**：用 `\_\_file\_\_` 定位输入，不依赖运行目录

产物：[case-c-parser.py](./assets/case-c-parser.py) | 验证：输出 9 行×7 列 CSV，与源表逐字段一致

案例 D：代码重构（软件工程，约 4m37s）

任务：把约 200 行过程式订单脚本（含重复代码 `calcordertotal` / `calcordertotalv2`）重构为 OOP + 职责分离，行为一致，测试验证。

dsh 的表现：

- ****精准识别重复****：合并两份相同逻辑为 ``Order.total()`` 单一入口
 - ****SOLID 设计****：Product/Customer/Order（模型）+ OrderProcessor（查询）+ ReportGenerator（报告）
 - ****向后兼容****：保留模块级函数接口，可直接替换
 - ****测试深度****：17/17 PASS——不仅对比函数返回值，还对比**脚本级整体运行产物**（`report.txt` / `orders.json`）
 - ****沙箱感知****：发现 ``tempfile.mkdtemp`` 在沙箱下 0700 ACL 不可写，主动换方案
- 产物：[`case-d-ordersrefactored.py`](./assets/case-d-ordersrefactored.py) + [`case-d-testrefactor.py`](./assets/case-d-testrefactor.py) | 验证：17/17 PASS

案例 E：API 文档生成（文档，约 1m04s）

任务：给含 8 个函数的 Python 模块生成完整 Markdown API 文档（参数表/返回值/异常/示例/边界）。

dsh 的表现：

- ****契约差异识别****：主动发现"文档声明"与"代码实现"的差异（如 ``user_id`` 字符集未强制校验），如实写入边界章节
 - ****防御式文档****：为每个函数标注调用陷阱（负数 `limit`、空 `updates` 行为）
 - ****ReadTheDocs 风格****：423 行，8 个函数全覆盖，示例含 doctest 风格
- 产物：[`case-e-api.md`](./assets/case-e-api.md)

第二批案例画像

维度	表现	
跨领域能力	✅ Web/工程/文档三种任务都能闭环	
工程意识	✅ 零依赖权衡、沙箱感知、向后兼容、契约差异识别	
验证习惯	✅ 每个案例都运行验证（含脚本级产物对比）	
耗时	1-5 分钟/案例，复杂度越高越久	

总结：dsh 在"要写代码 + 要验证"的工程任务上表现稳定，且会做权衡（依赖/兼容/安全）——这是 agent 从"能答"到"能干活"的分水岭。

第 11 章：未来展望——dsh 与 Agent 生态的演进预测

本章目标：从多个角度推演 dsh 及其生态的未来——**技术、生态、竞争、行业、开发者机会、风险**。预测不是断言，是“基于当前事实的推演”，供你判断是否值得投入。

TL;DR（本章核心，30 秒版）

- 1. **短期（1-3 月）**：正式版 0.1.0 落地、插件生态爆发、教程/工具类项目吃第一波红利
- 2. **中期（1 年）**：dsh 成为“可编程 Agent 底座”的事实标准候选，垂直场景插件成熟
- 3. **长期（2-3 年）**：Agent 工程层标准化，dsh 生态与模型迭代相互成就
- 4. **最大风险**：破坏性变更、生态碎片化、官方策略转向
- 5. **个人机会**：现在入场（教程/插件/工具）是低成本的早期红利

<details> <summary>本章导航</summary>

- [11.1 技术演进预测](#111-技术演进预测)
- [11.2 生态发展预测](#112-生态发展预测)
- [11.3 竞争格局预测](#113-竞争格局预测)
- [11.4 行业应用预测](#114-行业应用预测)
- [11.5 开发者机会（现在入场的人）](#115-开发者机会现在入场的人)
- [11.6 风险与不确定性（诚实版）](#116-风险与不确定性诚实版)
- [11.7 白皮书自己的展望](#117-白皮书自己的展望)
- [11.8 给读者的最终建议](#118-给读者的最终建议)

</details>

11.1 技术演进预测

时间	预测	依据	
短期	0.1.0 正式版发布（去掉 rc），破坏性变更收敛	当前 rc.6，官方明示“将有破坏性变更”，迭代极快	
短期	官方补上 TUI 与交互式 CLI（社区呼声最高，#172 15+ 评论）	官方 Discussion 最热需求	
中期	缓存/性能优化成为主旋律（reasoningeffort 精细化、缓存命中率工具化）	高缓存命中率已是成本优势（第 5 章），会被工具化显性化	
中期	插件生态标准化（插件市场/一键安装/质量分级）	官方已有 dsh-plugin topic，插件数量增长必然	

		催生市场	
长期	Agent 运行时架构沉淀为"工程范式"（类似当年 Linux 内核模式的 Agent 版）	"everything is a plugin" 已被验证为可组合架构	

11.2 生态发展预测

- ****插件数量****: 零日 → 1 年内预计数十到上百个（参照同类生态 S 曲线）
- ****内容生态****: 教程/博客/awesome 列表先爆发（中文内容目前是真空——本白皮书是第一份系统教程）
- ****社区规模****: 官方 Discussion 日均新增讨论（我们观察到单日 30+ 新话题），Discord 活跃度会同步增长
- ****头部项目****: 会诞生几个"生态旗舰"（类似 VSCode 生态的 Prettier/ESLint 地位）——****工具型 + 教程型最可能****

11.3 竞争格局预测

维度	dsh 的定位演进	
vs Claude Code	短期仍"开箱即用不如"，长期靠"可定制 + 开源 + 成本"差异化	
vs OpenCode	都开源；dsh 的官方后端 + 插件生态是差异点（OpenCode 无官方后端）	
vs 自建框架	dsh 是"半成品到成品的桥梁"——比自建省事，比闭源可控	
模型侧	DeepSeek 模型每代迭代都会放大 dsh 生态价值（模型 + 运行时协同）	

关键判断：dsh 的胜负手不在"模型多强"（那是 DeepSeek 的事），而在"Agent 工程层能否成为标准"——谁能定义"插件怎么写、生态怎么长"，谁就赢下这一层。

11.4 行业应用预测

- ****金融/数据分析****: 长会话 + 高缓存命中 = 成本友好的批量分析，最先落地
- ****企业知识库/文档****: 1M 上下文 + 文档工具链，企业内知识管理是天然场景
- ****教育****: 批量出题/解析/归纳，成本敏感场景吃缓存红利
- ****垂直 Agent 产品****: 会涌现"行业 Agent 封装"（在 dsh 上做行业插件/配置包）

11.5 开发者机会（现在入场的人）

角色	机会	时机	
教程/内容作者	中文教程真空（白皮书是第一份）	现在（红利最大）	
插件开发者	官方缺位方向：TUI、远程访问、移动端、缓存工具	现在	
工具型项目	提速、耗时可视化、MCP 工具包	现在（我们已做提速插件实验验证）	
生态基础设施	插件市场、模板生成器、评测工具	中期	
行业解决方案	金融/教育等行业插件包	中期	

11.6 风险与不确定性（诚实版）

- **破坏性变更****：rc 阶段 API 可能频繁变动——插件/教程需持续跟进（白皮书会同步更新）
- **生态碎片化****：插件质量参差，缺乏标准——早期需要“高质量示范项目”（本白皮书 + 第 4 章示例是示范之一）
- **官方策略转向****：官方可能收回某些方向（如内置 TUI）——生态项目要有差异化壁垒
- **模型竞争****：其他模型迭代可能削弱 DeepSeek 吸引力——但 dsh 模型无关的设计（可接 OpenAI 兼容模型）是缓冲
- **热度回落****：如果 dsh 生态没起来，早期投入可能“白费”——但教程/技能本身是可迁移资产

11.7 白皮书自己的展望

- **内容****：随 dsh 迭代持续更新（版本号对齐 rc/正式版）
- **双语****：英文版完成度追上中文
- **案例****：更多行业真实案例（合规前提）
- **生态****：与 awesome 列表、官方 Discussion 联动，成为生态内容枢纽之一

11.8 给读者的最终建议

- **想试试****：现在装起来玩（第 2 章），成本几乎为零
- **想投入****：挑一个“官方缺位 + 你有积累”的方向（TUI/行业插件/教程）
- **想观望****：等 0.1.0 正式版，但会错过生态早期红利——****早期红利 ≈ 先发者的耐心****

预测会错，但“现在入场的成本最低”这一点，大概率不会错。

附录 A: [术语表与命令速查](./appendix-glossary.md)

第 12 章：已知不足与边界——诚实版

本章目标：不吹不黑，列出 dsh 当前的**已知不足**与**使用边界**。写这本白皮书时 dsh 仍处于 `0.1.0-rc.6`（预发布阶段），这些不足是“此刻的事实”，不是“永远的宿命”——它们会随版本迭代变化。

本章所有“已知问题”均来自本机实测 + 官方仓库 `deepseek-ai/deepseek-harness` 讨论区（截至 2026-08-14）的公开反馈。

TL;DR（本章核心，30 秒版）

1. **rc 阶段是最大的不确定性**：API/配置随时可能破坏性变更，投入前先锁版本线
2. **插件生态早期**：官方包 60+ 但覆盖有限，第三方插件少，交互形态（TUI）缺失
3. **跨平台短板**：Windows 上除路径/编码 bug（UTF-16、0x00）外，还有端口保留、局域网访问、沙箱稳定性、WSL 工作区、子进程终止等家族问题（速查表见 [12.4] (#124-跨平台已知问题速查表))
4. **性能边界未充分验证**：高并发、大型代码库场景缺少公开压测数据
5. **官方策略风险**：开源承诺 vs 商业化转向，是选型时必须考虑的黑天鹅

<!-- [fix] 结构核验：补齐本章导航（第 12 章为新增章节，原缺失，与第 3-11 章结构保持一致） -->

<details><summary>本章导航</summary>

- [12.1 rc 阶段的不稳定性](#121-rc-阶段的不稳定性)
- [12.2 插件生态早期](#122-插件生态早期)
- [12.3 跨平台短板](#123-跨平台短板)
- [12.4 跨平台已知问题速查表](#124-跨平台已知问题速查表)
- [12.5 性能边界未充分验证](#125-性能边界未充分验证)
- [12.6 与成熟 Agent 的差距](#126-与成熟-agent-的差距)
- [12.7 官方策略风险](#127-官方策略风险)
- [12.8 白皮书自身的局限](#128-白皮书自身的局限)

</details>

12.1 rc 阶段的不稳定性

破坏性变更随时发生

dsh 从 rc.1 到 rc.6 已经历过至少一次依赖断裂：早期版本 `@deepseek-ai/` 包的版本线不一致会导致插件装不上（404/ERRMODULENOTFOUND）。rc.6 收敛了很多，但没有任何承诺说 rc.7/正式版不会再来一次。

对你的实际影响：

- 写教程/插件，可能每两周就要跟着改一遍
- 锁版本线（`^0.1.0-rc.6`）是基本操作，但 rc 线升级是"向上兼容"还是"推翻重来"，取决于官方心情

[!WARNING]

生产环境请谨慎评估。白皮书写作时官方仍在快速迭代，**今日的写法明天可能就废弃**。

已知的 rc 坑（本机/社区复现）

坑	表现	状态	
link 开发依赖断裂	@deepseek-ai/ 本地 link 时报 ERRMODULENOTFOUND, npm 安装却正常	已定位（扁平兜底目录机制），需锁依赖线规避	
Windows 路径 0x00	含中文/特殊字符路径 workspace 创建失败 (ENOENT)	社区反馈中（#151/ #396）	
fs-sandbox 竞态	post-check 路径检查与 workspace-write 存在时序竞态	社区反馈中（#159）	
TUI 缺失	官方 examples 无交互终端 UI（社区自建有，未纳入）	建议中（#392）	

12.2 插件生态早期

现状：官方包 60+，但生态整体处于"零日"状态。

- ****第三方插件少****：讨论区插件帖在爆发，但质量参差，多数是"第一个插件"练手作
- ****交互形态缺失****：headless/JSON-RPC/Web 形态齐全，**TUI 等终端交互形态无官方示例**（社区 deepseek-harness-tui 已证明可行，未纳入官方）
- ****文档滞后于代码****：官方文档以架构为主，上手路径/避坑记录依赖社区自产（这正是本白皮书存在的理由）
- ****版本线混乱****：npm 上同包多版本线并存，装错线就是 404

判断：生态玩法现在入场是早期红利（竞争少、官方扶持意愿强），但不要指望"照着官方文档就能跑"——踩坑是常态。

12.3 跨平台短板

dsh 在 macOS/Linux 上表现成熟，但 Windows 支持有明显的第二公民感：

- ****路径处理****: 中文路径、特殊字符路径有真实 bug (0x00 截断、ENOENT) , 社区多人反馈 (根因 #107, 家族 17+ 帖)
 - ****编码问题****: UTF-16 相关处理存在缺陷, 终端输出偶发乱码
 - ****CLI/TUI 之争未定****: 官方讨论区存在"CLI 才是正道 vs TUI 才是交互未来"的路线争议 (#386) , 路线未明前, 投资终端 UI 形态有风险
- 以下 Windows 家族问题来自官方讨论区挖掘报告
([docs/research/discussion-mining.md](./research/discussion-mining.md), 2026-08-14 抓取, rc.6 时代) , 均为社区真实复现, 多数尚未修复。

端口: 默认 3080 撞上 Hyper-V 保留区间 (#589)

现象: Windows 上默认端口 3080 启动报 EACCES, 服务起不来、web 界面打不开。

根因: 启用 Hyper-V/WSL2 后, Windows 会保留一段动态端口区间 (3070-3169) , 3080 恰好落在其中。

临时 workaround: 换用保留区间外的端口 (社区实测 13080 可用) 。

局域网 HTTP 访问 RPC 全挂 (#755)

现象: 局域网内通过 HTTP (非 localhost、非 HTTPS) 访问时, 所有 RPC 调用失败。

根因: crypto.randomUUID 只在安全上下文 (HTTPS 或 localhost) 可用, 局域网裸 HTTP 属非安全上下文。

临时 workaround: 官方无修复; HTTPS 或隧道 (如 Tailscale) 访问可规避非安全上下文限制 (按成因推论, 未在社区帖内验证) 。

沙箱: 临时目录清理后永久崩溃 (#758)

现象: Windows 上清理沙箱临时目录后 dsh 永久崩溃、不自愈 (社区标 P0) , 并伴随 4 个相关稳定性问题。

影响: 清一次临时目录 = 服务报废, 无自动恢复路径。

临时 workaround: 不要清理 dsh 沙箱临时目录; 已触发则重启进程恢复。

WSL: 工作区只能选 /root (#160)

现象: WSL/Ubuntu 环境下工作区选择器只能选 /root 内的目录, 其余路径不可选。

临时 workaround: 把项目放到 /root 下使用 (限制内可用, 限制外暂无绕过方案) 。

子进程: Windows 无优雅终止 (#717)

现象: Windows 下子进程管理系统性缺失——没有优雅终止阶梯、孙进程输出截断、spill 权限不生效、shellPath 默认指向 /bin/bash (Windows 上不存在该路径) 。

影响：长任务终止不干净、输出丢失、权限预期失效，属平台适配缺口而非单个 bug。

临时 workaround：手动 taskkill /T 清理进程树；显式配置 shellPath 为 Windows 实际路径。

12.4 跨平台已知问题速查表

本章跨平台已知问题一表速查。帖号均为官方讨论区真实帖 (deepseek-ai/deepseek-harness)，截至 2026-08-14。

问题	环境	帖号	临时 workaround	
中文路径截断 (readUtf16 单字节判 0, 开=U+5F00 被截)	Windows	#107 https://github.com/deepseek-ai/deepseek-harness/discussions/107 (根因；家族 #151/#396/#563 等 17+ 帖)	工作区路径避开中文/特殊字符；社区附修复补丁可 cherry-pick (#244/#580)	
目录选择器 worker 崩溃 (koffi 相关)	Windows	#30 https://github.com/deepseek-ai/deepseek-harness/discussions/30 (家族 #154/#236/#449/#768)	安装层锁 koffi@3.1.2 (#293)；选择器崩溃暂无绕行	
默认端口 3080 撞 Hyper-V 保留区间 (EACCES)	Windows (启用 Hyper-V/WSL2)	#589 https://github.com/deepseek-ai/deepseek-harness/discussions/589	换用保留区间外端口 (如 13080)	
局域网 HTTP 访问 RPC 全挂 (crypto.randomUID 非安全上下文)	局域网 HTTP (非 localhost)	#755 https://github.com/deepseek-ai/deepseek-harness/discussions/755	HTTPS/隧道访问可规避 (推论)；官方无修复	
沙箱临时目录清理后永久崩溃 (不自)	Windows	#758 https://github.com/	勿清理沙箱临时目录；已触发需重启	

愈, P0)		deepseek-ai/ deepseek- harness/ discussions/758	进程	
WSL 工作区只能选 /root 内目录	WSL/Ubuntu	#160https:// github.com/ deepseek-ai/ deepseek- harness/ discussions/160	项目放 /root 下使 用	
Windows 子进程无 优雅终止 (孙进程 输出截断/spill 失效 /shellPath 错)	Windows	#717https:// github.com/ deepseek-ai/ deepseek- harness/ discussions/717	手动 taskkill /T 清 理; 显式配置 shellPath	

12.5 性能边界未充分验证

白皮书的 benchmark 覆盖了单 agent、常规任务规模，以下场景缺少公开数据：

- ****高并发****：多 agent 并行、大规模任务分发
- ****大型代码库****：百万行级仓库的上下文管理、工具调用延迟
- ****长时运行****：连续数小时运行的稳定性、内存泄漏风险
- ****缓存命中率的边界****：97% 实测命中率依赖"对话模式重复"——全新任务/冷启动场景会明显下降

12.6 与成熟 Agent 的差距

对照 Claude Code、Codex 等成熟产品，dsh 的差距是结构性的（不是补几个功能就能追上）：

维度	dsh (rc.6)	成熟 Agent	
生态阶段	零日，第三方资产稀少	成熟，生态完整	
开箱即用	需理解 profile/插件体系	装完就跑	
稳定性	rc 期，破坏性变更风险	稳定版，长期兼容承诺	
文档	官方偏架构，上手靠社区	官方文档完善 + 教程丰富	
IDE/工具链集成	起步	深度集成	

dsh 的定位：不是“开箱即用的整车”，是“可编程的乐高底座”。选择 dsh = 选择自由度，代价是自己要动手拼。

12.7 官方策略风险

作为选型者，必须考虑的黑天鹅：

- ****开源承诺****：MIT 开源目前无杂音，但“官方级插件体系”意味着生态深度绑定官方节奏
- ****模型绑定倾向****：官方默认体验倾向 DeepSeek 模型（通过 llm 插件可接任意模型，但“官方优化”以自家模型为主）
- ****商业化转向****：一旦 dsh 用户量上来，官方可能推出托管服务/付费层——开源版能否保持同等能力未知
- ****方向漂移****：rc 期功能增删频繁（TUI/CLI 路线之争即信号），押注错误方向 = 沉没成本

12.8 白皮书自身的局限

最后，诚实说这本白皮书自己：

- ****基于 rc.6 编写****：所有命令、配置、数据在 rc.6 验证，****新版本可能全部失效****
 - ****benchmark 样本有限****：单机、单模型、有限任务集，不是权威评测
 - ****中文优先****：英文版是翻译/精简版，可能滞后于中文版内容
 - ****覆盖不全面****：dsh 官方包 60+，本手册深挖的是核心路径，长尾插件未逐一覆盖
- **使用建议****：把本白皮书当“rc.6 快照 + 方法论”，不要当“永恒圣经”。版本更新时，先跑一遍 [roadmap 学习路径](./roadmap.md) 与 [速查卡](./cheatsheet.md) 的验收标准，再决定要不要更新你的依赖线。

本章信息截至 2026-08-14 (dsh 0.1.0-rc.6)。后续版本如有更新，欢迎提 Issue/PR 修正。

第 13 章：安全与沙箱模型

本章目标：看懂 dsh 的安全骨架——沙箱管什么、权限怎么分级、审批怎么放行——以及社区审计发现的真实边界。 **这是从“能跑”到“敢上生产”的关键一章。 **

TL;DR（本章核心，30 秒版）

- 1. **三层防线**：沙箱（在哪执行）→ 权限预设（能做什么）→ 审批（危险动作要不要人点头）——默认不是裸执行
- 2. **沙箱只管文件效果**：`read-only` / `workspace-write` / `danger-full-access` 三档；网络与进程可见性不在词汇表内（所以 `taskkill` 杀宿主等案例是“词汇表外”，不是沙箱失守）
- 3. **权限 = 两个旋钮捆成预设**：`sandbox/mode` + `approval/policy`；默认表两张：`workspace-write`（工作区写 + ask）与 `danger-full-access`（无沙箱 + never）
- 4. **审批 fail-closed**：只有 `allowed-once` 放行；ask 无应答 = 拒绝（unavailable），never 一切确定性拒绝——headless 的默认姿态
- 5. **社区审计找到真实边界**：#159 fs-sandbox 竞态、#584 scrubbedParentEnv 误伤、#381 iframe 点击劫持、#817 审计报告（vm 逃逸 + 本地 RPC 无认证）
- 6. **企业基线一句话**：默认 `workspace-write` + ask、loopback 不放行、插件只装信任源、敏感目录不进 workspace

<details><summary>本章导航</summary>

- [13.1 安全设计哲学：沙箱/权限/审批三层](#131-安全设计哲学沙箱权限审批三层)
- [13.2 沙箱机制原理：fs 边界与工具沙箱](#132-沙箱机制原理 fs-边界与工具沙箱)
- [13.3 权限模型：工具权限分级表](#133-权限模型工具权限分级表)
- [13.4 审批流：从请求到放行](#134-审批流从请求到放行)
- [13.5 插件安全审计清单](#135-插件安全审计清单)
- [13.6 社区已知安全案例](#136-社区已知安全案例)
- [13.7 企业安全基线](#137-企业安全基线)

</details>

13.1 安全设计哲学：沙箱/权限/审批三层

dsh 的安全骨架是三层各管一件事（依据官方 docs/subsystems/ 架构文档，已核验：sandbox.md / permission-presets.md / approval.md；与第 8 章 8.5 实测交叉印证）：

层	管什么	官方包	一句话	
沙箱	在哪执行、能碰哪些文件	sandbox/ sandbox、 sandbox/ sandbox-local、	隔离命令执行的文件效果	

		sandbox/ sandbox-policy		
权限	能做什么	interaction/ permission- presets	把沙箱 + 审批捆成 命名预设	
审批	危险动作要不要人 确认	interaction/user- approval	最小权限的最后一 道闸	

最小权限原则是三层共同的设计取向：默认预设只给"工作区写 + 关键操作询问"；任何提升（切 danger-full-access、改审批策略）都显式发生并写入会话日志——permission/preset 事件是纯日志的用户意图，不进模型转录，便于事后回溯"谁在什么时候提了权"。

威胁模型速记：三层防线防的是"不可信输入驱动代理越界"——提示词投毒、恶意插件、被诱导的高权限操作（#381 iframe 劫持就是往这条链上打）；它不承诺防"信任代码自身"（插件就是可执行代码，见 13.5），也不承诺防网络/进程级攻击。

核心认知：***dsh 的工具执行默认有隔离与审批层，不是裸执行***；但它不是"安全操作系统"——沙箱不挡网络与进程、审批可以被模型自答（13.6）。

13.2 沙箱机制原理：fs 边界与工具沙箱

官方沙箱文档明确定义：沙箱只管文件效果（filesystem effects），网络与进程可见性不在其词汇表内。

三档模式（SandboxMode）：

模式	允许的文件效果	说明	
read-only	只读 + 必需 sink (POSIX 下如 /dev/null)	Windows ACL 后端无显 式可写根，报 partial	
workspace-write	工作区根 + 后端承诺的临 时区可写	默认预设；根来自会话不 可变 cwd	
danger-full-access	不设限	直接 spawn 原 argv，不 走 ctx.sandbox	

执行细节：

- ****策略按调用携带****（per-call）：`SandboxExecutionPolicy`（mode + workspaceRoot + sessionId）在每次能力调用时解析，不绑死在 provider 上——同一 provider 可同时服务 `read-only` 的 bash 与需要可写状态目录的子代理
- ****工作区根规范化****：先按文件系统语义 canonicalize（`symlink/..` 解析到真实目录）再做词法归一——防符号链接绕边界
- ****后端矩阵****：Linux bwrap/Landlock、macOS Seatbelt、Windows ACL restricted-token；`enforcement: full | partial`——旧 Landlock ABI 与 Windows ACL 的

Everyone/hard-link 边界是当前 partial 案例 (**承诺打折扣时，消费方须按 partial 处置**)

- **fs 工具同边界**：`write`/`edit` 等文件工具同样受 workspace-write 约束，不是"文件工具直通、只有 bash 才沙箱" (#149 递归删工作区即发生在 workspace-write 下)
- **只限写不限读**：当前权限模型约束的是**写**，工作区外内容可被读到 (#492 提议评测隔离模式时点出的现状)

工具沙箱：bash/pwsh 走 bash-sandbox / pwsh-sandbox (消费 ctx.sandbox) 在沙箱内起子进程；Windows 上 pwsh 沙箱有 ACL 约束 (第 8 章实测遇到过 temp 权限问题；#758 还报告 Windows 沙箱临时目录清理后永久崩溃)。

同族案例：#159 的竞态属于 TOCTOU (检查与使用之间路径被换)；#278 是另一种拓宽手法——/tmp 作 workspace 时，受限子进程可通过 rebind 把 workspace-write 授权范围放宽。两者共同教训：边界根目录要选可信位置，且不能只信任单一路径检查。

13.3 权限模型：工具权限分级表

官方权限预设把两个旋钮——sandbox/mode 与 approval/policy——捆成命名预设，客户端展示为一个"Permissions"选择器。默认表两张：

预设	sandbox/mode	approval/policy	语义	
workspace-write	workspace-write	ask	工作区内可写、操作前询问 (默认)	
danger-full-access	danger-full-access	never	无沙箱、不询问	
custom (派生态)	任意组合	任意	手动调旋钮后的"非预设"态，不可作为切换目标	

工具权限分级 (按危害半径排序；各工具"建议预设"为按官方文档推导，非逐工具实测——推断，待实测)：

级别	代表工具	建议预设	风险	备注	
只读探查	read/grep/glob	read-only 兼容	低	只读不落盘；读不限于工作区	
工作区写	write/edit/strreplaceeditor	workspace-write	中	写边界 = 工作区根 + 临时区	
命令执行	bash/pwsh	workspace-write (沙箱内)	高	沙箱不挡网络与进程	
全访问	任意 (切 danger-full-	danger-full-access	极高	关闭所有闸门	

	access)				
--	---------	--	--	--	--

官方文档明确沙箱**只管文件**——所以"命令执行"级的高风险不能靠沙箱消除，要靠审批与信任边界 (13.5 / 13.7) 兜底。

真实边界案例 (详见 13.6)：workspace-write 下递归删除整个工作区零确认 (#149)；danger-full-access 误删整个家目录 (#461, 真实事故)；Windows 上 minimal preset 允许工作区外写入且无审批 (#523)；沙箱内 agent 可 taskkill 杀宿主 (#466, 进程可见性在沙箱词汇表外)。

13.4 审批流：从请求到放行

官方审批文档：审批回答一个问题——"这个具体动作能不能做？"

结果集 fail-closed (ApprovalOutcome)：

结果	含义	对调用方的效果	
allowed-once	一次性放行 (只放行被问的这一个动作)	✅ 继续	
rejected	明确拒绝	❌ 中止	
cancelled	请求被撤回 (AbortSignal)	❌ 中止	
unavailable	无应答者 / 应答者异常	❌ 中止 (默认 fail-closed)	

策略 (ApprovalPolicy)：ask (默认, 交给应答者链; 链为空 → unavailable)；never (确定性全部 rejected, 不派发任何应答者——headless/CI 的严格姿态)。

流程：工具调用 → approval/request waterfall (插件可拦截/改写) → 应答者 (Web UI 人肉应答, 或 ACP 桥的一次性机器决策) → 每次请求成对写审计事件 approval/asked + approval/decided (同一 ApprovalRequestId)。

请求内容 (ApprovalRequest)：agent (应答者只回答自己拥有的 agent) + toolName + callId (关联已流式展示的工具调用, 参数不重复渲染) + reason (为什么问) + signal (AbortSignal 撤回)。

三个已知坑：

- 1. **审批回环**：#250 真实复现"模型自批准 danger-full-access" (Web approval 通道可被模型自己驱动) ——**审批不是安全边界**，只是人机协作闸门
- 2. **并发误定向**：#453 并发沙箱审批时点 Allow 会中止另一个调用 (UI 应答与 callId 错配)
- 3. **重连丢审批**：#646 重连静默丢 pending approval (resync 清空 + replay 竞态)；headless 下审批行为未定义 (#291)

13.5 插件安全审计清单

插件是 dsh 的能力边界 ("一切皆插件", 见第 4 章) ——装插件 = 装可执行代码。社区审计 (#817 及同族) 沉淀的检查清单:

#	检查项	社区依据	处置	
1	插件来源可信? dsh plugin add 无签名 /来源校验	#587	只装官方/知名源; 装前读源码	
2	boot 期权限最小? 插件 boot 期有全配置树写权限	#587	警惕"装完自动改配置"的插件	
3	不拿 vm 当安全边界? workflow/动态插件 vm 可逃逸	#243 #451 #774 #778	vm 只当隔离引擎, 不当安全层	
4	子进程环境 scrubbed 正确? scrubbedParentEnv 子串误伤合法变量	#584	检查 KEYBOARD/MONKEY 等含 KEY 子串的变量是否被误 scrub (误伤机制按标题推断)	
5	密钥脱敏不 fail-open? settings role'secret' 存在脱敏缺口	#226	密钥不写进提示词; 校验脱敏逻辑	
6	安全 hook 不静默失效? timeout: 0 会 fail-open	#460 #583	hook 超时设正数; 加载失败要报错	
7	审计留痕? approval/asked/decided 成对可查	官方 approval.md	关键操作按会话可回溯	
8	不泄漏会话明文? 崩溃后 .tmp 明文会话残留	#674	敏感环境禁用崩溃转储 / 定期清理	

13.6 社区已知安全案例

以下 4 帖全部经 gh api graphql 核验存在 (deepseek-ai/deepseek-harness Discussions, 2026-08-14) :

帖号	一句话	类型	影响	
#159 https://	fs-sandbox post-	沙箱竞态	TOCTOU: 检查与	

github.com/deepseek-ai/deepseek-harness/discussions/159	check pathname race 可绕过 workspace-write 文件边界		使用之间路径被换，可越界写	
#584https://github.com/deepseek-ai/deepseek-harness/discussions/584	scrubbedParentEnv 子串误伤 KEYBOARD/MONKEY 等合法环境变量（附可 cherry-pick 修复）	子进程环境	合法环境变量被 scrubbed，行为异常	
#381https://github.com/deepseek-ai/deepseek-harness/discussions/381	默认 localhost Web 可被跨站 iframe 点击劫持，诱导授权 Full access 并驱动高权限操作	前端点击劫持	恶意网页诱导用户在 dsh UI 上点出高权限	
#817https://github.com/deepseek-ai/deepseek-harness/discussions/817	安全审计报告：沙箱/审批边界绕过与本地 RPC 无认证（PoC 可私下提供）	系统性审计	覆盖 vm 逃逸（同族 #243 #778）、本地 /api 无鉴权（同族 #451，CVSS 8.8）、approval 回环（#250）	

同族高价值补充（帖号来自仓库内 docs/research/discussion-mining.md §2.6，该报告称全量 780 帖程序化核验）：

帖号	一句话	启示	
#149	workspace-write 下可递归删除整个工作区，零确认	工作区内容也要防"自毁"	
#250	Web approval 回环：模型自批准 danger-full-access	审批不是安全边界	
#461	Full Access 模式误删整个家目录（真实事故）	高权限预设风险实锤	
#587	第三方插件 boot 期有全配置树写权限	插件信任 = 供应链安全	
#466	沙箱内 agent 可 taskkill 杀宿主	进程可见性在沙箱词汇外	
#674	崩溃后 .tmp 明文会话残	隐私风险	

	留不清理		
--	------	--	--

免责：以上为 rc.6 时代 (2026-08-13 发布后 48h 内) 的社区报告，部分可能已在新 rc 修复；引用时注意版本语境。

13.7 企业安全基线

给"要上生产 / 团队推广"的决策建议（对齐第 6 章风格）：

维度	基线	依据	
网络暴露	保持 loopback (--host 0.0.0.0 被官方拒绝是有意 的)；远程认证完善前勿 绕过	#76 #130 #397	
权限预设	默认 workspace-write + ask; danger-full-access 只在隔离机 / 一次性任务 用	官方 preset 表 + #461	
审批策略	人肉应答链路必备； headless 用 never (确定 性拒绝) 并前置 review 闸	approval.md + #291	
插件治理	白名单源 + 装前过 13.5 清单；禁止裸 dsh plugin add github:	#587 #656	
工作区边界	敏感目录 (家目录/密钥目 录) 不进 workspace；工 作区内容定期提交版本控 制	#149 #461	
审计	会话日志留存 (approval 审计对可回溯)；防 .tmp 明文残留	approval.md + #674	
升级纪律	rc 阶段每次升级重跑 13.5 清单 (沙箱后端/预 设表可能变)	第 12 章 rc 版诚信	

决策速记：本地个人开发 → 默认预设即可；团队共享 → workspace-write + ask + 插件白
名单；CI/无人值守 → headless + never + 前置代码 review；任何场景都别为省事长期挂
danger-full-access。

场景 → 推荐组合（决策建议，按上表基线推导）：

场景	推荐组合	理由	
本地个人开发	默认 workspace-write +	开箱即用，审批不烦人	

	ask		
团队共享主机	workspace-write + ask + 插件白名单	多用户共用，插件供应链 风险放大	
CI / 无人值守	headless + never + 前置 review 闸	确定性拒绝，无人挂起	
隔离机 / 一次性任务	danger-full-access (机 器本身隔离)	授权最大化但攻击面控制 在单机	

动手练习（检验你是否真懂了）

1. ****理解题****：沙箱三档模式分别允许什么文件效果？为什么说"网络与进程不在沙箱词汇表内"？
> 自查：参考本章 13.2 节三档表与"后端矩阵"段
2. ****理解题****：为什么 headless 下的 `never` 是"最严格"而非"最宽松"？
> 自查：参考本章 13.4 节"策略"段 (deterministic rejected)
3. ****动手题****：打开 `dsh web`，观察 Permissions 选择器的两个预设；切到 `danger-full-access` 再切回，看会话日志里的 `permission/preset` 事件
> 自查：参考本章 13.3 节预设表
4. ****动手题****：装一个社区插件前，按 13.5 清单逐条过一遍（来源/源码/权限/审计），结论写进笔记
> 自查：参考本章 13.5 节清单表
5. ****思考题****：为什么 #250 的"模型自批准"说明审批不是安全边界？如果审批挡不住，企业靠什么兜底？
> 自查：参考本章 13.6 节 + 13.7 节基线表

常见疑问 FAQ

- Q1：沙箱能防住恶意代码吗？
不能当安全边界用。沙箱只管文件效果；网络（如 SSRF）与进程（如 #466 taskkill）在其词汇表外。防恶意代码靠插件信任（13.5）与网络/进程级隔离（容器/VM/远程沙箱——官方文档明确这些是能力缝的 sibling 实现，不是 ctx.sandbox 的 provider）。
- Q2：为什么 headless 用 never 反而更安全？
never 不是"永不询问"的宽松模式，而是确定性拒绝：任何审批请求直接 rejected，不派发应答者——无人值守时不会出现"挂着等人点 Allow"。需要放行的动作靠前置 review 或显式配置，而不是运行时询问。
- Q3：workspace-write 是不是就安全了？

边界内相对安全，但 #149 显示"递归删除整个工作区"在 workspace-write 下零确认——沙箱防的是"越界"，不防"边界内自毁"。重要代码请纳入版本控制。

Q4：第 12 章已提过 #159，这章为什么又讲？

第 12 章是"已知不足速查表"（一句话 + 状态），本章展开机制（post-check 竞态怎么发生）、同族（#278 /tmp rebind）与缓解（不信任单一路径检查、关键目录不进 workspace）。

Q5：这些安全帖号可信吗？不会是编的吧？

4 个核心帖号（#159 #584 #381 #817）均经 gh api graphql 逐号核验存在（链接见 13.6 表格）；同族补充帖来自仓库内 docs/research/discussion-mining.md（全量分页抓取 780 帖并程序化核验）。

下一章：[第 14 章：成本与用量](./14-cost.md)（规划中）。

第 14 章：缓存与成本工程

本章目标：把“便宜”从玄学变成工程——对话缓存机制、命中率实测与优化、成本模型、推理档位联动、真实任务预算，以及怎么“看见”每笔 token 花在哪。

TL;DR (本章核心, 30 秒版)

1. ****缓存是成本第一变量****：DeepSeek context cache 对重复输入按 ****98% 折扣 (Flash) / 99%+ 折扣 (Pro) **** 计费——Agent 工作负载输入占比高，命中率直接决定成本量级
2. ****手册实测命中率 97%****：会话延续 + 稳定工具 schema + Agent 多步工作负载特性 (第 5 章 5.1.1)；社区长跑实测可达 99.7%
([#560](https://github.com/deepseek-ai/deepseek-harness/discussions/560))
3. ****命中率三原则****：会话延续（别频繁新建）、前缀稳定（别老改配置）、少打断（一次写清验收标准）
4. ****两个独立杠杆****：推理档位管“思考 token 量”，缓存管“输入单价”，可叠加——`low` 档 + 高命中 = 最便宜组合
5. ****成本要看得见****：会话统计行看缓存命中 %；每轮 token 显示官方待实现 ([#735](https://github.com/deepseek-ai/deepseek-harness/discussions/735))，先用统计行 + 社区 cost-tracker 插件

<details> <summary>本章导航</summary>

- [14.1 对话缓存机制原理](#141-对话缓存机制原理)
- [14.2 命中率实测：97% 怎么来的](#142-命中率实测-97-怎么来的)
- [14.3 命中率优化实践](#143-命中率优化实践)
- [14.4 成本模型：命中率如何决定账单](#144-成本模型-命中率如何决定账单)
- [14.5 推理档位联动：low/high/max 成本矩阵](#145-推理档位联动-lowhighmax-成本矩阵)
- [14.6 预算实战：案例 A 成本估算](#146-预算实战案例-a-成本估算)
- [14.7 测量方法：让 token 消耗可见](#147-测量方法让-token-消耗可见)
- [14.8 成本相关踩坑清单](#148-成本相关踩坑清单)
- [14.9 决策建议速查](#149-决策建议速查)

</details>

14.1 对话缓存机制原理

DeepSeek API 的 context cache（提示词缓存）：重复/相似的输入 token 按缓存价计费，而不是全价。dsh 每次模型请求的输入 = 系统提示 + 技能目录 + 对话历史 + 工具 schema (第 8 章 8.3)，其中不变的前缀部分就是缓存的天然候选——这决定了 Agent 工作负载的缓存潜力远高于普通聊天。

计费规则（第 5 章 5.1.1 定价表）：

计费项	未命中价	缓存命中价	折扣	
输入 (Flash)	\$0.14/M	\$0.0028/M	98%	
输入 (Pro)	\$0.435/M	\$0.003625/M	99%+	

每次请求的输入结构（第 8 章 8.3），决定了哪些 token 能命中：

系统提示（稳定）	+	技能目录（稳定）	+	对话历史（增量）	+	工具 schema（稳定）	+	本轮消息（增量）
└──────────┘				缓存命中区（重复）	└──────────┘		未命中区（新增量）	└──────────┘

命中区越大、增量越小 → 命中率越高。理解这个结构，14.3 的三个优化杠杆本质上都是"让命中区变大"。

缓存不只省钱，还提速：冷启动首轮含上下文注入约 110s，热缓存约 1s（第 1 章实测）——命中时首 token 时间量级性缩短。

****严格前缀缓存规则（社区分析，#1052 weijiafu14，官方文档 [kv_cache](https://api-docs.deepseek.com/guides/kv_cache/)）**：**DeepSeek 是****严格的前缀缓存****——前缀单元在****用户输入结束、模型输出结束等位置持久化****；下一次请求只能命中"已经完整匹配"的前缀。
关键推论：

- ****工具结果天然 miss 一次****：工具结果是在"上一轮模型输出"之后才追加的，它****第一次进入下一次请求时必然是新后缀、必 miss 一次****——不论传原文还是压缩预览（这与截断方式无关）。
- ****"截断会避开缓存"是误读****：只要截断是确定性的（同输入同输出），后续回放的是同一份字节，已有前缀照常命中；只有首次出现的压缩结果、以及之后主动读取 artifact 新增的内容各自 miss 一次。****压缩工具不会绕开 DeepSeek 缓存，反而把"必然首次 miss"的工具结果缩小****（#1052 weijiafu14 实测：原生工具输出 42,299 字符 → 压缩持久化 7,885 字符，后续 derive/replay 哈希一致）。
- ****代价提醒（#1052 fnsii + weijiafu14）****：缓存本身是 best-effort、官方不承诺 100% 命中（weijiafu14 转述官方说明）；若完全不保留上下文前缀（如每轮重写/清空历史、换新会话丢全部前缀），则完全无法命中缓存，等于按新输入全价计算（fnsii）。****快封顶时优先做 summary 压缩再继续****（保留前缀摘要），而不是直接开新会话丢全部前缀（fnsii 建议）。

14.2 命中率实测：97% 怎么来的

手册在真实 dsh 会话统计中实测缓存命中率可达 97%（第 5 章 5.1.1）。为什么 dsh 的命中率特别高：

原因	说明	
会话延续	同会话多轮对话，系统提示/技能目录/历史重复 → 命中	
稳定的工具 schema	每步请求携带相同的工具定义 → 命中	
Agent 工作负载特性	多步工具链反复携带相同上下文 → 命中率天然高	

边界（诚实版）：97% 依赖"对话模式重复"——全新任务/冷启动场景会明显下降（第 12 章 12.5）。社区长跑实测可达 99.7%（[#560](https://github.com/deepseek-ai/deepseek-harness/discussions/560)），印证"越长的会话命中率越高"。

实测方法：Web UI 底部会话统计行看"缓存命中 %"（第 6 章 6.6）；对比基准是 5.1.1 的"50 步工具链任务、2.4M 输入 token"——它是输入量级的典型样本。

***口径注意（#1234 社区补充）**：Harness 界面显示的「缓存命中 %」是**对话内**口径——只统计当前会话这一路请求。若同一时间段开过多个对话，其他对话命中率较低时，会把**多对话整体/后台口径**拉低（社区实测对照：后台/整体约 94.5% vs 界面（对话内）98%，[#1234](https://github.com/deepseek-ai/deepseek-harness/discussions/1234)）。**测量命中率时先明确口径**：对话内（界面统计行）还是多对话整体（后台/API 侧）；对比命中率只在同口径下才有意义。*

指标	看哪里	命中时的表现	
缓存命中 %	会话统计行（Web UI 底部）	稳定在高位（长会话 97%+）	
首 token	每轮结束行	从 10s+ 量级性降到 1s 以下（第 6 章 FAQ Q4）	
总 token	会话总览	增量小 = 命中率在变大（14.1 结构）	

14.3 命中率优化实践

三个杠杆，按性价比排序：

杠杆	做法	原理	
会话延续	长任务保持会话延续，避免频繁新建会话；批量任务放同一会话/同前缀	历史消息重复 → 命中	
稳定提示词	系统提示/技能目录等前缀保持稳定，不频繁改配置；工具 schema 不变	前缀一致 → 命中	
少打断	一次把验收标准写清楚（第 5 章 5.7 / 第 10 章 案例启示），减少"重开会话重讲上下文"	避免前缀重建 → 全价重来	

落地检查：命中率低于预期时，第一反应查"前缀是否变了"——改过配置、换过档位、动过技能目录，都会让缓存失效（第 6 章 6.6 监控行）。

14.4 成本模型：命中率如何决定账单

成本模型速记（第 6 章 6.6）：总成本 ≈ 输出 token×输出价 + 输入未命中×未命中价 + 输入命中×命中价——Agent 工作负载输入占比高，缓存命中率是成本的第一变量。

用第 5 章 Flash 输入价算一笔账（10k 输入 token，命中率对比）。算术示例（90% 命中）：9,000 × \$0.0028/M + 1,000 × \$0.14/M ≈ \$0.000165——先把命中/未命中拆开，再分别乘各自单价：

命中率	命中 token	未命中 token	输入成本 (Flash)	相对成本	
90%	9,000	1,000	≈ \$0.000165	1×	
50%	5,000	5,000	≈ \$0.000714	≈ 4.3×	
10%	1,000	9,000	≈ \$0.001263	≈ 7.6×	

放大到 1M 输入 token：90% 命中 ≈ \$0.0165，10% 命中 ≈ \$0.126，全价 \$0.14——差近一个数量级。

再放大到手册实测量级（5.1.1：50 步工具链、2.4M 输入 token）：97% 命中 ≈ \$0.017，全价 ≈ \$0.34，约 20×。这就是 5.1.1"成本远低于按未命中价计算的预期"的数字来源。

注：本表只算输入侧——第 5 章定价表只收录输入价，输出侧请按官方定价页补充。输入占比高的 Agent 场景下，输入侧就是主变量。

14.5 推理档位联动：low/high/max 成本矩阵

推理档位管"思考量"，与缓存是两个正交杠杆：档位影响 token 总量，缓存影响输入单价，两者相乘。思考 token 减少 → 总 token 下降（第 6 章 6.6），且随上下文重复的部分同样吃缓存折扣（推断，待实测）。

档位	思考 token 量	相对成本	适用场景（第 6 章 6.2）	成本策略	
low	最少	最低	简单/确定性轮次：文件操作、批量、工具链中的廉价步	批量任务的默认档	
high	中等	中等	日常 Agent 任务（默认）	质量与成本的默认平衡	
max	最多	最高	复杂推理、长链规划、debug	单次复杂任务可用，别开进批量循环	

联动要点：

- ****长工具链任务（20-50 步）收益最大****：每步思考降档的累计效果显著（第 6 章 FAQ Q2）——档位 × 命中率两个杠杆同时作用于每一步
- 简单轮次用 `low` 档质量几乎无差别；复杂推理用 `low` 可能漏关键步骤（第 6 章 FAQ Q3）
- ****叠加示例****（2.4M 输入量级任务，Flash 价）：`low` + 97% 命中 $\approx$ \$0.017 以下（思考量更低，实际更少，推断，待实测）；`max` + 反复冷启动 $\approx$ \$0.34 以上——**同一任务，两个杠杆全开与全关差 20×+**
- 注：`low/high/max` 为本手册实测网关（pi-ai/opencode-go）档位；默认 deepseek-official 适配器为 `off/high/max`（第 6 章 6.2 注释）

14.6 预算实战：案例 A 成本估算

以第 10 章案例 A（数据质量分析，186 秒）为样本做预算：工具链 read → write(clean.py) → bash → write(visualize.py) → bash → read → 总结，约 6-8 步。按 5.1.1 量级折算（50 步 $\approx$ 2.4M 输入 token），案例 A 输入量级约 50 万 token（推断，待实测）：

场景	命中率	输入成本 (Flash, 估算)	
会话延续 + 前缀稳定 (推荐做法)	97%	$\approx$ \$0.0035	
中途新开会话/前缀变动	10%	$\approx$ \$0.063	
极端：每次全价	0%	\$0.07	

步骤级拆解（为什么会话延续省钱）——只有首轮是冷启动全价，后续每轮只有"本轮消息 + 工具结果"这一小段新增量未命中（推断，待实测）：

步骤	内容	输入 token (推断, 待实测)	命中状态	
1	readsalesdata.json	~5 万	冷启动 (未命中)	
2-6	write/bash/ write/bash/read/ 总结	~45 万	前缀命中区，增量极小	

结论：一次 3 分钟的真实任务，输入侧成本不到 1 美分；同样的活，做法不同（会话延续 vs 反复冷启动）成本差约 18×。输出侧（两个脚本 + 总结）量级远小于输入，总成本仍为美分级（推断，待实测）。这就是"dsh 配 V4-Flash 成本约为 Claude 的 1/10~1/30"（第 1 章实测）在单任务维度的来源。

14.7 测量方法：让 token 消耗可见

现状（有的）：

- Web UI 底部会话统计行：`N 轮 · M 步 | LLM Xs · 工具调用 Ys | 首 token 平均 ...` (第 6 章 6.3)
- 每轮结束行：`10:14 · 用时 9 分 34 秒 · 首 token 1.7 秒 · 79 tok/s`
([#735](https://github.com/deepseek-ai/deepseek-harness/discussions/735) 原帖截图)
- 会话总览有总 token 统计；统计行可见“缓存命中 %” (第 6 章 6.6) ——**对话内口径**，多对话整体命中率会被其他低命中对话拉低 ([#1234](https://github.com/deepseek-ai/deepseek-harness/discussions/1234) 社区补充，见 14.2 口径注意)

缺口 (没有的)：每轮 token 数。官方讨论区

[#735](https://github.com/deepseek-ai/deepseek-harness/discussions/735) (2026-08-14 提出，标题「【友好显示】希望在每轮对话中加入本轮对话 token 消耗量」) 正是这个需求——已在帖子中确认存在，官方尚未实现。

另一个缺口 (#735 评论区 Jianye)：希望在每轮显示中带 provider 与 model id 标识 (原帖截图里 xtoken: gpt-5.6-sol 这类“provider + modelid”信息用户希望界面直接给出) ——同一需求帖下的补充诉求。

社区建议 (已同步到 #735 评论区)：每轮显示应拆成两个数——① 本轮总 token (粗看消耗)；② 本轮缓存命中/未命中 token (看成本优化空间)。只看总 token 会误判：同样 10k token，命中率 90% 和 10% 成本差 7.6× (见 14.4)。

过渡期工具：社区 dsh-plugin-cost-tracker (第 9 章 9.5/9.6，实时 token 成本追踪，插件/MCP 形态) ——实现层面走第 4 章的插件扩展点，在请求/会话事件上统计 usage (推断，待实测)；或按会话日志/API usage 字段手工核算。第 11 章预测“缓存命中率工具化”是中期主线 (11.2) ——#735 落地后成本透明化闭环。

更完整的社区实测工具：dsh-usage (作者

kestiany, [#1169](https://github.com/deepseek-ai/deepseek-harness/discussions/1169) 收录授权)。npm 已发布 0.1.0 (dsh plugin --profile web add dsh-usage 即可安装)，基于 Harness 持久化会话日志计算、无需独立统计数据库。核心能力：

- **每轮对话结束位置固定展示**：`Total · Input · Cache · Output · Cost`——正好补齐 #735 缺的“每轮 token 数”，且区分输入/缓存命中/输出
- **Settings → Usage 完整用量页**：总 token、输入、缓存命中、输出、调用次数及**预估费用** (需为 Provider/模型配置价格；缺 usage/价格时费用显示 `--`，对话底部省略 Cost，避免把不完整费用当总费用)
- **52 周用量热力图** (GitHub Contributions 风格) + 按模型/会话/单轮查看
- 支持 DeepSeek Harness 中的其他模型和 Provider；`Cost` 为估算值，不代表供应商最终账单

记忆/压缩生态工具 (#1052 长会话降本专题评论区，2026-08-14) ——针对“长会话 token 暴涨” (原帖实测 70M→100M)，社区给出两个互补方案：

工具	作者	定位	机制	
dsh-sgme (freehul/ sgme https://github.com/freehul/sgme , npm 包 dsh-sgme)	freehul	记忆引擎（治本）	「对话历史」与「长期记忆」分层：每轮零成本落盘（L0，不走 LLM）→ 会话结束提炼去重合并（L1/L1.5/L2，提炼前先剪枝剔除无用工具调用/中间产物，实测省 65%~96% 会话内容）→ 新会话按场景只注入相关记忆块（纯结构化查询，不烧 token）→ 需要细节时 memorysearch 按需检索	
pi-quiet-tools（经 pi2dsh https://github.com/weijiafu14/pi2dsh 挂载）	weijiafu14 提供（freehul 亦推荐）	工具输出压缩（治标）	在进入模型上下文前压缩大工具结果：默认超过 12,000 字符或 240 行时只把确定性的头尾预览交给模型，完整结果存本地 artifact、需要时模型再读；阈值可用 QUIETTOOLSMAXCHARS / QUIETTOOLSMAXLINES 调整。对 MCP/Playwright 大返回体有效（作者实测 40,799 字符闭环压缩）。与缓存兼容：见 14.1 严格前缀缓存规则——不绕开缓存，反而缩小"必然首次 miss"的工具结果	

安装示例（pi-quiet-tools，摘自 #1052 作者实测）：

```
npm i -g pi2dsh pi2dsh host --packages pi-quiet-tools@0.2.0 --out ./dsh-pi-quiet dsh plugin --profile web add file:$PWD/dsh-pi-quiet
```

两者不冲突：pi-quiet-tools 解决"大工具结果反复进上下文"，dsh-sgme 解决"长会话越用越贵/延续性"——前者立即生效，后者适合需要跨会话迁移记忆的场景（#1052 评论区共识：把"对话历史"和"长期记忆"分开，历史该滚就滚、记忆按需注入）。

14.8 成本相关踩坑清单

#	坑	现象	解法	
1	缓存命中误判成"模型变快"	A/B 对比被 1s vs 110s 误导（第 6 章坑 #6）	对比测试用全新 prompt	
2	频繁新建会话烧钱	每个任务都冷启动，输入全价	长任务/批量保持会话延续	
3	改配置悄悄杀掉命中率	命中 % 突然下降，成本上涨	监控统计行命中 %，前缀稳定	
4	只看总 token 误判成本	10k token 90% vs 10% 差 7.6×	拆命中/未命中看（#735 建议）	
5	预算漏了输出侧	只按输入价算，账不对	按官方定价页补输出价（第 5 章只收录输入价）	
6	档位乱开	批量任务开 max，成本翻倍	批量用 low，复杂任务才 max	

14.9 决策建议速查

场景	建议	
长工具链任务（20-50 步）	high + 会话延续 + 前缀稳定；2.4M 输入量级 ≈ \$0.017（97% 命中）	
批量/简单轮次	low + 同会话批量（命中红利最大）	
复杂推理/debug	max（成本换质量），单次任务可接受冷启动	
成本敏感批处理	low + headless + 单会话串行	
性能/成本对比测试	全新 prompt + 固定档位 + 多次取中位数（第 6 章 6.4/6.6）	
命中率异常下降	先查前缀是否变动（配置/技能目录/模型档位）	

动手练习（检验你是否真懂了）

1. ****理解题****：为什么说"缓存命中率是成本的第一变量"？用 14.4 的 10k token 表格解释 90% 与 10% 命中差多少倍
> 自查：参考 14.4 对比表（7.6×）与 6.6 成本模型速记
2. ****动手题****：跑一个 3 步任务，观察 Web UI 底部的会话统计行和每轮结束行（时间/首 token/tok/s），判断这次任务大概命中了多少缓存
> 自查：参考 14.7 测量方法与 6.3 统计行格式
3. ****动手题****：把同一批任务分别用"每项新开会话"和"同会话连续跑"两种方式执行，对比耗时差异——新开会话大概率首轮明显变慢（冷启动）
> 自查：参考 14.1 冷启动 110s vs 热缓存 1s 的实测
4. ****思考题****：为什么"只看本轮总 token"会误判成本？#735 评论区建议把每轮显示拆成哪两个数？
> 自查：参考 14.7 节"社区建议"段落
5. ****动手题****：按 #735 的建议口径，把一个会话的总 token 手动拆成"命中/未命中"两部分，用 14.4 的单价分别核算，验证"差一个数量级"的说法
> 自查：参考 14.4 对比表与 14.2 测量方法表

常见疑问 FAQ

Q1：缓存命中率最高能到多少？

手册实测 97%（第 5 章 5.1.1）；社区长跑实测可达 99.7%

（[#560](https://github.com/deepseek-ai/deepseek-harness/discussions/560)）。但全新任务/冷启动会明显下降（第 12 章 12.5）——命中率是"做法"的函数，不是模型的常数。

Q2：low 档会明显降低质量吗？

简单确定性任务（文件操作、批量处理）几乎无差别；复杂推理、长链规划、debug 用 low 可能漏掉关键步骤（第 6 章 FAQ Q3）。建议日常 high，批量/简单任务切 low。

Q3：官方什么时候提供每轮 token 显示？

[#735](https://github.com/deepseek-ai/deepseek-harness/discussions/735) 是 2026-08-14 提出的需求帖（每轮 token + provider/model 标识，见 14.7），尚未实现。过渡期用：会话统计行命中 % + 社区 dsh-plugin-cost-tracker（第 9 章）或 dsh-usage（14.7）。

Q4：第三方网关/自建 provider 也吃缓存折扣吗？

缓存折扣是 DeepSeek API 侧能力（第 5 章定价表）；第三方网关的缓存支持与计费需查对应定价页（推断，待实测）。

Q5：为什么缓存命中后任务会明显变快？

命中的前缀部分无需重新计算，首 token 时间量级性缩短（冷启动 ~110s vs 热缓存 ~1s，第 1 章实测）。判断方法：首 token 突然从 10s+ 降到 1s 以下，大概率命中（第 6 章 FAQ Q4）。做性能对比时用全新 prompt，避免缓存干扰（第 6 章坑 #6）。

本章信息截至 2026-08-14（dsh 0.1.0-rc.6）。定价与缓存策略以官方文档为准；标注"（推断，待实测）"处为推算或预估，欢迎实测后 PR 修正。

附录 B：官方包速查大全（@deepseek-ai/*）

****本清单为「已知包」清单****：收录白皮书正文实测/提及过、且能在 npm registry 上核实的官方包（@deepseek-ai/dsh-* 与 @deepseek-ai/cordis），包描述来自 npm view 实测结果。dsh 处于 0.1.0-rc 快速迭代期，**包名与描述随版本更新**——若与官方仓库 packages/AGENTS.md 或 npm 最新描述不一致，以官方为准。未能核实的包标注「（待补全）」，不虚构包名。

****包数口径****：本清单收录经 npm 核实的 ****33 个核心包****（CLI 直接依赖 53 个 + 家族发布总量 221 个，见 [08 章 8.1 节](./08-tools-context.md) 说明）；白皮书/官方所称「60+ 能力包」指仓库 packages/ 下全部子目录，完整列表见官方仓库 packages/README.md（47 组权威表）。

包名与仓库布局对应关系：npm 包 @deepseek-ai/dsh-xxx ≈ 官方仓库 packages/<group>/xxx（如 dsh-tool-fs ↔ fs/tool-fs）。

验证方式：npm view @deepseek-ai/<name> description（2026-08 快照）。

能力域取值：工具（模型可调用的工具/执行管道）· 上下文（请求上下文组装与压缩）· 会话（会话持久化/标题/遥测）· 子代理（委派子任务）· MCP（外部工具服务器接入）· 工作流（多步编排）· 安全（沙箱/审批/循环卫生）· LLM（模型接入与策略）· UI（浏览器界面与客户端服务）· 核心（CLI/骨架 bundle，不属上述能力域）。

核心（Core）：CLI 与骨架 bundle

dsh 的“地基”：装一个 @deepseek-ai/dsh 就能跑，profile 由内置 bundle 栈堆出来（dsh-base → dsh-headless / dsh-web-app）。

包名	用途	能力域	
@deepseek-ai/dsh	dsh CLI：profile 启动、插件管理、浏览器 UI 别名（npx -y @deepseek-ai/dsh web）	核心	
@deepseek-ai/dsh-base	共享 dsh 核心 profile bundle：每个 profile 的第一层补丁，在空 profile 根上插入基础插件行	核心	
@deepseek-ai/dsh-headless	headless 一次性 bundle：无 Host/HTTP/浏览器层的直接 core	核心	

	Agent/Session 运行器		
@deepseek-ai/dsh-agent	Agent 接口、注册表、发起者作用域与事件词汇 (插件开发常直接依赖)	核心	
@deepseek-ai/dsh-web-app	dsh 浏览器面 bundle: web patch 层 (前端 dist 服务、web 面提示词、bash 运行时变量、URL 行)	核心	
@deepseek-ai/cordis	底层元框架: 现代 JavaScript 应用的依赖注入/事件/生命周期容器 (dsh 的插件底座)	核心	

工具 (Tools) : 模型可调用的能力

模型实际看到的工具名是简短动词 (read/write/grep/glob/edit/bash/websearch/todowrite...) , 底层由本组包提供实现。

包名	用途	能力域	
@deepseek-ai/dsh-tools	工具注册表与执行管道 (tool registry + execution pipeline)	工具	
@deepseek-ai/dsh-fs	抽象文件系统能力 seam (ctx.fs) : 词汇类型、FileSystem 服务 (文本 IO + 可选版本守卫原子写)、fs/ 策略事件词汇	工具	
@deepseek-ai/dsh-tool-fs	模型侧文件系统工具 (read、write、edit) , 基于 ctx.fs	工具	
@deepseek-ai/dsh-tool-fs-search	模型侧文件发现工具 (glob、grep) , 内置打包的 ripgrep 二进制	工具	
@deepseek-ai/dsh-tool-str-replace-editor	模型侧编辑工具: 查看、创建、字面量替换、行插入 (工具结果含 locations → 产物追踪)	工具	
@deepseek-ai/dsh-shell	抽象 bash 执行器 seam (ctx.shell)	工具	
@deepseek-ai/dsh-	模型侧 bash 工具, 可选	工具	

tool-bash	通用后台任务与沙箱升级支持		
@deepseek-ai/dsh-web	抽象 web 访问能力 seam (ctx.web) : search/fetch 提供者注册表、与注册顺序无关的选择、请求/结果词汇、WebError 分类	工具	
@deepseek-ai/dsh-tool-web	模型侧 web 工具 (websearch、webfetch) , 基于 ctx.web	工具	
@deepseek-ai/dsh-tool-todo	模型侧待办工具 todowrite, 基于事件溯源会话日志	工具	
@deepseek-ai/dsh-tool-skill	模型侧技能加载工具 (skill 调用入口)	工具	

上下文 (Context) : 上下文组装与压缩

"装什么" (系统提示 + 技能目录 + 历史 + 工具 schema) 与"装不下时怎么压缩"。

包名	用途	能力域	
@deepseek-ai/dsh-system-prompt	系统提示组装注册表 (官方插件经 systemPrompt.section 注册提示片段)	上下文	
@deepseek-ai/dsh-compaction	抽象压缩服务 seam (ctx.compaction)	上下文	
@deepseek-ai/dsh-compaction-basic	token 计量驱动的压缩策略 + LLM 摘要后端 (检测溢出 → 修剪 → 摘要)	上下文	
@deepseek-ai/dsh-skill	Agent 技能提供者注册表 (技能目录注入上下文, 模型按需调用)	上下文	

会话 (Session) : 持久化、标题、遥测

包名	用途	能力域	
@deepseek-ai/dsh-session	事件溯源会话存储 (event-sourced session store)	会话	

@deepseek-ai/dsh-session-title	基于日志的会话标题服务与提供者注册表	会话	
@deepseek-ai/dsh-session-telemetry	遥测 seam：会话事件捕获、投影、脱敏、交接给上报后端	会话	

子代理 (Subagent)：委派子任务

包名	用途	能力域	
@deepseek-ai/dsh-subagent	抽象子代理 seam (ctx.subagents)：委派子代理的命名提供者注册表	子代理	

MCP：外部工具服务器接入

包名	用途	能力域	
@deepseek-ai/dsh-mcp-client	MCP 客户端桥：连接 MCP 服务器并把其工具注册到 ctx.tools	MCP	

工作流 (Workflow)：多步确定性编排

包名	用途	能力域	
@deepseek-ai/dsh-workflow	工作流能力 seam：ctx.workflows 服务、run 词汇、workflow/ 事件	工作流	

安全 (Safety)：沙箱、审批、循环卫生

包名	用途	能力域	
@deepseek-ai/dsh-sandbox	抽象进程沙箱 seam (ctx.sandbox)：同世界隔离词汇 + SandboxProvider 契约	安全	
guard/	循环卫生与工具超时 (白皮书 8.5 提及；npm 上具体包名待补全)	安全	
interaction/	权限/审批 (危险操作确认；npm 上具体包名待补全)	安全	

LLM：模型接入与策略

包名	用途	能力域	
@deepseek-ai/dsh-llm	Provider 无关的 LLM 服务接口	LLM	
@deepseek-ai/dsh-llm-deepseek	DeepSeek chat-completions 适配器（默认 provider=deepseek-official，接受 off/high/max 档位）	LLM	
@deepseek-ai/dsh-llm-retry	Provider 路由的 LLM 请求重试策略	LLM	

UI：浏览器界面与客户端服务

包名	用途	能力域	
@deepseek-ai/dsh-client-runtime	客户端核心服务：SlotsService、SessionsService（作用域树 + 对象层）	UI	
@deepseek-ai/dsh-client-locale	语言包插件：Host 端 zh/en 偏好、浏览器端回退、语言快照、类型化命名空间字典	UI	
ui-conversation / ui-tool 等	Web UI 各部件（白皮书 8.1 提及 client/；npm 上具体包名待补全）	UI	

已知名但 npm 未发布（历史 404 包）

以下包名仅存在于白皮书踩坑记录中，在 npm 上无法安装（rc.1 时代依赖断裂的根源），遇到 404 属正常：

包名	说明	
@deepseek-ai/dsh-pty	rc.1 时代依赖，从未发布（pnpm dlx 404 的根因，见第 2 章 FAQ）	
@deepseek-ai/dsh-type-meta	rc.1 时代依赖，从未发布（rc.1 依赖断裂的根因，见第 3 章 3.5 节）	

规避方式：依赖统一走 `^0.1.0-rc.6` 线。

相关章节: [第 8 章 · 工具与上下文系统](./08-tools-context.md) (60+ 能力包地图) · [第 9 章 · MCP 子代理与 workflows](./09-mcp-subagent-workflow.md) · [术语表与命令速查](./appendix-glossary.md)

附录 A：术语表与命令速查

术语表

术语	一句话解释	
Harness	套在模型外的工程层：会话、工具、上下文、循环控制	
dsh	DeepSeek Harness 的命令行名 (dsh 命令)	
Profile	一种可启动形态 (web / headless / 自定义) , = bundle 栈 + patch 层	
Bundle	一组插件的集合 (官方: dsh-base、dsh-web-app、dsh-headless)	
Cordis	dsh 底层的插件容器 (依赖注入、事件、生命周期)	
插件 (Plugin)	cordis 插件; 可同时携带 host 半 (Node) 与 client 半 (浏览器)	
host 半 / client 半	插件在 Node 侧 (工具/服务/事件) 与浏览器侧 (UI) 的两副面孔	
扩展点	官方提供的钩子 (agent/request、settings、conversationEvents、slots)	
agent/request waterfall	每步模型请求前可改配置的事件链 (插件在此注入 reasoningEffort 等)	
reasoningeffort	思考强度 (官方适配器 off/high/max; low 为实测网关档位) ——速度与质量的权衡旋钮	
headless	一次性 CLI 任务模式 (dsh --profile headless "任务")	
compaction	长对话上下文压缩	
subagent	子代理 (并行委派任务)	
MCP	模型上下文协议 (接入外部工具服务器)	
workflow	多步确定性工作流编排	

locations	工具返回的文件路径（驱动产物追踪）	
extension point	官方钩子（agent/request 等），插件接入点	
waterfall	事件链：监听者可改配置传给下一个（agent/request 用此注入）	
context cache	DeepSeek 提示词缓存（重复输入按折扣价计费）	
缓存命中率	输入 token 走缓存价的比例（dsh 实测可到 97%）	
TUI	终端 UI（官方未内置，需插件）	
turn	对话的一轮（用户+助手+工具调用）	
step	turn 内的一个推理步骤	
guard	循环卫生/工具超时插件	
skill	技能（skill-catalog 注入上下文，模型按需调用）	
inject	cordis 依赖注入（插件声明所需服务）	
产物文件	模型创建/修改的文件（对话末尾的可打开 chips）	
sandbox	命令执行的隔离沙箱	
rc	预发布版本（0.1.0-rc.6），迭代快、可能有破坏性变更	

命令速查

dsh 核心

```
dsh web # 启动 Web UI dsh --profile headless "任务"
# 一次性任务（脚本/CI） dsh --version # 版本 dsh --dump-
config # 合成配置树 dsh plugin --profile <name> add <pkg>
# 安装插件
```

环境

```
node --version # 需 ≥ 22 npm install -g @deepseek-ai/dsh
# 全局安装 npx -y @deepseek-ai/dsh web # 免安装运行
```

排障

```
netstat -ano | findstr 3080          # 端口占用 (Windows) taskkill /PID <pid> /F
# 杀进程 cat ~/.dsh/settings.yaml    # 全局配置 (模型/推理档位)
```

插件开发

```
# 挂载到 profile (web 为例) # ① package.json 加依赖: "pkg": "link:C:\\path\\to\\pkg" # ②
cordis.patch.yml 加: #      - insert: #      - id: <插件id> #      name: <npm 包名> cd
~/.dsh/profiles/web && pnpm install    # 安装
```

配置参考 (settings.yaml)

<!-- [fix] 技术准确性核验: 官方 DeepSeek 适配器档位为 off / high / max (low 为 pi-ai/opencode-go 网关档位) , 见 02-quickstart 2.3 注 -->

```
agent-default-model:  model: deepseek-v4-flash    # 或 deepseek-v4-pro    reasoningEffort:
high                  # off (关闭思考/最快) / high (默认) / max (最强)
```

附录 B: [官方包速查大全](./appendix-packages.md) · 附录 C: [同模型多 Agent 实测](./benchmark.md)

附录 C：同模型 × 不同 Agent 实测对比 (Benchmark)

实测日期: 2026-08-13 | 模型: deepseek-v4-flash (同一 opencode-go 网关, 同一 API key) | Agent: dsh / opencode / omp

目的: **控制模型变量, 对比 Agent 工程层的差异** (提示词、工具链、轮次管理)。

扩展: 2026-08-13 追加 T4 (生成 markdown 报告) / T5 (多文件小重构), 样本 3 轮 → 5 任务 × 3 轮。

方法

项	说明	
模型	deepseek-v4-flash (三 agent 均走 opencode-go 网关 + 同一 key, 公平对照)	
Agent	dsh (headless profile)、opencode (opencode run)、omp (--print 非交互)	
任务	T1 创建文件 / T2 搜索统计 / T3 修复 bug + 验证 / T4 读数据生成报告 + 自复核 / T5 多文件重构 + 测试通过	
环境	Windows 11 + Node 24, 独立工作目录, 无预置上下文	
度量	耗时 (秒) + 正确性 (人工核对产物/输出)	

任务说明 (T4/T5 为合成数据, 无隐私风险) :

任务	输入	要求	人工核对标准	
T4 生成报告	data.json (4 条合成销售记录)	生成 report.md: 数据表格 + 汇总 (总销量/总营收/最畅销), 自复核	汇总数字与数据一致 (397 / 130853 / 耳机)	
T5 多文件重构	mathops.py + 依赖它的 main.py (含断言)	把 multiply 的乘法逻辑提取为 multiply 辅助函数, 不改 main.py, python main.py 通过	出现 multiply 且 multiply 委托调用、断言全过	

结果（3 轮采样，取中位数）

Agent	T1 创建文件	T2 搜索统计	T3 修 bug+验证	T4 生成报告	T5 多文件重构	总计（中位）	正确率	
omp	10s	11s	15s	21s	13s	70s	45/45	
dsh	22s	15s	48s	26s	19s	130s	45/45	
opencode	35s	37s	42s	30s	28s	172s	45/45	

总计 = 5 任务中位数相加; 扩展前 (仅 T1-T3) 为 omp 36s / dsh 85s / opencode 114s。
![benchmark 柱状图](./assets/benchmark-bar.svg)

原始 3 轮（秒）：

Agent	轮次	T1	T2	T3	T4	T5	
dsh	1 / 2 / 3	11 / 27 / 22	11 / 15 / 22	27 / 48 / 74	30 / 26 / 25	19 / 25 / 18	
opencode	1 / 2 / 3	18 / 35 / 35	19 / 37 / 37	50 / 41 / 42	30 / 49 / 30	28 / 28 / 32	
omp	1 / 2 / 3	9 / 10 / 12	9 / 11 / 12	13 / 33 / 15	23 / 21 / 17	16 / 12 / 13	

解读

- 1. ****正确率三家持平（45/45）****——5 任务 × 3 轮全部正确。同模型下，Agent 工程层的差异主要体现在****效率****而非****能力上限****；即便引入文档生成与多文件重构两类新任务，正确性差异仍未出现。
- 2. ****总耗时稳定排序****：omp < dsh < opencode（3 轮一致，中位数相加 70s / 130s / 172s）。
- 3. ****任务类型对效率差异的影响****（本次扩展的核心发现）——按耗时画像，5 个任务可归为三类：
 - ****单步轻量****（T1 创建文件 / T2 搜索统计）：agent 间差距****最大****。opencode 35/37s vs omp 10/11s（约 ****3.4×****）。任务越简单，越接近纯"启动 + 一次工具调用"开销，opencode 的启动/框架开销占比越高。
 - ****多步执行 + 验证****（T3 修 bug + 跑验证 / T5 多文件重构 + 测试）：dsh 与 opencode 在此类任务上差距****显著收窄****（T5：19s vs 28s；T3：48s vs 42s 甚至反超）。多工具链场景下，双方都要多次读文件/改文件/跑命令，框架层"每步思考"成本拉平了启动开销差异；dsh 的优势在 T5 上最明显（19s，接近 omp 的 13s），而 T3 的 bug 定位仍让 dsh 偏慢。

- **文档生成** (T4 读数据 → 写报告 → 自复核) : agent 间差距**最小** (omp 21s / dsh 26s / opencode 30s, 约 1.4×)。报告生成是"读一次 + 写一次长文本"的回路, 耗时主要由模型**输出 token 数**主导, Agent 工程层能优化的工具往返很少, 故三家趋同。
- 4. **反直觉点**: T5 (重构+测试) 普遍比 T4 (写报告) 更快 (dsh 19s<26s、omp 13s<21s; 仅 opencode 28s≈30s)。原因: 重构是"短文本代码编辑 + 秒级 `python main.py` 验证"的回路, 每步模型思考短; 而写 markdown 报告需要一次较长文本生成, 输出时间占比高——与第 6 章"工具链任务 90% 时间在模型思考/生成"的性能模型一致。
- 5. **omp 的领先幅度随任务类型变化**: 搜索统计类最大 (T2 为 opencode 的 3.4×), 文档生成类最小 (T4 仅 1.4×)。说明 omp 的优势主要在**轮次少、工具调用快**, 而非模型本身; 当任务由长文本生成主导时, 任何 agent 的工程层都难再压缩模型输出时间。
- 6. **波动性提示**: opencode 在 T4 第 2 轮出现 49s 离群 (其余两轮 30s), dsh 在 T3 波动最大 (27→74s)。多轮中位数能吸收这类网络/工具链抖动, 单轮比较需谨慎。
- 7. **dsh 定位**: dsh 居中, 且 headless 是"运行时 + 插件生态"——**同样的模型, 通过插件 (如提速插件降推理档) 可进一步优化耗时** (见第 6 章); T5 实测已接近 omp, 说明多文件重构类任务是其相对强项。
- 8. **样本警示**: 3 轮 × 5 任务, 同网关同 key, 含网络抖动——方向可信, 绝对值会随环境波动。

可复现

```
# 三个 agent 的命令 (独立目录) dsh --profile headless "任务" opencode run "任务" --model
opencode-go/deepseek-v4-flash omp "任务" --model deepseek-v4-flash --print
```

T4/T5 任务原文 (T1-T3 见上一版本记录) :

<!-- [style] 任务原文代码块统一补 text 语言标签 -->

T4: 读取当前目录 data.json 中的数据, 生成 markdown 报告 report.md: 包含每行数据的表格 (产品/销量/单价三列) 和汇总 (总销量、总营收、最畅销产品), 生成后自己复核汇总数字与 data.json 一致, 完成后回复 已生成
T5: 重构 mathops.py: 把 multiply 函数内的乘法逻辑提取为私有辅助函数 _multiply(a, b), multiply 改为调用 _multiply; main.py 依赖 mathops.py 并包含断言测试, 不得改动 main.py; 重构后运行 python main.py 验证所有断言通过, 完成后回复 已重构

*完整任务定义、合成数据与产物: `~/agent-bench/bench-ext/` (T4/T5 每 agent 独立目录) ;
T1-T3 见 `~/agent-bench/`。白皮书仓库内 `benchmark/` 目录规划中。*

一页速查卡 (Cheatsheet)

打印/收藏这张卡，日常用 dsh 不用翻书。

安装与启动

```
npx -y @deepseek-ai/dsh --version      # 免安装运行 npm i -g @deepseek-ai/dsh      #
全局安装 dsh web                      # Web UI → http://127.0.0.1:3080 dsh --
profile headless "任务"                # 一次性任务 (脚本/CI)
```

配置 (~/.dsh/settings.yaml)

```
<!-- [fix] 技术准确性核验：官方 DeepSeek 适配器（默认 provider=deepseek-official）仅
接受 off / high / max; low 为 pi-ai (opencode-go) 网关档位 -->
agent-default-model:  model: deepseek-v4-flash      # 或 deepseek-v4-pro  reasoningEffort:
high                  # off (关闭思考/最快) / high (默认) / max (最强)
```

推理档位

档位	用途	备注	
low	简单/批量/工具链廉价轮 (最快)	仅实测网关 (pi-ai/ opencode-go) 支持	
high	日常默认	官方适配器默认	
max	复杂推理/长链规划	官方适配器支持	
off	关闭思考/最快	DeepSeek 官方适配器档 位 (替代 low)	

工具链任务 90% 时间在思考——降档是最快提速。

核心命令

命令	用途	
dsh web	Web UI	
dsh --profile headless "任务"	一次性任务	
dsh --dump-config	看合成配置	
dsh plugin --profile <n> add <pkg>	装插件	

插件挂载 (两步)

```
# package.json 加依赖 "my-plugin": "link:C:\\path\\to\\my-plugin" # cordis.patch.yml 加挂载
- insert:      - id: my-plugin      name: my-plugin
cd ~/.dsh/profiles/web && pnpm install && dsh web
```

提示词黄金法则

- 1. ****写验收标准****: ``"运行验证通过"`` > ``"写个脚本"``
- 2. ****给上下文****: 文件在哪、数据长啥样、读者是谁
- 3. ****一次一个任务****: 小闭环比巨型任务可靠

缓存省钱

- 长任务保持会话延续（别频繁新建）
- prompt 前缀稳定（别老改配置）
- 看 Web UI 底部"缓存命中 %"（实测可到 97%）

排障速查

现象	解法	
端口占	netstat -ano \	findstr 3080 → kill
模型无响应	查 settings.yaml + API key	
插件装不上 404	依赖用 ^0.1.0-rc.6 线	
长任务崩	全局安装（绕 npx）+ 降推理档	

术语（速记）

profile 形态 · bundle 插件组 · host/client 半 服务端/界面 · 扩展点 官方钩子 · waterfall 请求链 · compaction 上下文压缩 · headless 一次性 CLI · locations 产物路径

完整教程见 [dsh-handbook 白皮书](https://github.com/Electricitysheep/dsh-handbook) · [配置参考](./config-reference.md) · [术语表与命令速查](./appendix-glossary.md)